

课堂小测

考虑以下随机变量分布：

$$\mathbf{p}_X = \left[\frac{1}{21}, \frac{1}{21}, \frac{2}{21}, \frac{4}{21}, \frac{6}{21}, \frac{7}{21} \right].$$

- (a) 进行二元 Huffman 编码；
- (b) 进行三元 Huffman 编码；
- (c) 分别计算 (a) 和 (b) 码率。

向量信源编码定理

- ① 向量信源编码
- ② 大数定律
- ③ 样本熵和典型集
- ④ 渐近均分性 (AEP)
- ⑤ 向量信源编码定理的证明

注：典型集和渐近均分性是信息论的基础

主要内容:

- 描述一个随机向量的最小无损率: $H(X)$
- 简单、渐近最优“典型集”编码
- 渐近均分性 (AEP) 证明


向量信源编码定理

- ① 向量信源编码
- ② 大数定律
- ③ 样本熵和典型集
- ④ 渐近均分性 (AEP)
- ⑤ 向量信源编码定理的证明

注：典型集和渐近均分性是信息论的基础

向量信源编码


- 单信源编码



- 输入：单随机变量
- 最优方案：Huffman 编码
- 最优编码 C^* : $H(X) \leq L(C^*) < H(X) + 1$


向量信源编码

● 单信源编码



- 输入：单随机变量
- 最优方案：Huffman 编码
- 最优编码 C^* : $H(X) \leq L(C^*) < H(X) + 1$

● 向量信源编码



- 输入： n 个随机变量组成的序列
- 最优方案：“典型集”编码（“渐近均分性”）
- 最优编码 C^* : $H(X) \leq L(C^*) < H(X) + \epsilon, \forall \epsilon > 0$

向量信源编码的符号表示

令 C 为信源编码码本，对一个信源符号 $\mathbf{x} \in \mathcal{X}^n$ ：

- 码字： $C(\mathbf{x})$
- 码长： $\ell(\mathbf{x})$
- 码率：

$$R(C) = \frac{1}{n} \sum_{\mathbf{x} \in \mathcal{X}^n} p_X(\mathbf{x}) \ell(\mathbf{x})$$

单变量情况： $L(C) = \sum_{x \in \mathcal{X}} p_X(x) \ell(x)$

- 单信源编码是向量信源编码 $n = 1$ 时的特例
- 码率 R 越低，描述随机变量序列 \mathbf{x} 所需比特数越少

向量信源编码定理

定理 (向量信源编码): 令 $\mathbf{X} = (X_1, \dots, X_n)$ 为 n 个独立同分布的随机变量, $X_i \sim p_x$ 的熵为 $H(X)$ 。则, 对任意 $\epsilon > 0$, 当 n 足够大时, 存在码率为 R 的向量信源编码满足:

$$H(X) \leq R < H(X) + \epsilon.$$

即, 当 $n \rightarrow \infty$ 时, $R \rightarrow H(X)$.

通过单信源编码定理证明

回顾：

定理 (单信源编码定理): 令 L^* 为一个最优 d 元码本 C^* 的期望码长, 则

$$H_d(X) \leq L^* < H_d(X) + 1.$$

等号成立条件为其概率分布是 d 进制。

通过单信源编码定理证明

回顾：

定理 (单信源编码定理)：令 L^* 为一个最优 d 元码本 C^* 的期望码长，则

$$H_d(X) \leq L^* < H_d(X) + 1.$$

等号成立条件为其概率分布是 d 进制。

将 $X = [X_1, X_2, \dots, X_n]$ 视为一个单随机变量：

例： $X_i \in \{0, 1\}$ ，概率为 $\{p_0 = 0.3, p_1 = 0.7\}$ ，则，

$$\mathbf{X} = [X_1, X_2] \in \{00, 01, 10, 11\} \sim \{a, b, c, d\}$$

各元素概率为

$$\{p_a = 0.09, p_b = 0.21, p_c = 0.21, p_d = 0.49\}$$

通过单信源编码定理证明

因此,

$$H_d(\mathbf{X}) \leq nL_n^* < H_d(\mathbf{X}) + 1,$$

通过单信源编码定理证明

因此,

$$H_d(\mathbf{X}) \leq nL_n^* < H_d(\mathbf{X}) + 1,$$

$$\frac{1}{n}H_d(\mathbf{X}) \leq L_n^* < \frac{1}{n}H_d(\mathbf{X}) + \frac{1}{n},$$

通过单信源编码定理证明

因此,

$$H_d(\mathbf{X}) \leq nL_n^* < H_d(\mathbf{X}) + 1,$$

$$\frac{1}{n}H_d(\mathbf{X}) \leq L_n^* < \frac{1}{n}H_d(\mathbf{X}) + \frac{1}{n},$$

$$H(X) \leq R < H(X) + \epsilon,$$

其中 $R = L_n^*$, $H(X) = \frac{1}{n}H_d(\mathbf{X})$ (\mathbf{X} 独立同分布), $\epsilon = 1/n$.

注: 可用 Huffman 编码, 但复杂度为指数级。

- 单信源编码定理 $\xRightarrow{\text{证明}}$ 向量信源编码定理

- 单信源编码定理 $\xRightarrow{\text{证明}}$ 向量信源编码定理
- 但单信源编码定理的证明比较复杂

- 单信源编码定理 $\xrightarrow{\text{证明}}$ 向量信源编码定理
- 但单信源编码定理的证明比较复杂
- 利用**典型集**和**渐近均分性**给出**简易证明**

向量信源编码定理

- ① 向量信源编码
- ② 大数定律
- ③ 样本熵和典型集
- ④ 渐近均分性 (AEP)
- ⑤ 向量信源编码定理的证明

注：典型集和渐近均分性是信息论的基础

样本均值和数学期望

假设 X_1, X_2, \dots, X_n 是 n 维独立同分布 (IID) 随机变量:

- 数学期望 & 方差, 由于 X_i 独立同分布, 期望和方差:

$$\mathbb{E}[X] = \sum_{x \in \mathcal{X}} x p(x), \quad \text{Var}[X] = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

样本均值和数学期望

假设 X_1, X_2, \dots, X_n 是 n 维独立同分布 (IID) 随机变量:

- 数学期望 & 方差, 由于 X_i 独立同分布, 期望和方差:

$$E[X] = \sum_{x \in \mathcal{X}} x p(x), \quad \text{Var}[X] = E[(X - E[X])^2] = E[X^2] - (E[X])^2$$

- 样本均值 \bar{X}_n 为

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

样本均值和数学期望

假设 X_1, X_2, \dots, X_n 是 n 维独立同分布 (IID) 随机变量:

- 数学期望 & 方差, 由于 X_i 独立同分布, 期望和方差:

$$E[X] = \sum_{x \in \mathcal{X}} x p(x), \quad \text{Var}[X] = E[(X - E[X])^2] = E[X^2] - (E[X])^2$$

- 样本均值 \bar{X}_n 为

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

- 由于 X_i 是随机变量, \bar{X}_n 同样也是随机变量, 且

$$E[\bar{X}_n] = E[X], \quad \text{Var}[\bar{X}_n] = \frac{1}{n} \text{Var}[X] \xrightarrow{n \rightarrow \infty} 0$$

样本均值和数学期望

假设 X_1, X_2, \dots, X_n 是 n 维独立同分布 (IID) 随机变量:

- 数学期望 & 方差, 由于 X_i 独立同分布, 期望和方差:

$$\mathbb{E}[X] = \sum_{x \in \mathcal{X}} x p(x), \quad \text{Var}[X] = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

- 样本均值 \bar{X}_n 为

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

- 由于 X_i 是随机变量, \bar{X}_n 同样也是随机变量, 且

$$\mathbb{E}[\bar{X}_n] = \mathbb{E}[X], \quad \text{Var}[\bar{X}_n] = \frac{1}{n} \text{Var}[X] \xrightarrow{n \rightarrow \infty} 0$$

- 若 X_i 服从伯努利 (两点) 分布, 即 $X_i \sim B(1, p)$, 则

$$\Pr(\bar{X}_n = z/n) = \binom{n}{z} p^z (1-p)^{n-z}, \quad z = 0, 1, \dots, n$$

样本均值实例

- 考虑 $n = 15, p = 1/3$ 的两点分布随机向量 (二元向量):

$$\mathbf{X} = X_1, X_2, \dots, X_{15}.$$

其数学期望是多少? $\Rightarrow 1/3$ 。

样本均值实例

- 考虑 $n = 15, p = 1/3$ 的两点分布随机向量 (二元向量):

$$\mathbf{X} = X_1, X_2, \dots, X_{15}.$$

其数学期望是多少? $\Rightarrow 1/3$ 。

- 样本均值是什么? 执行多次随机测试, 结果如下:

0 1 0 0 0 0 0 0 0 1 0 0 1 0 1 \rightarrow ave = 0.266667

1 0 0 0 1 1 0 0 1 1 1 0 0 0 0 \rightarrow ave = 0.4

0 1 1 0 0 0 0 0 0 0 1 0 0 0 0 \rightarrow ave = 0.2

1 1 0 0 0 1 0 0 1 0 1 0 1 0 1 \rightarrow ave = 0.466667

0 0 0 0 0 1 0 0 0 1 1 0 0 1 0 \rightarrow ave = 0.266667

1 0 0 0 0 0 0 0 0 1 1 0 0 0 0 \rightarrow ave = 0.2

0 0 0 0 0 1 1 0 1 0 1 0 0 0 0 \rightarrow ave = 0.266667

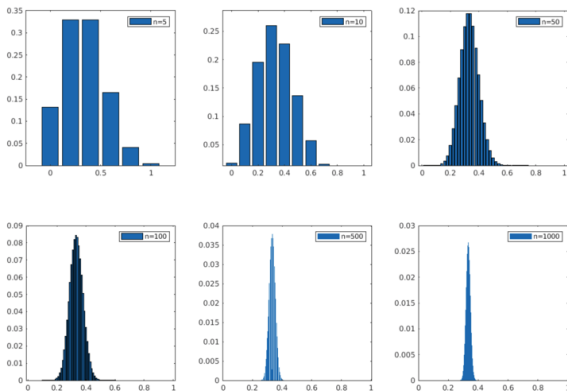
1 0 1 1 0 1 0 0 0 1 0 0 0 0 0 \rightarrow ave = 0.333333

0 0 0 1 1 1 0 0 0 1 0 0 0 0 0 \rightarrow ave = 0.266667

两点分布样本均值的概率分布

$$\Pr(\bar{X}_n = \frac{z}{n}) = \binom{n}{z} p^z (1-p)^{n-z}$$

$p = 1/3$ 时, 期望 $E[\bar{X}_n] = E[X] = 1/3$, 样本均值的概率分布函数:



$n \uparrow \Rightarrow \text{Var}[\bar{X}_n] \downarrow$ 且 $\lim_{n \rightarrow \infty} \text{Var}[\bar{X}_n] \rightarrow 0$

样本均值离数学期望有多近?

- 定义：考虑随机序列 \mathbf{X} ，若其样本均值 \bar{X}_n 满足

$$|\bar{X}_n - \mathbb{E}[X]| \leq \epsilon,$$

其中 ϵ 为常数，则称其样本均值 \bar{X}_n 与数学期望 $\mathbb{E}[X]$ “ ϵ 接近”。

样本均值离数学期望有多近?

- 定义：考虑随机序列 \mathbf{X} ，若其样本均值 \bar{X}_n 满足

$$|\bar{X}_n - \mathbb{E}[X]| \leq \epsilon,$$

其中 ϵ 为常数，则称其样本均值 \bar{X}_n 与数学期望 $\mathbb{E}[X]$ “ ϵ 接近”。

- 由于 \bar{X}_n 是随机变量，我们关心：

$$\Pr (|\bar{X}_n - \mathbb{E}[X]| \leq \epsilon)$$

样本均值离数学期望有多近？

- 定义：考虑随机序列 X ，若其样本均值 \bar{X}_n 满足

$$|\bar{X}_n - E[X]| \leq \epsilon,$$

其中 ϵ 为常数，则称其样本均值 \bar{X}_n 与数学期望 $E[X]$ “ ϵ 接近”。

- 由于 \bar{X}_n 是随机变量，我们关心：


$$\Pr (|\bar{X}_n - E[X]| \leq \epsilon)$$

- 直接计算这个概率非常困难，我们考虑其下界 q ：

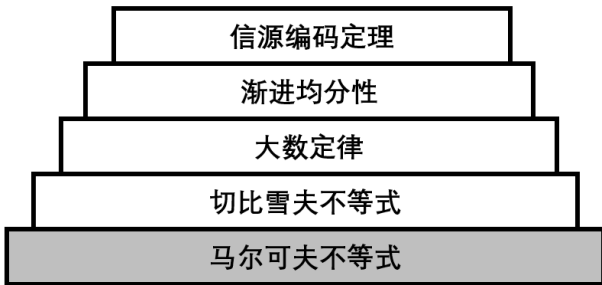
$$\Pr (|\bar{X}_n - E[X]| \leq \epsilon) \geq q$$

n 需要多大呢？

令 $p = \frac{1}{3}, \epsilon = 0.03$, 为使 $\Pr(|\bar{X}_n - \mu| \leq \epsilon) > 0.95$, n 需要多大呢？




“信息论是大数定律的巧妙应用”



马尔可夫不等式 (Markov Inequality)

马尔可夫不等式： X 是一个非负随机变量且 $a > 0$ ，则


$$\Pr(X \geq a) \leq \frac{\mu}{a}, \quad \mu = E[X]$$



马尔可夫不等式 (Markov Inequality)

马尔可夫不等式： X 是一个非负随机变量且 $a > 0$ ，则

$$\Pr(X \geq a) \leq \frac{\mu}{a}, \quad \mu = E[X]$$




简易证明： $\mu = E[X] = \sum_x p(x)x$

马尔可夫不等式 (Markov Inequality)

马尔可夫不等式： X 是一个非负随机变量且 $a > 0$ ，则

$$\Pr(X \geq a) \leq \frac{\mu}{a}, \quad \mu = E[X]$$




简易证明： $\mu = E[X] = \sum_x p(x)x \geq \sum_{x \geq a} p(x)x$

马尔可夫不等式 (Markov Inequality)

马尔可夫不等式： X 是一个非负随机变量且 $a > 0$ ，则

$$\Pr(X \geq a) \leq \frac{\mu}{a}, \quad \mu = E[X]$$




简易证明： $\mu = E[X] = \sum_x p(x)x \geq \sum_{x \geq a} p(x)x \geq \sum_{x \geq a} p(x)a$

马尔可夫不等式 (Markov Inequality)

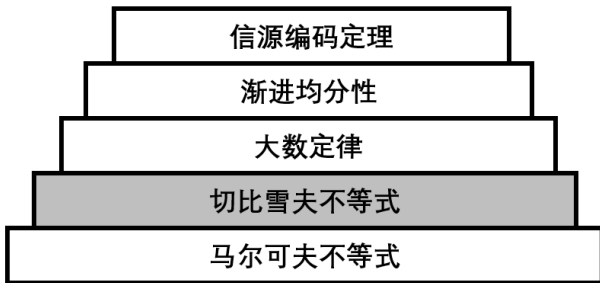
马尔可夫不等式： X 是一个非负随机变量且 $a > 0$ ，则

$$\Pr(X \geq a) \leq \frac{\mu}{a}, \quad \mu = E[X]$$



简易证明： $\mu = E[X] = \sum_x p(x)x \geq \sum_{x \geq a} p(x)x \geq \sum_{x \geq a} p(x)a = a\Pr(X \geq a)$

“信息论是大数定律的巧妙应用”



切比雪夫不等式 (Chebyshev Inequality)

切比雪夫不等式：考虑一个期望为 μ ，方差为 σ^2 的随机变量 X ，对任意 $\epsilon > 0$ ，则

$$\Pr (|X - \mu| \geq \epsilon) \leq \frac{\sigma^2}{\epsilon^2}.$$


切比雪夫不等式 (Chebyshev Inequality)

切比雪夫不等式：考虑一个期望为 μ ，方差为 σ^2 的随机变量 X ，对任意 $\epsilon > 0$ ，则

$$\Pr(|X - \mu| \geq \epsilon) \leq \frac{\sigma^2}{\epsilon^2}.$$

证明：将 $(X - \mu)^2$ 视为期望为 σ^2 的非负随机变量，由马尔可夫不等式可得

$$\Pr((X - \mu)^2 \geq \epsilon^2) \leq \frac{\sigma^2}{\epsilon^2}.$$




切比雪夫不等式 (Chebyshev Inequality)

切比雪夫不等式：考虑一个期望为 μ ，方差为 σ^2 的随机变量 X ，对任意 $\epsilon > 0$ ，则

$$\Pr(|X - \mu| \geq \epsilon) \leq \frac{\sigma^2}{\epsilon^2}.$$

证明：将 $(X - \mu)^2$ 视为期望为 σ^2 的非负随机变量，由马尔可夫不等式可得

$$\Pr((X - \mu)^2 \geq \epsilon^2) \leq \frac{\sigma^2}{\epsilon^2}.$$



● 也可以写成如下形式：

$$\Pr(|X - \mu| \leq \epsilon) \geq 1 - \frac{\sigma^2}{\epsilon^2},$$


切比雪夫不等式 (Chebyshev Inequality)

切比雪夫不等式：考虑一个期望为 μ ，方差为 σ^2 的随机变量 X ，对任意 $\epsilon > 0$ ，则

$$\Pr(|X - \mu| \geq \epsilon) \leq \frac{\sigma^2}{\epsilon^2}.$$

证明：将 $(X - \mu)^2$ 视为期望为 σ^2 的非负随机变量，由马尔可夫不等式可得

$$\Pr((X - \mu)^2 \geq \epsilon^2) \leq \frac{\sigma^2}{\epsilon^2}.$$

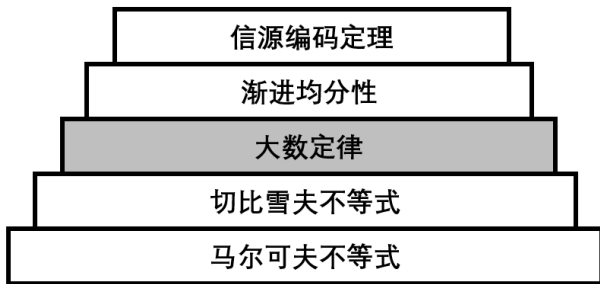


● 也可以写成如下形式：

$$\Pr(|X - \mu| \leq \epsilon) \geq 1 - \frac{\sigma^2}{\epsilon^2},$$

当 $\frac{\sigma^2}{\epsilon^2} \rightarrow 0$ 时， $\Pr(|X - \mu| \leq \epsilon) \rightarrow 1$.

“信息论是大数定律的巧妙应用”



大数定律 (Law of Large Numbers)

X_1, X_2, \dots, X_n 为 n 个独立同分布随机变量, 且 $\text{Var}[X_i] = \sigma^2$.

弱大数定律: 样本均值依概率收敛于数学期望, 即对 $\forall \epsilon > 0$,

$$\lim_{n \rightarrow \infty} \Pr(|\bar{X}_n - E[X]| \leq \epsilon) = 1.$$

大数定律 (Law of Large Numbers)

X_1, X_2, \dots, X_n 为 n 个独立同分布随机变量, 且 $\text{Var}[X_i] = \sigma^2$.

弱大数定律: 样本均值依概率收敛于数学期望, 即对 $\forall \epsilon > 0$,

$$\lim_{n \rightarrow \infty} \Pr(|\bar{X}_n - E[X]| \leq \epsilon) = 1.$$

证明: $E[\bar{X}_n] = E[X]$, $\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n} \xrightarrow{n \rightarrow \infty} 0$, 由切比雪夫不等式,

大数定律 (Law of Large Numbers)

X_1, X_2, \dots, X_n 为 n 个独立同分布随机变量, 且 $\text{Var}[X_i] = \sigma^2$.

弱大数定律: 样本均值依概率收敛于数学期望, 即对 $\forall \epsilon > 0$,

$$\lim_{n \rightarrow \infty} \Pr(|\bar{X}_n - E[X]| \leq \epsilon) = 1.$$

证明: $E[\bar{X}_n] = E[X]$, $\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n} \xrightarrow{n \rightarrow \infty} 0$, 由切比雪夫不等式,

$$\Pr(|\bar{X}_n - E[X]| \leq \epsilon) \geq 1 - \frac{\text{Var}(\bar{X}_n)}{\epsilon^2}$$

大数定律 (Law of Large Numbers)

X_1, X_2, \dots, X_n 为 n 个独立同分布随机变量, 且 $\text{Var}[X_i] = \sigma^2$.

弱大数定律: 样本均值依概率收敛于数学期望, 即对 $\forall \epsilon > 0$,

$$\lim_{n \rightarrow \infty} \Pr(|\bar{X}_n - E[X]| \leq \epsilon) = 1.$$

证明: $E[\bar{X}_n] = E[X]$, $\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n} \xrightarrow{n \rightarrow \infty} 0$, 由切比雪夫不等式,

$$\Pr(|\bar{X}_n - E[X]| \leq \epsilon) \geq 1 - \frac{\text{Var}(\bar{X}_n)}{\epsilon^2} = 1 - \frac{\sigma^2}{n\epsilon^2}$$

大数定律 (Law of Large Numbers)

X_1, X_2, \dots, X_n 为 n 个独立同分布随机变量, 且 $\text{Var}[X_i] = \sigma^2$.

弱大数定律: 样本均值依概率收敛于数学期望, 即对 $\forall \epsilon > 0$,

$$\lim_{n \rightarrow \infty} \Pr(|\bar{X}_n - E[X]| \leq \epsilon) = 1.$$

证明: $E[\bar{X}_n] = E[X]$, $\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n} \xrightarrow{n \rightarrow \infty} 0$, 由切比雪夫不等式,

$$\Pr(|\bar{X}_n - E[X]| \leq \epsilon) \geq 1 - \frac{\text{Var}(\bar{X}_n)}{\epsilon^2} = 1 - \frac{\sigma^2}{n\epsilon^2} \xrightarrow{n \rightarrow \infty} 1.$$

向量信源编码定理

- ① 向量信源编码
- ② 大数定律
- ③ 样本熵和典型集
- ④ 渐近均分性 (AEP)
- ⑤ 向量信源编码定理的证明

注：典型集和渐近均分性是信息论的基础

样本熵 (Sample Entropy)

定义：联合概率分布函数为 P_X 的随机序列 \mathbf{X} ，其样本熵为

$$\bar{H}(\mathbf{X}) = -\frac{1}{n} \log p_X$$

样本熵 (Sample Entropy)

定义：联合概率分布函数为 P_X 的随机序列 \mathbf{X} ，其样本熵为

$$\bar{H}(\mathbf{X}) = -\frac{1}{n} \log p_X$$

当 X_1, X_2, \dots, X_n 独立同分布，

$$\bar{H}(\mathbf{X}) = -\frac{1}{n} \sum_{i=1}^n \log p_{X_i}$$

样本熵 (Sample Entropy)

定义：联合概率分布函数为 P_X 的随机序列 \mathbf{X} ，其样本熵为

$$\bar{H}(\mathbf{X}) = -\frac{1}{n} \log p_X$$

当 X_1, X_2, \dots, X_n 独立同分布，

$$\bar{H}(\mathbf{X}) = -\frac{1}{n} \sum_{i=1}^n \log p_{X_i}$$


注意：与样本均值和数学期望类似：

- 样本熵是一个随机变量
- 真实熵是一个常数

样本熵实例

- 考虑独立同分布的二元随机序列 $\mathbf{X} = X_1, X_2, X_3, X_4$, 且 $p_0 = \frac{3}{4}, p_1 = \frac{1}{4}$ 。
- 样本熵的分布 (样本总数为 $2^4 = 16$)

x_1, x_2, x_3, x_4	sample entropy	
	$p_{\mathbf{X}}(\mathbf{x})$	$-\frac{1}{n} \log p_{\mathbf{X}}(\mathbf{x})$
0 0 0 0	0.31641	0.41504
1 0 0 0	0.10547	0.81128
0 1 0 0	0.10547	0.81128
0 0 1 0	0.10547	0.81128
0 0 0 1	0.10547	0.81128
1 1 0 0	0.03516	1.20752
1 0 1 0	0.03516	1.20752
0 1 1 0	0.03516	1.20752
1 0 0 1	0.03516	1.20752
0 1 0 1	0.03516	1.20752
0 0 1 1	0.03516	1.20752



典型集 (Typical Set)

定义：令 ϵ 为任意正数，则典型集 $\mathcal{T}_\epsilon^{(n)}$ 是所有样本熵与真实熵 “ ϵ 接近” 的离散无记忆随机序列 $\mathbf{X} \in \mathcal{X}^n$ 的集合，即

$$\mathcal{T}_\epsilon^{(n)} = \{\mathbf{X} \in \mathcal{X}^n : |\bar{H}(\mathbf{X}) - H(X)| < \epsilon\}$$

典型集 (Typical Set)

定义：令 ϵ 为任意正数，则典型集 $\mathcal{T}_\epsilon^{(n)}$ 是所有样本熵与真实熵 “ ϵ 接近” 的离散无记忆随机序列 $\mathbf{X} \in \mathcal{X}^n$ 的集合，即

$$\mathcal{T}_\epsilon^{(n)} = \{\mathbf{X} \in \mathcal{X}^n : |\bar{H}(\mathbf{X}) - H(X)| < \epsilon\}$$

- 典型集的元素个数表示为 $|\mathcal{T}_\epsilon^{(n)}|$;
- 信源集合 \mathcal{X}^n 可以分为典型集 $\mathcal{T}_\epsilon^{(n)}$ 及其补集 $\bar{\mathcal{T}}_\epsilon^{(n)}$ ，即

$$\mathcal{X}^n = \mathcal{T}_\epsilon^{(n)} \cup \bar{\mathcal{T}}_\epsilon^{(n)}$$


典型集实例

- 考虑独立同分布的二元随机序列 $\mathbf{X} = X_1, X_2, X_3, X_4$, 且 $p_0 = \frac{3}{4}, p_1 = \frac{1}{4}$ 。
当 $\epsilon = 0.01$ 或 $\epsilon = 0.45$ 时, 找出典型集及其元素个数。

典型集实例

- 考虑独立同分布的二元随机序列 $\mathbf{X} = X_1, X_2, X_3, X_4$, 且 $p_0 = \frac{3}{4}, p_1 = \frac{1}{4}$ 。
当 $\epsilon = 0.01$ 或 $\epsilon = 0.45$ 时, 找出典型集及其元素个数。
- 样本熵的分布 (可能存在的样本总数为 $2^4 = 16$)

x_1, x_2, x_3, x_4	sample entropy	
	$p_{\mathbf{X}}(\mathbf{x})$	$-\frac{1}{n} \log p_{\mathbf{X}}(\mathbf{x})$
0 0 0 0	0.31641	0.41504
1 0 0 0	0.10547	0.81128
0 1 0 0	0.10547	0.81128
0 0 1 0	0.10547	0.81128
0 0 0 1	0.10547	0.81128
1 1 0 0	0.03516	1.20752
1 0 1 0	0.03516	1.20752
0 1 1 0	0.03516	1.20752
1 0 0 1	0.03516	1.20752
0 1 0 1	0.03516	1.20752
0 0 1 1	0.03516	1.20752

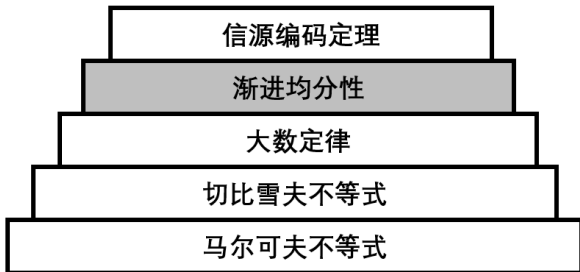


向量信源编码定理

- ① 向量信源编码
- ② 大数定律
- ③ 样本熵和典型集
- ④ 渐近均分性 (AEP)
- ⑤ 向量信源编码定理的证明

注：典型集和渐近均分性是信息论的基础

“信息论是大数定律的巧妙应用”



渐近均分性 (Asymptotic Equipartition Property, AEP)

主要性质:

当 $n \rightarrow \infty$ 且 $\epsilon \rightarrow 0$ 时:

① 近似等概: 若 $x \in \mathcal{T}_\epsilon^{(n)}$, 则 $p_x \rightarrow 2^{-nH(X)}$, 典型序列近似等概

渐近均分性 (Asymptotic Equipartition Property, AEP)

主要性质:

当 $n \rightarrow \infty$ 且 $\epsilon \rightarrow 0$ 时:

- ① 近似等概: 若 $x \in \mathcal{T}_\epsilon^{(n)}$, 则 $p_x \rightarrow 2^{-nH(X)}$, 典型序列近似等概
- ② 高概率: $\Pr(X \in \mathcal{T}_\epsilon^{(n)}) \rightarrow 1$, 典型集的概率很高

渐近均分性 (Asymptotic Equipartition Property, AEP)

主要性质:

当 $n \rightarrow \infty$ 且 $\epsilon \rightarrow 0$ 时:

- ① 近似等概: 若 $x \in \mathcal{T}_\epsilon^{(n)}$, 则 $p_x \rightarrow 2^{-nH(X)}$, 典型序列近似等概
- ② 高概率: $\Pr(X \in \mathcal{T}_\epsilon^{(n)}) \rightarrow 1$, 典型集的概率很高
- ③ 个数少: $|\mathcal{T}_\epsilon^{(n)}| \rightarrow 2^{nH(X)}$, 典型集元素个数很少, $|\mathcal{T}_\epsilon^{(n)}| \ll |\mathcal{X}^n|$

渐近均分性 (Asymptotic Equipartition Property, AEP)

主要性质:

当 $n \rightarrow \infty$ 且 $\epsilon \rightarrow 0$ 时:

- ① 近似等概: 若 $\mathbf{x} \in \mathcal{T}_\epsilon^{(n)}$, 则 $p_{\mathbf{x}} \rightarrow 2^{-nH(X)}$, 典型序列近似等概
- ② 高概率: $\Pr(\mathbf{X} \in \mathcal{T}_\epsilon^{(n)}) \rightarrow 1$, 典型集的概率很高
- ③ 个数少: $|\mathcal{T}_\epsilon^{(n)}| \rightarrow 2^{nH(X)}$, 典型集元素个数很少, $|\mathcal{T}_\epsilon^{(n)}| \ll |\mathcal{X}^n|$

注: 性质 1 (近似等概性) 直接由样本熵和典型集定义可得

$$\bar{H}(\mathbf{X}) = -\frac{1}{n} \log p_{\mathbf{X}} \xrightarrow[n \rightarrow \infty]{\epsilon \rightarrow 0} H(X).$$

性质 2 (高概率): 随机序列样本大概率是典型的

命题: 独立同分布的二元随机序列 $\mathbf{X} = X_1, X_2, \dots, X_n$, 其概率分布为 $p(x)$, 则 $\forall \epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} \Pr(\mathbf{X} \in \mathcal{T}_\epsilon^{(n)}) = 1$$

性质 2 (高概率): 随机序列样本大概率是典型的

命题: 独立同分布的二元随机序列 $\mathbf{X} = X_1, X_2, \dots, X_n$, 其概率分布为 $p(x)$, 则 $\forall \epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} \Pr(\mathbf{X} \in \mathcal{T}_\epsilon^{(n)}) = 1$$

证明: 对独立同分布 (IID) 的序列 $\{X_i\}$,

IID 随机变量: $Y_i \equiv \bar{H}(X_i) = -\log P_{X_i}, \forall i$

性质 2 (高概率): 随机序列样本大概率是典型的

命题: 独立同分布的二元随机序列 $\mathbf{X} = X_1, X_2, \dots, X_n$, 其概率分布为 $p(x)$, 则 $\forall \epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} \Pr(\mathbf{X} \in \mathcal{T}_\epsilon^{(n)}) = 1$$

证明: 对独立同分布 (IID) 的序列 $\{X_i\}$,

IID 随机变量: $Y_i \equiv \bar{H}(X_i) = -\log P_{X_i}, \forall i$

$$\Rightarrow \bar{Y}_n \equiv \frac{1}{n} \sum_{i=1}^n Y_i = \bar{H}(\mathbf{X})$$

性质 2 (高概率): 随机序列样本大概率是典型的

命题: 独立同分布的二元随机序列 $\mathbf{X} = X_1, X_2, \dots, X_n$, 其概率分布为 $p(x)$, 则 $\forall \epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} \Pr(\mathbf{X} \in \mathcal{T}_\epsilon^{(n)}) = 1$$

证明: 对独立同分布 (IID) 的序列 $\{X_i\}$,

IID 随机变量: $Y_i \equiv \bar{H}(X_i) = -\log P_{X_i}, \forall i$

$$\Rightarrow \bar{Y}_n \equiv \frac{1}{n} \sum_{i=1}^n Y_i = \bar{H}(\mathbf{X})$$

$$\Rightarrow \mathbb{E}[Y_i] = \mathbb{E}[Y] = H(X)$$

性质 2 (高概率): 随机序列样本大概率是典型的

命题: 独立同分布的二元随机序列 $\mathbf{X} = X_1, X_2, \dots, X_n$, 其概率分布为 $p(x)$, 则 $\forall \epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} \Pr(\mathbf{X} \in \mathcal{T}_\epsilon^{(n)}) = 1$$

证明: 对独立同分布 (IID) 的序列 $\{X_i\}$,

IID 随机变量: $Y_i \equiv \bar{H}(X_i) = -\log P_{X_i}, \forall i$

$$\Rightarrow \bar{Y}_n \equiv \frac{1}{n} \sum_{i=1}^n Y_i = \bar{H}(\mathbf{X})$$

$$\Rightarrow \mathbb{E}[Y_i] = \mathbb{E}[Y] = H(X)$$

由大数定律: $\lim_{n \rightarrow \infty} \Pr(|\bar{Y}_n - \mathbb{E}[Y]| \leq \epsilon) = 1$, 即:

性质 2 (高概率): 随机序列样本大概率是典型的

命题: 独立同分布的二元随机序列 $\mathbf{X} = X_1, X_2, \dots, X_n$, 其概率分布为 $p(x)$, 则 $\forall \epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} \Pr(\mathbf{X} \in \mathcal{T}_\epsilon^{(n)}) = 1$$

证明: 对独立同分布 (IID) 的序列 $\{X_i\}$,

IID 随机变量: $Y_i \equiv \bar{H}(X_i) = -\log P_{X_i}, \forall i$

$$\Rightarrow \bar{Y}_n \equiv \frac{1}{n} \sum_{i=1}^n Y_i = \bar{H}(\mathbf{X})$$

$$\Rightarrow \mathbb{E}[Y_i] = \mathbb{E}[Y] = H(X)$$

由大数定律: $\lim_{n \rightarrow \infty} \Pr(|\bar{Y}_n - \mathbb{E}[Y]| \leq \epsilon) = 1$, 即:

$$\lim_{n \rightarrow \infty} \Pr(|\bar{H}(\mathbf{X}) - H(X)| < \epsilon) = 1$$

性质 2 (高概率): 随机序列样本大概率是典型的

命题: 独立同分布的二元随机序列 $\mathbf{X} = X_1, X_2, \dots, X_n$, 其概率分布为 $p(x)$, 则 $\forall \epsilon > 0$, 有

$$\lim_{n \rightarrow \infty} \Pr(\mathbf{X} \in \mathcal{T}_\epsilon^{(n)}) = 1$$

证明: 对独立同分布 (IID) 的序列 $\{X_i\}$,

IID 随机变量: $Y_i \equiv \bar{H}(X_i) = -\log P_{X_i}, \forall i$

$$\Rightarrow \bar{Y}_n \equiv \frac{1}{n} \sum_{i=1}^n Y_i = \bar{H}(\mathbf{X})$$

$$\Rightarrow \mathbb{E}[Y_i] = \mathbb{E}[Y] = H(X)$$

由大数定律: $\lim_{n \rightarrow \infty} \Pr(|\bar{Y}_n - \mathbb{E}[Y]| \leq \epsilon) = 1$, 即:

$$\lim_{n \rightarrow \infty} \Pr(|\bar{H}(\mathbf{X}) - H(X)| < \epsilon) = 1 \quad \Rightarrow \quad \lim_{n \rightarrow \infty} \Pr(\mathbf{X} \in \mathcal{T}_\epsilon^{(n)}) = 1$$

性质 3 (个数少): 典型集元素个数很少

命题: 当 n 足够大时, 典型集 $\mathcal{T}_\epsilon^{(n)}$ 的元素个数接近 $2^{nH(X)}$, 即:

$$|\mathcal{T}_\epsilon^{(n)}| \rightarrow 2^{nH(X)}$$

性质 3 (个数少): 典型集元素个数很少

命题: 当 n 足够大时, 典型集 $\mathcal{T}_\epsilon^{(n)}$ 的元素个数接近 $2^{nH(X)}$, 即:

$$|\mathcal{T}_\epsilon^{(n)}| \rightarrow 2^{nH(X)}$$

证明: 当 $n \rightarrow \infty$ 时,

$$1 = \sum_x p(x)$$

性质 3 (个数少): 典型集元素个数很少

命题: 当 n 足够大时, 典型集 $\mathcal{T}_\epsilon^{(n)}$ 的元素个数接近 $2^{nH(X)}$, 即:

$$|\mathcal{T}_\epsilon^{(n)}| \rightarrow 2^{nH(X)}$$

证明: 当 $n \rightarrow \infty$ 时,

$$1 = \sum_{\mathbf{x}} p(\mathbf{x}) \rightarrow \sum_{\mathbf{x} \in \mathcal{T}_\epsilon^{(n)}} p(\mathbf{x})$$

性质 3 (个数少): 典型集元素个数很少

命题: 当 n 足够大时, 典型集 $\mathcal{T}_\epsilon^{(n)}$ 的元素个数接近 $2^{nH(X)}$, 即:

$$|\mathcal{T}_\epsilon^{(n)}| \rightarrow 2^{nH(X)}$$

证明: 当 $n \rightarrow \infty$ 时,

$$1 = \sum_{\mathbf{x}} p(\mathbf{x}) \rightarrow \sum_{\mathbf{x} \in \mathcal{T}_\epsilon^{(n)}} p(\mathbf{x}) \rightarrow |\mathcal{T}_\epsilon^{(n)}| 2^{-nH(X)}$$

性质 3 (个数少): 典型集元素个数很少

命题: 当 n 足够大时, 典型集 $\mathcal{T}_\epsilon^{(n)}$ 的元素个数接近 $2^{nH(X)}$, 即:

$$|\mathcal{T}_\epsilon^{(n)}| \rightarrow 2^{nH(X)}$$

证明: 当 $n \rightarrow \infty$ 时,

$$1 = \sum_{\mathbf{x}} p(\mathbf{x}) \rightarrow \sum_{\mathbf{x} \in \mathcal{T}_\epsilon^{(n)}} p(\mathbf{x}) \rightarrow |\mathcal{T}_\epsilon^{(n)}| 2^{-nH(X)}$$

即, $|\mathcal{T}_\epsilon^{(n)}| \rightarrow 2^{nH(X)}$

性质 3 (个数少): 典型集元素个数很少

命题: 当 n 足够大时, 典型集 $\mathcal{T}_\epsilon^{(n)}$ 的元素个数接近 $2^{nH(X)}$, 即:

$$|\mathcal{T}_\epsilon^{(n)}| \rightarrow 2^{nH(X)}$$

证明: 当 $n \rightarrow \infty$ 时,

$$1 = \sum_{\mathbf{x}} p(\mathbf{x}) \rightarrow \sum_{\mathbf{x} \in \mathcal{T}_\epsilon^{(n)}} p(\mathbf{x}) \rightarrow |\mathcal{T}_\epsilon^{(n)}| 2^{-nH(X)}$$

即, $|\mathcal{T}_\epsilon^{(n)}| \rightarrow 2^{nH(X)}$

- 当 X 不是均匀分布时, 典型集占比趋于 0:

性质 3 (个数少): 典型集元素个数很少

命题: 当 n 足够大时, 典型集 $\mathcal{T}_\epsilon^{(n)}$ 的元素个数接近 $2^{nH(X)}$, 即:

$$|\mathcal{T}_\epsilon^{(n)}| \rightarrow 2^{nH(X)}$$

证明: 当 $n \rightarrow \infty$ 时,

$$1 = \sum_{\mathbf{x}} p(\mathbf{x}) \rightarrow \sum_{\mathbf{x} \in \mathcal{T}_\epsilon^{(n)}} p(\mathbf{x}) \rightarrow |\mathcal{T}_\epsilon^{(n)}| 2^{-nH(X)}$$

即, $|\mathcal{T}_\epsilon^{(n)}| \rightarrow 2^{nH(X)}$

- 当 X 不是均匀分布时, 典型集占比趋于 0:

$$\frac{2^{nH(X)}}{2^{n \log |\mathcal{X}|}} = 2^{n(H(X) - \log |\mathcal{X}|)}$$

性质 3 (个数少): 典型集元素个数很少

命题: 当 n 足够大时, 典型集 $\mathcal{T}_\epsilon^{(n)}$ 的元素个数接近 $2^{nH(X)}$, 即:

$$|\mathcal{T}_\epsilon^{(n)}| \rightarrow 2^{nH(X)}$$

证明: 当 $n \rightarrow \infty$ 时,

$$1 = \sum_{\mathbf{x}} p(\mathbf{x}) \rightarrow \sum_{\mathbf{x} \in \mathcal{T}_\epsilon^{(n)}} p(\mathbf{x}) \rightarrow |\mathcal{T}_\epsilon^{(n)}| 2^{-nH(X)}$$

即, $|\mathcal{T}_\epsilon^{(n)}| \rightarrow 2^{nH(X)}$

- 当 X 不是均匀分布时, 典型集占比趋于 0:





$$\frac{2^{nH(X)}}{2^{n \log |\mathcal{X}|}} = 2^{n(H(X) - \log |\mathcal{X}|)} \xrightarrow[n \rightarrow \infty]{H(X) < \log |\mathcal{X}|} 0$$

AEP 实例



- 考虑独立同分布二元随机变量 $\mathbf{X} = X_1, X_2, \dots, X_n$, 且 $p_0 = \frac{3}{4}, p_1 = \frac{1}{4}$ 。
当 $\epsilon = 0.1$ 且 $n = 8, 16, 32, 256$ 时, 找出典型集及其概率。

AEP 实例

- 考虑独立同分布二元随机变量 $\mathbf{X} = X_1, X_2, \dots, X_n$, 且 $p_0 = \frac{3}{4}, p_1 = \frac{1}{4}$.
当 $\epsilon = 0.1$ 且 $n = 8, 16, 32, 256$ 时, 找出典型集及其概率。



渐近均分性



渐近均分性：一小部分近似等概的序列占了绝大部分可能性。

向量信源编码定理

- ① 向量信源编码
- ② 大数定律
- ③ 样本熵和典型集
- ④ 渐近均分性 (AEP)
- ⑤ 向量信源编码定理的证明

注：典型集和渐近均分性是信息论的基础

信源编码定理及其证明

定理 (向量信源编码定理): 令 $\mathbf{X} = (X_1, X_2, \dots, X_n)$ 为 n 维独立同分布随机序列, 其中 $X_i \sim p(x)$, 其信息熵为 $H(X)$ 。则, 对任意 $\epsilon > 0$, 当 n 足够大时, 存在一种码率为 R 的向量编码满足:

$$R \leq H(X) + \epsilon.$$

“存在一种向量编码”: 接下来给出一个编码策略

基于典型集的向量编码

令 $\mathbf{x} = x_1, x_2, \dots, x_n$:

- 如果 $\mathbf{x} \in \mathcal{T}_\epsilon^{(n)}$, 将 $\mathcal{T}_\epsilon^{(n)}$ 中各个元素与如下集合对应:

$$\{1, 2, 3, \dots, |\mathcal{T}_\epsilon^{(n)}|\}$$

码字为 $C(\mathbf{x}) = \text{“0”} + \text{“对应索引”}$

基于典型集的向量编码

令 $\mathbf{x} = x_1, x_2, \dots, x_n$:

- 如果 $\mathbf{x} \in \mathcal{T}_\epsilon^{(n)}$, 将 $\mathcal{T}_\epsilon^{(n)}$ 中各个元素与如下集合对应:

$$\{1, 2, 3, \dots, |\mathcal{T}_\epsilon^{(n)}|\}$$

码字为 $C(\mathbf{x}) = \text{“0”} + \text{“对应索引”}$

- 如果 $\mathbf{x} \in \bar{\mathcal{T}}_\epsilon^{(n)}$, 则不压缩。码字为 $C(\mathbf{x}) = \text{“1”} + \text{“}\mathbf{x}\text{ 本身”}$

基于典型集的向量编码

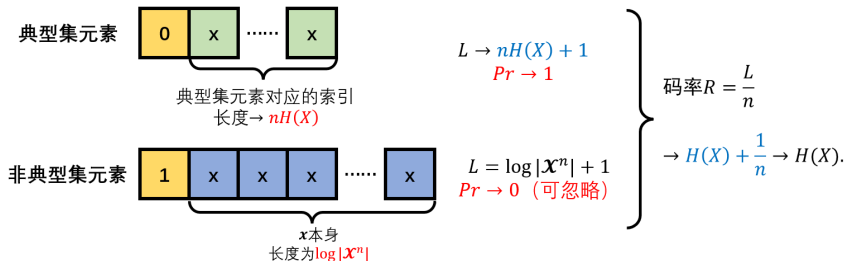
令 $\mathbf{x} = x_1, x_2, \dots, x_n$:

- 如果 $\mathbf{x} \in \mathcal{T}_\epsilon^{(n)}$, 将 $\mathcal{T}_\epsilon^{(n)}$ 中各个元素与如下集合对应:

$$\{1, 2, 3, \dots, |\mathcal{T}_\epsilon^{(n)}|\}$$

码字为 $C(\mathbf{x}) = \text{“0”} + \text{“对应索引”}$

- 如果 $\mathbf{x} \in \bar{\mathcal{T}}_\epsilon^{(n)}$, 则不压缩。码字为 $C(\mathbf{x}) = \text{“1”} + \text{“}\mathbf{x}\text{ 本身”}$



基于典型集的向量编码

码率计算:

$$\Pr(\mathbf{X} \in \bar{\mathcal{T}}_{\epsilon}^{(n)}) \rightarrow 0 \Rightarrow R_{\mathbf{x} \in \bar{\mathcal{T}}_{\epsilon}^{(n)}} \rightarrow 0$$

因此,

$$R = R_{\mathbf{x} \in \mathcal{T}_{\epsilon}^{(n)}} + R_{\mathbf{x} \in \bar{\mathcal{T}}_{\epsilon}^{(n)}}$$

基于典型集的向量编码

码率计算:

$$\Pr(\mathbf{X} \in \bar{\mathcal{T}}_{\epsilon}^{(n)}) \rightarrow 0 \Rightarrow R_{x \in \bar{\mathcal{T}}_{\epsilon}^{(n)}} \rightarrow 0$$

因此,

$$\begin{aligned} R &= R_{x \in \mathcal{T}_{\epsilon}^{(n)}} + R_{x \in \bar{\mathcal{T}}_{\epsilon}^{(n)}} \\ &\rightarrow R_{x \in \mathcal{T}_{\epsilon}^{(n)}} \quad \quad \quad " = R_{x \in \mathcal{T}_{\epsilon}^{(n)}} + \epsilon' " \end{aligned}$$

基于典型集的向量编码

码率计算:

$$\Pr(\mathbf{X} \in \bar{\mathcal{T}}_\epsilon^{(n)}) \rightarrow 0 \Rightarrow R_{\mathbf{x} \in \bar{\mathcal{T}}_\epsilon^{(n)}} \rightarrow 0$$

因此,

$$\begin{aligned} R &= R_{\mathbf{x} \in \mathcal{T}_\epsilon^{(n)}} + R_{\mathbf{x} \in \bar{\mathcal{T}}_\epsilon^{(n)}} \\ &\rightarrow R_{\mathbf{x} \in \mathcal{T}_\epsilon^{(n)}} && \text{“} = R_{\mathbf{x} \in \mathcal{T}_\epsilon^{(n)}} + \epsilon' \text{”} \\ &= \frac{\log |\mathcal{T}_\epsilon^{(n)}| + 1}{n} \end{aligned}$$

基于典型集的向量编码

码率计算:

$$\Pr(\mathbf{X} \in \bar{\mathcal{T}}_\epsilon^{(n)}) \rightarrow 0 \Rightarrow R_{\mathbf{x} \in \bar{\mathcal{T}}_\epsilon^{(n)}} \rightarrow 0$$

因此,

$$\begin{aligned} R &= R_{\mathbf{x} \in \mathcal{T}_\epsilon^{(n)}} + R_{\mathbf{x} \in \bar{\mathcal{T}}_\epsilon^{(n)}} \\ &\rightarrow R_{\mathbf{x} \in \mathcal{T}_\epsilon^{(n)}} && \text{"} = R_{\mathbf{x} \in \mathcal{T}_\epsilon^{(n)}} + \epsilon' \text{"} \\ &= \frac{\log |\mathcal{T}_\epsilon^{(n)}| + 1}{n} \\ &\leq H(X) + \epsilon. && \text{"}\epsilon = \epsilon' + \frac{1}{n}\text{"} \end{aligned}$$

总结

- 向量信源编码优于单信源编码
- 单信源编码最差可达码率为 $H(X) + 1$
- 向量信源编码最差可达码率为 $H(X) + \epsilon$ (当 $n \rightarrow \infty$ 时 $\epsilon \rightarrow 0$)
- 信息论的核心思路：大系统 ($n \rightarrow \infty$) 下进行证明
- 典型集和渐近均分性给出了信源编码定理的简易证明

作业

- 复习授课内容
- 预习马尔可夫链和熵率
- 独立完成习题

令 $\mathbf{X} = X_1, \dots, X_n$ 为 IID 随机变量, 其分布为 $p_{\mathbf{X}}(x_1, \dots, x_n)$, 计算:

$$\lim_{n \rightarrow \infty} (p_{\mathbf{X}}(x_1, \dots, x_n))^{1/n}$$