

矩阵论

2024年秋季学期

第二讲

2024年9月11日

- 1) 第一讲复习
- 2) 矩阵代数基础

矩阵代数基础

矩阵的基本运算

包括矩阵的转置、共轭、共轭转置、加法和乘法。

共轭转置 (Hermitian转置/ Hermitian伴随/ Hermitian共轭)

$$\mathbf{A}^H = \begin{bmatrix} a_{11}^* & a_{21}^* & \cdots & a_{m1}^* \\ a_{12}^* & a_{22}^* & \cdots & a_{m2}^* \\ \vdots & \vdots & \ddots & \vdots \\ a_{1n}^* & a_{2n}^* & \cdots & a_{mn}^* \end{bmatrix}$$

$$\mathbf{A}^H = (\mathbf{A}^*)^T = (\mathbf{A}^T)^*$$

加法

$$[\mathbf{A} + \mathbf{B}]_{ij} = a_{ij} + b_{ij}$$

乘法

$$[\alpha \mathbf{A}]_{ij} = \alpha a_{ij} \quad [\mathbf{A}\mathbf{x}]_i = \sum_{j=1}^n a_{ij}x_j, \quad i = 1, \cdots, m$$

$$[\mathbf{A}\mathbf{B}]_{ij} = \sum_{k=1}^n a_{ik}b_{kj}, \quad i = 1, \cdots, m; \quad j = 1, \cdots, s$$

矩阵代数基础

运算法则

加法

$$A + B = B + A$$

$$(A + B) + C = A + (B + C)$$

乘法

$$A(BC) = (AB)C$$

$$(A + B)C = AC + BC$$

$$A(B + C) = AB + AC$$

$$\alpha(A + B) = \alpha A + \alpha B$$

共轭、转置、共轭转置和逆矩阵性质

$$(A + B)^* = A^* + B^*, \quad (A + B)^T = A^T + B^T, \quad (A + B)^H = A^H + B^H$$

$$(AB)^T = B^T A^T, \quad (AB)^H = B^H A^H$$

$$(AB)^{-1} = B^{-1} A^{-1} \quad (A, B \text{ 为可逆的方阵})$$

$$(A^*)^{-1} = (A^{-1})^*, \quad (A^T)^{-1} = (A^{-1})^T, \quad (A^H)^{-1} = (A^{-1})^H$$

对于任意矩阵 A , 矩阵 $B = A^H A$ 都是 Hermitian 矩阵

矩阵代数基础

运算法则

导数

$$\frac{dA}{dt} = \dot{A} = \begin{bmatrix} \frac{da_{11}}{dt} & \frac{da_{12}}{dt} & \cdots & \frac{da_{1n}}{dt} \\ \frac{da_{21}}{dt} & \frac{da_{22}}{dt} & \cdots & \frac{da_{2n}}{dt} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{da_{m1}}{dt} & \frac{da_{m2}}{dt} & \cdots & \frac{da_{mn}}{dt} \end{bmatrix}$$

$$\frac{d e^{At}}{dt} = A e^{At}$$

Eq. (1.1.21)

矩阵函数: Eq.
1.1.17~22

$$\frac{d}{dt}(AB) = \frac{dA}{dt}B + A\frac{dB}{dt}$$

积分

$$\int A dt = \begin{bmatrix} \int a_{11} dt & \int a_{12} dt & \cdots & \int a_{1n} dt \\ \int a_{21} dt & \int a_{22} dt & \cdots & \int a_{2n} dt \\ \vdots & \vdots & \ddots & \vdots \\ \int a_{m1} dt & \int a_{m2} dt & \cdots & \int a_{mn} dt \end{bmatrix}$$

矩阵的基本运算

工程和科学计算中常见的方程组

$$\left. \begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &= b_2 \\ &\vdots \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n &= b_m \end{aligned} \right\}$$

$$Ax = b \quad A = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} \quad x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}, \quad b = \begin{bmatrix} b_1 \\ \vdots \\ b_m \end{bmatrix}$$

矩阵代数基础

向量的线性无关与非奇异性

线性方程组

$$c_1 \mathbf{u}_1 + \cdots + c_n \mathbf{u}_n = \mathbf{0}$$

向量组**线性无关**：只有零解

向量组**线性相关**：有非零解

$n \times n$ 矩阵方程组

$$U\mathbf{c} = \mathbf{0}$$

只有零解： \mathbf{c} 是非奇异的

存在非零解： \mathbf{c} 是奇异的

矩阵的初等变换

初等行变换

- (1) 互换矩阵的任意两行, 如 $r_p \leftrightarrow r_q$, 称为 I 型初等行变换。
- (2) 一行元素同乘一个非零常数 α , 如 $\alpha r_p \rightarrow r_p$, 称为 II 型初等行变换。
- (3) 将第 p 行元素同乘一个非零常数 β 后, 加给第 q 行, 即 $\beta r_p + r_q \rightarrow r_q$, 称为 III 型初等行变换。

经过初等行变换得到的矩阵等价于原矩阵, 行等价矩阵

应用I: 方程组求解

$$Ax = b \xrightarrow{\text{初等行变换}} x = A^{-1}b \quad \text{高斯消去法}$$

$$[A, b] \xrightarrow{\text{初等行变换}} [I, A^{-1}b] \quad \text{初等列变换?}$$

矩阵的初等变换

初等行变换

应用II: 矩阵求逆

$$\begin{array}{lcl} AX = I & \xrightarrow{\text{初等行变换}} & X = A^{-1} \\ [A, I] & \xrightarrow{\text{初等行变换}} & [I, A^{-1}] \end{array} \quad \text{高斯消去法}$$

复矩阵方程求解

$$(A_r + j A_i)(x_r + j x_i) = b_r + j b_i$$

$$\begin{bmatrix} A_r & -A_i \\ A_i & A_r \end{bmatrix} \begin{bmatrix} x_r \\ x_i \end{bmatrix} = \begin{bmatrix} b_r \\ b_i \end{bmatrix}$$

复矩阵方程求解 $Ax = b \xrightarrow{\text{初等行变换}} x = A^{-1}b$

实增广矩阵 $\begin{bmatrix} A_r & -A_i & b_r \\ A_i & A_r & b_i \end{bmatrix} \xrightarrow{\text{初等行变换}} \begin{bmatrix} I_n & O_n & x_r \\ O_n & I_n & x_i \end{bmatrix}$

向量空间与线性映射

集合的基本概念

元素的集体表示

常用的数学符号

\mathbf{R}, \mathbf{C}

\forall 表示“对所有...”；

$x \in A$ 读作“ x 属于集合 A ”，意即 x 是集合 A 的一个元素；

$x \notin A$ 表示 x 不是集合 A 的元素；

\ni 代表“使得”；

\exists 意即“存在”；

$A \Rightarrow B$ 表示“若有条件 A ，则有结果 B ”或“ A 意味着 B ”。

向量空间

以向量为元素的集合

向量空间与线性映射

线性映射

子空间 V 到子空间 W 的映射

$$T : V \mapsto W$$

线性映射/线性变换

叠加性

$$T(\boldsymbol{v} + \boldsymbol{w}) = T(\boldsymbol{v}) + T(\boldsymbol{w})$$

齐次性

$$T(c\boldsymbol{v}) = cT(\boldsymbol{v})$$

线性映射/线性变换（也可写成）

$$T(\boldsymbol{v}) = 3\boldsymbol{v} + 3 \quad \text{线性?}$$

$$T(c_1\boldsymbol{v} + c_2\boldsymbol{w}) = c_1T(\boldsymbol{v}) + c_2T(\boldsymbol{w})$$

更一般形式

$$T(c_1\boldsymbol{u}_1 + \cdots + c_p\boldsymbol{u}_p) = c_1T(\boldsymbol{u}_1) + \cdots + c_pT(\boldsymbol{u}_p)$$

向量空间与线性映射

线性映射


三维到二维的变换 $T: \mathbb{R}^3 \mapsto \mathbb{R}^2$

$$T_1(\mathbf{x}) = \begin{bmatrix} x_1 + x_2 \\ x_1^2 - x_2^2 \end{bmatrix}, \quad \text{其中, } \mathbf{x} = [x_1, x_2, x_3]^T \quad \text{非线性}$$

$$T_2(\mathbf{x}) = \begin{bmatrix} x_1 - x_2 \\ x_2 + x_3 \end{bmatrix}, \quad \text{其中, } \mathbf{x} = [x_1, x_2, x_3]^T \quad \text{线性}$$

正交投影算子 $w = T(x)$

$$\begin{bmatrix} w_1 \\ w_2 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}$$



向量的内积

典范内积

$$\langle x, y \rangle = x^H y = \sum_{i=1}^n x_i^* y_i$$

几何意义

从几何角度看，两个向量的内积与它们夹角的余弦有关。具体来说，两个向量 x 和 y 的内积可以表示为：

$$\langle x, y \rangle = \|x\| \|y\| \cos(\theta)$$

其中， $\|x\|$ 和 $\|y\|$ 分别是向量 x 和 y 的模长（或称为长度）， θ 是这两个向量的夹角， $\cos(\theta)$ 是夹角的余弦值。

内积性质

1. 交换律： $\langle x, y \rangle = \langle y, x \rangle$
2. 分配律： $\langle x, y + z \rangle = \langle x, y \rangle + \langle x, z \rangle$
3. 结合律： $c \langle x, y \rangle = \langle cx, y \rangle = \langle x, cy \rangle$
4. 若 $\langle x, y \rangle = 0$ ，且 x 和 y 都不是零向量，则 x 和 y 正交（即夹角为 90 度）

向量的内积

内积举例：DTFT（离散时间傅里叶变换）变换

$$X(f) = \sum_{n=0}^{N-1} x(n) e^{-j\left(\frac{2\pi}{N}\right)nf} = \mathbf{e}_{N-1}^H \mathbf{x} = \langle \mathbf{e}_{N-1}, \mathbf{x} \rangle$$

输入时间序列

其中 $\mathbf{e}_{N-1} = \left[1, e^{j\frac{2\pi}{N}f}, e^{j\frac{2\pi}{N}2f}, \dots, e^{j\frac{2\pi}{N}(N-1)f} \right]$ 傅里叶变换基向量

加权内积

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^H \mathbf{G} \mathbf{y}$$

Hermitian, positive definite (正定, 二次型大于0)

向量的范数

常用的向量范数

(1) L_0 范数（也称0范数），在稀疏表示中常用

$$\|\mathbf{x}\|_0 \stackrel{\text{def}}{=} \text{非零元素的个数}$$

(2) L_1 范数（也称1范数），将0范数松弛为1范数

$$\|\mathbf{x}\|_1 \stackrel{\text{def}}{=} \sum_{i=1}^m |x_i| = |x_1| + \cdots + |x_m|$$

(3) L_2 范数（常称Euclidean范数，有时也称Frobenius范数）

$$\|\mathbf{x}\|_2 = \left(\sum_{i=1}^m |x_i|^2 \right)^{1/2} = \left(|x_1|^2 + \cdots + |x_m|^2 \right)^{1/2}$$

也可缩写为 $\|\mathbf{x}\|$

向量的范数

常用的向量范数

(4) L_∞ 范数（也称无穷范数）或极大范数

$$\|\mathbf{x}\|_\infty = \max \{|x_1|, \dots, |x_m|\}$$

(5) L_p 范数（也称Hölder范数）

$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^m |x_i|^p \right)^{1/p} = \left(|x_1|^p + \dots + |x_m|^p \right)^{1/p}, \quad p \geq 1$$

向量的内积与范数

两个连续函数内积

$$\langle x(t), y(t) \rangle = \int_a^b x^*(t)y(t)dt$$

两个函数向量的内积

$$\langle \mathbf{x}(t), \mathbf{y}(t) \rangle \stackrel{\text{def}}{=} \int_a^b \mathbf{x}^H(t)\mathbf{y}(t)dt$$

两个函数向量的夹角定义

$$\cos \theta \stackrel{\text{def}}{=} \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\sqrt{\langle \mathbf{x}, \mathbf{x} \rangle} \sqrt{\langle \mathbf{y}, \mathbf{y} \rangle}} = \frac{\int_a^b \mathbf{x}^H(t)\mathbf{y}(t)dt}{\|\mathbf{x}(t)\| \|\mathbf{y}(t)\|}$$

$$\text{函数向量的范数} \quad \|\mathbf{x}(t)\| \stackrel{\text{def}}{=} \left(\int_a^b \mathbf{x}^H(t)\mathbf{x}(t)dt \right)^{1/2}$$

机器学习中向量的相似比较

距离衡量：未知模式向量 x 与样本模式向量 s_1 更相似

$$D(x, s_1) \leq D(x, s_2)$$

一种比较的方法：Euclidean距离

$$D_E(x, s_i) = \|x - s_i\|_2 = \sqrt{(x - s_i)^T (x - s_i)}$$

$$D_E(x, y) = 0 \iff x = y$$

$$D_E(x, s_i) = \min_k D_E(x, s_k), \quad k = 1, 2, \dots, M$$

最近的邻居

- K最近邻(k-Nearest Neighbor, KNN)
- K均值聚类 (clustering)：不同于分类 (classification)，
将无标签的数据点按照某种相似度来进行归类

随机向量

随机向量的内积与范数

随机向量的内积涉及到概率论和统计学中的概念，特别是在处理具有随机性的向量时。随机向量是由随机变量构成的向量，其内积的计算和理解，对于数据分析、信号处理、机器学习等领域非常重要

内积 $\langle \mathbf{x}(\xi), \mathbf{y}(\xi) \rangle \stackrel{\text{def}}{=} \mathbb{E} \{ \mathbf{x}^H(\xi) \mathbf{y}(\xi) \}$

范数 $\| \mathbf{x}(\xi) \|^2 \stackrel{\text{def}}{=} \mathbb{E} \{ \mathbf{x}^H(\xi) \mathbf{x}(\xi) \}$

正交性：两个向量之间在统计意义上正交（随机向量的统计特性描述）

$$\mathbb{E} \{ \mathbf{x}(\xi) \mathbf{y}^H(\xi) \} = \mathbf{O}_{m \times n}$$

随机向量

概率密度函数

随机向量

$$\mathbf{x}(\xi) = [x_1(\xi), \dots, x_m(\xi)]^T$$

ξ : 时间, 频率, 位置信息等 (空、时、频)

可由联合累积分布函数 (CDF: Culmulative Distribution Function) 完全描述

$$F(\mathbf{x}) \stackrel{\text{def}}{=} P\{\xi : x_1(\xi) \leq x_1, \dots, x_m(\xi) \leq x_m\}$$

也可以由概率密度函数 (PDF: Probability Density Function) 完全描述

$$\begin{aligned} f(\mathbf{x}) &\stackrel{\text{def}}{=} \lim_{\Delta x_1 \rightarrow 0, \dots, \Delta x_m \rightarrow 0} \frac{P\{\xi : x_1 < x_1(\xi) \leq x_1 + \Delta x_1, \dots, x_m < x_m(\xi) \leq x_m + \Delta x_m\}}{\Delta x_1 \cdots \Delta x_m} \\ &= \frac{\partial^m}{\partial x_1 \cdots \partial x_m} F_x(x_1, \dots, x_m) \end{aligned}$$

随机向量

概率密度函数

复随机向量

$$\mathbf{x}(\xi) = \mathbf{x}_R(\xi) + \mathrm{j}\mathbf{x}_I(\xi) = \begin{bmatrix} x_{R1}(\xi) \\ \vdots \\ x_{Rm}(\xi) \end{bmatrix} + \mathrm{j} \begin{bmatrix} x_{I1}(\xi) \\ \vdots \\ x_{Im}(\xi) \end{bmatrix}$$

可由联合累积分布函数完全描述

$$F(\mathbf{x}) \stackrel{\text{def}}{=} P\{\mathbf{x}(\xi) \leq \mathbf{x}\} \stackrel{\text{def}}{=} P\{\mathbf{x}_R(\xi) \leq \mathbf{x}_R, \mathbf{x}_I(\xi) \leq \mathbf{x}_I\}$$

也可以由概率密度函数完全描述

$$f(\mathbf{x}) \stackrel{\text{def}}{=} \frac{\partial^{2m} F(\mathbf{x})}{\partial x_{R1} \partial x_{I1} \cdots \partial x_{Rm} \partial x_{Im}}$$

随机向量

随机向量的统计描述

均值向量

$$\boldsymbol{\mu}_x = E\{\mathbf{x}(\xi)\} = \begin{bmatrix} E\{x_1(\xi)\} \\ \vdots \\ E\{x_m(\xi)\} \end{bmatrix} = \begin{bmatrix} \mu_1 \\ \vdots \\ \mu_m \end{bmatrix}$$

随机变量的期望

连续随机变量 $E\{x(\xi)\} \stackrel{\text{def}}{=} \int_{-\infty}^{\infty} x f(x) dx$ $f(x)$ 为概率密度函数

离散随机变量 $E[X] = \sum_{i=1}^n x_i P(X = x_i)$


对于一个离散随机变量 X , 其可能的取值为 x_1, x_2, \dots, x_n

与这些取值相对应的概率分别为 $P(X = x_1), P(X = x_2), \dots, P(X = x_n)$

随机向量

随机向量的统计描述

相关矩阵

$$\mathbf{R}_x \stackrel{\text{def}}{=} \mathbb{E} \left\{ \mathbf{x}(\xi) \mathbf{x}^{\text{H}}(\xi) \right\} = \begin{bmatrix} r_{11} & \cdots & r_{1m} \\ \vdots & \ddots & \vdots \\ r_{m1} & \cdots & r_{mm} \end{bmatrix}$$


对角：自相关函数 $r_{ii} \stackrel{\text{def}}{=} \mathbb{E} \left\{ |x_i(\xi)|^2 \right\}, \quad i = 1, \dots, m$

非对角：互相关函数 $r_{ij} \stackrel{\text{def}}{=} \mathbb{E} \left\{ x_i(\xi) x_j^*(\xi) \right\}, \quad i, j = 1, \dots, m, i \neq j$

\mathbf{R}_x : 复共轭对称矩阵, 即Hermitian矩阵

随机向量

随机向量的统计描述

自协方差矩阵

$$\mathbf{C}_x = \text{Cov}(\mathbf{x}, \mathbf{x}) \stackrel{\text{def}}{=} \text{E} \left\{ [\mathbf{x}(\xi) - \boldsymbol{\mu}_x][\mathbf{x}(\xi) - \boldsymbol{\mu}_x]^H \right\} = \begin{bmatrix} c_{11} & \cdots & c_{1m} \\ \vdots & \ddots & \vdots \\ c_{m1} & \cdots & c_{mm} \end{bmatrix}$$

自相关矩阵与自协方差矩阵之间的关系

$$\mathbf{C}_x = \mathbf{R}_x - \boldsymbol{\mu}_x \boldsymbol{\mu}_x^H$$

推广：互相关矩阵

$$\mathbf{R}_{xy} \stackrel{\text{def}}{=} \text{E} \left\{ \mathbf{x}(\xi) \mathbf{y}^H(\xi) \right\} = \begin{bmatrix} r_{x_1, y_1} & \cdots & r_{x_1, y_m} \\ \vdots & \ddots & \vdots \\ r_{x_m, y_1} & \cdots & r_{x_m, y_m} \end{bmatrix}$$

互协方差矩阵

$$\mathbf{C}_{xy} \stackrel{\text{def}}{=} \text{E} \left\{ [\mathbf{x}(\xi) - \boldsymbol{\mu}_x][\mathbf{y}(\xi) - \boldsymbol{\mu}_y]^H \right\} = \begin{bmatrix} c_{x_1, y_1} & \cdots & c_{x_1, y_m} \\ \vdots & \ddots & \vdots \\ c_{x_m, y_1} & \cdots & c_{x_m, y_m} \end{bmatrix} \quad \mathbf{C}_{xy} = \mathbf{R}_{xy} - \boldsymbol{\mu}_x \boldsymbol{\mu}_y^H$$

随机向量

两个随机变量之间的相关系数定义

$$\rho_{xy} \stackrel{\text{def}}{=} \frac{c_{xy}}{\sqrt{E\{|x(\xi) - \mu_x|^2\} E\{|y(\xi) - \mu_y|^2\}}} = \frac{c_{xy}}{\sigma_x \sigma_y}$$

由Cauchy-Schwartz $0 \leq |\rho_{xy}| \leq 1$

统计特性可由均值和协方差矩阵表征

实高斯白噪声向量 各个元素独立同分布

$$E\{\mathbf{x}(t)\} = \mathbf{0} \qquad E\{\mathbf{x}(t)\mathbf{x}^T(t)\} = \sigma^2 \mathbf{I}$$

复高斯白噪声向量 $E\{\mathbf{x}(t)\} = \mathbf{0}$

$$E\{\mathbf{x}(t)\mathbf{x}^H(t)\} = \sigma^2 \mathbf{I}$$

$$E\{\mathbf{x}(t)\mathbf{x}^T(t)\} = \mathbf{0}$$