

矩阵论

2024年秋季学期

第五讲

2024年9月23日

稀疏表示和压缩感知

特殊矩阵

矩阵微分

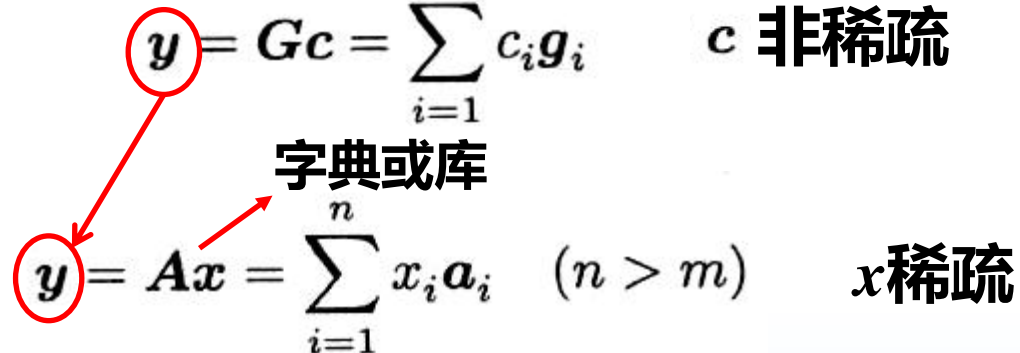
稀疏表示和压缩感知

一个含有大多数零元素的向量或矩阵称为稀疏向量 (sparse vector) 或者稀疏矩阵 (sparse matrix)

信号向量 $y \in \mathbb{R}^m$ 最多可分解为 m 个正交基 (向量) $g_k \in \mathbb{R}^m, k = 1, \dots, m$, 这些正交基的集合称为完备正交基 (complete orthogonal basis)。此时, 信号分解

$$\begin{aligned} y &= Gc = \sum_{i=1}^m c_i g_i && c \text{ 非稀疏} \\ y &= Ax = \sum_{i=1}^n x_i a_i \quad (n > m) && x \text{ 稀疏} \end{aligned}$$

字典或库



则 $n(> m)$ 个向量 $a_i \in \mathbb{R}^m, i = 1, \dots, n$ 不可能是正交基的集合。

A 的列称为原子 (atom) 或框架, 组成的集合为过完备集合。

稀疏表示和压缩感知

欠定方程

$$y = Ax = \sum_{i=1}^n x_i a_i \quad (n > m)$$

1. 经典方法：求最小 L_2 范数解

$$\min \|x\|_2 \quad \text{subject to } Ax = y$$

最小能量解，具有唯一性，解不符合稀疏表示要求

2. 现代方法：求最小 L_0 范数解

$$\min \|x\|_0 \quad \text{subject to } Ax = y$$

非零元素个数

解符合稀疏表示要求，求解较复杂

存在观测误差/噪声（随机）情况下：求最小 L_0 范数解

$$\min \|x\|_0 \quad \text{subject to } \|Ax - y\|_2 \leq \varepsilon$$

估计 \rightarrow Ax \leftarrow y 信号

稀疏表示和压缩感知

稀疏信号：大多数采样时刻取值等于零或者近似等于零
(频域)

压缩感知：低维的采样数据向量恢复或重构高维数据向量

压缩+低速率采样

$$y = Ax$$

$m \times 1$ $m \times n$ $n \times 1$ $m \leq n$

低维感知波形 感知矩阵 待重构：高维信号向量

变换域

$$x = \Phi \alpha$$

x 的K-稀疏表示

1. 估计稀疏向量 α , 仅含K个非零元素
2. 重构 x

Hermitian矩阵

$$\mathbf{R} = \begin{bmatrix} r_{11} & r_{21}^* & r_{31}^* & r_{41}^* \\ r_{21} & r_{22} & r_{32}^* & r_{31}^* \\ r_{31} & r_{32} & r_{22} & r_{21}^* \\ r_{41} & r_{31} & r_{21} & r_{11} \end{bmatrix}$$

复共轭对称矩阵 $\mathbf{R} = \mathbf{R}^H$

反Hermitian矩阵? $\mathbf{R} = -\mathbf{R}^H$

$$\alpha \mathbf{A} + \beta \mathbf{B}$$

置换矩阵

定义 2.2.1 一个正方形矩阵称为置换矩阵 (permutation matrix), 若它的每一行和每一列有一个且仅有一个非零元素 1。

置换矩阵 P 有下列性质^[61]:

(1) $(P_{m \times n})^T = P_{n \times m}。$

(2) $P^T P = P P^T = I$, 这说明置换矩阵是正交矩阵。

(3) $P^T = P^{-1}。$

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \\ a_{41} & a_{42} & a_{43} & a_{44} \\ a_{51} & a_{52} & a_{53} & a_{54} \end{bmatrix}$$

$$P_4 = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix},$$

$$P_5 = \begin{bmatrix} 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 \end{bmatrix}$$

$P_5 A = \begin{bmatrix} a_{51} & a_{52} & a_{53} & a_{54} \\ a_{31} & a_{32} & a_{33} & a_{34} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{41} & a_{42} & a_{43} & a_{44} \\ a_{11} & a_{12} & a_{13} & a_{14} \end{bmatrix}$, **对行重新排列**

$A P_4 = \begin{bmatrix} a_{13} & a_{12} & a_{14} & a_{11} \\ a_{23} & a_{22} & a_{24} & a_{21} \\ a_{33} & a_{32} & a_{34} & a_{31} \\ a_{43} & a_{42} & a_{44} & a_{41} \\ a_{53} & a_{52} & a_{54} & a_{51} \end{bmatrix}$ **对列重新排列**

互换矩阵

$$J = \begin{bmatrix} 0 & & & 1 \\ & \ddots & & \\ & & 1 & \\ 1 & & & 0 \end{bmatrix}$$

左乘：矩阵的行顺序反转

flipud

$$J_m A = \begin{bmatrix} a_{m1} & a_{m2} & \cdots & a_{mn} \\ \vdots & \vdots & \vdots & \vdots \\ a_{21} & a_{22} & \cdots & a_{2n} \\ a_{11} & a_{12} & \cdots & a_{1n} \end{bmatrix}$$

右乘：矩阵的列顺序反转

fliplr

$$A J_n = \begin{bmatrix} a_{1n} & \cdots & a_{12} & a_{11} \\ a_{2n} & \cdots & a_{22} & a_{21} \\ \vdots & \vdots & \vdots & \vdots \\ a_{mn} & \cdots & a_{m2} & a_{m1} \end{bmatrix}$$

广义置换矩阵

定义 2.2.2 一个正方形矩阵称为广义置换矩阵 (generalized permutation matrix), 简称 g 矩阵, 若其每行和每列有一个并且仅有一个非零元素。

$$G = \begin{bmatrix} 0 & 0 & 0 & 0 & \alpha \\ 0 & 0 & \beta & 0 & 0 \\ 0 & \gamma & 0 & 0 & 0 \\ 0 & 0 & 0 & \lambda & 0 \\ \rho & 0 & 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \rho & & & & 0 \\ & \gamma & & & \\ & & \beta & & \\ & & & \lambda & \\ 0 & & & & \alpha \end{bmatrix}$$

g 矩阵 置换矩阵 非奇异对角阵

观测数据模型

$$x(t) = As(t) = \sum_{i=1}^n a_i s_i(t)$$

对信号进行恢复

$$s(t) = A^\dagger x(t) \quad A^\dagger = (A^T A)^{-1} A^T \quad \text{广义逆矩阵}$$

两种不确定性: 1) 累加导致信号顺序不确定

2) 信号幅度不确定 $x(t) = \sum_{i=1}^n \frac{a_i}{\alpha_i} \alpha_i s_i(t)$

这两种不确定性可以通过广义置换矩阵进行描述

$$x(t) = GAs(t)$$

正交矩阵与酉矩阵

定理 2.3.2^[238] 若 $U \in \mathbb{C}^{n \times n}$, 则下列叙述等价:

- (1) U 是酉矩阵;
- (2) U 是非奇异的, 并且 $U^H = U^{-1}$;
- (3) $UU^H = U^H U = I$;
- (4) U^H 是酉矩阵;
- (5) $U = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n]$ 的列组成标准正交组, 即

$$\mathbf{u}_i^H \mathbf{u}_j = \delta(i - j) = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}$$

- (6) U 的行组成标准正交组;

- (7) 对所有 $\mathbf{x} \in \mathbb{C}^n$ 而言, $\mathbf{y} = U\mathbf{x}$ 的 Euclidean 长度与 \mathbf{x} 的 Euclidean 长度相同, 即

$$\mathbf{y}^H \mathbf{y} = \mathbf{x}^H \mathbf{x}.$$

正交矩阵与酉矩阵

酉变换

(1) 向量内积在酉变换下是不变的, 即

$$\langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{Ax}, \mathbf{Ay} \rangle$$

这是因为 $\langle \mathbf{Ax}, \mathbf{Ay} \rangle = (\mathbf{Ax})^H \mathbf{Ay} = \mathbf{x}^H \mathbf{A}^H \mathbf{Ay} = \mathbf{x}^H \mathbf{y} = \langle \mathbf{x}, \mathbf{y} \rangle$ 。

(2) 向量范数在酉变换下是不变的, 即

$$\|\mathbf{Ax}\|^2 = \|\mathbf{x}\|^2$$

因为 $\|\mathbf{Ax}\|^2 = \langle \mathbf{Ax}, \mathbf{Ax} \rangle = \langle \mathbf{x}, \mathbf{x} \rangle = \|\mathbf{x}\|^2$ 。

(3) 两个向量的夹角在酉变换下也是不变的, 即

$$\cos \theta = \frac{\langle \mathbf{Ax}, \mathbf{Ay} \rangle}{\|\mathbf{Ax}\| \|\mathbf{Ay}\|} = \frac{\langle \mathbf{x}, \mathbf{y} \rangle}{\|\mathbf{x}\| \|\mathbf{y}\|}$$

实向量/矩阵与复向量/矩阵的性质比较

表 2.3.1 实向量、实矩阵与复向量、复矩阵的性质比较

实向量、实矩阵	复向量、复矩阵
范数 $\ \mathbf{x}\ = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2}$	范数 $\ \mathbf{x}\ = \sqrt{ x_1 ^2 + x_2 ^2 + \cdots + x_n ^2}$
转置 $\mathbf{A}^T = [a_{ji}]$, $(\mathbf{AB})^T = \mathbf{B}^T \mathbf{A}^T$	共轭转置 $\mathbf{A}^H = [a_{ji}^*]$, $(\mathbf{AB})^H = \mathbf{B}^H \mathbf{A}^H$
内积 $\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^T \mathbf{y}$	内积 $\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^H \mathbf{y}$
正交性 $\mathbf{x}^T \mathbf{y} = 0$	正交性 $\mathbf{x}^H \mathbf{y} = 0$
对称矩阵 $\mathbf{A}^T = \mathbf{A}$	Hermitian 矩阵 $\mathbf{A}^H = \mathbf{A}$
正交矩阵 $\mathbf{Q}^T = \mathbf{Q}^{-1}$	酉矩阵 $\mathbf{U}^H = \mathbf{U}^{-1}$
特征值分解 $\mathbf{A} = \mathbf{Q} \mathbf{\Sigma} \mathbf{Q}^T = \mathbf{Q} \mathbf{\Sigma} \mathbf{Q}^{-1}$	特征值分解 $\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{U}^H = \mathbf{U} \mathbf{\Sigma} \mathbf{U}^{-1}$
范数的正交不变性 $\ \mathbf{Qx}\ = \ \mathbf{x}\ $	范数的酉不变性 $\ \mathbf{Ux}\ = \ \mathbf{x}\ $
内积的正交不变性 $\langle \mathbf{Qx}, \mathbf{Qy} \rangle = \langle \mathbf{x}, \mathbf{y} \rangle$	内积的酉不变性 $\langle \mathbf{Ux}, \mathbf{Uy} \rangle = \langle \mathbf{x}, \mathbf{y} \rangle$

三角矩阵

$$U = \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ 0 & u_{22} & \cdots & u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & u_{nn} \end{bmatrix}$$

$$L = \begin{bmatrix} l_{11} & & & 0 \\ l_{12} & l_{22} & & \\ \vdots & \vdots & \ddots & \\ l_{n1} & l_{n2} & \cdots & l_{nn} \end{bmatrix}$$

(1) 下三角矩阵, 若

$$a_{ij} = 0 \ (i < j);$$

(2) 严格下三角矩阵, 若

$$a_{ij} = 0 \ (i \leq j);$$

(3) 单位下三角矩阵, 若

$$a_{ij} = 0 \ (i < j), \ a_{ii} = 1 \ (\forall i);$$

(4) 上三角矩阵, 若

$$a_{ij} = 0 \ (i > j);$$

(5) 严格上三角矩阵, 若

$$a_{ij} = 0 \ (i \geq j);$$

(6) 单位上三角矩阵, 若

$$a_{ij} = 0 \ (i > j), \ a_{ii} = 1 \ (\forall i)。$$

相似矩阵

定义 2.6.1 (相似矩阵与相似变换) 矩阵 $B \in \mathbb{C}^{n \times n}$ 称为矩阵 $A \in \mathbb{C}^{n \times n}$ 的相似矩阵, 若存在一非奇异矩阵 $S \in \mathbb{C}^{n \times n}$ 使得 $B = S^{-1}AS$ 。此时, 线性变换 $A \mapsto S^{-1}AS$ 称为矩阵 A 的相似变换。关系“ B 相似于 A ”常简写作 $B \sim A$ 。

特征值相同

特征向量存在线性变换关系

$$\det(B) = \det(A) \quad \text{tr}(B) = \text{tr}(A)$$

Vandermonde矩阵

矩阵每行（或列）的元素组成一个等比序列

$$\mathbf{A} = \begin{bmatrix} 1 & 1 & \cdots & 1 \\ x_1 & x_2 & \cdots & x_n \\ x_1^2 & x_2^2 & \cdots & x_n^2 \\ \vdots & \vdots & \vdots & \vdots \\ x_1^{n-1} & x_2^{n-1} & \cdots & x_n^{n-1} \end{bmatrix}$$

$$\mathbf{A} = \begin{bmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^{n-1} \\ 1 & x_2 & x_2^2 & \cdots & x_2^{n-1} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^{n-1} \end{bmatrix}$$

性质：第二行/第二列元素各不相同时，矩阵非奇异

Fourier矩阵

Fourier矩阵是一种特殊结构的Vandermonde

DFT

$$X_k = \sum_{n=0}^{N-1} x_n e^{-j2\pi nk/N} = \sum_{n=0}^{N-1} x_n w^{nk}, \quad k = 0, 1, \dots, N-1$$

$$\begin{bmatrix} X_0 \\ X_1 \\ \vdots \\ X_{N-1} \end{bmatrix} = \begin{bmatrix} 1 & 1 & \dots & 1 \\ 1 & w & \dots & w^{N-1} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & w^{N-1} & \dots & w^{(N-1)(N-1)} \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_{N-1} \end{bmatrix}$$

$$\hat{x} = Fx$$

$$F = \begin{bmatrix} 1 & 1 & \dots & 1 \\ 1 & w & \dots & w^{N-1} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & w^{N-1} & \dots & w^{(N-1)(N-1)} \end{bmatrix}, \quad w = e^{-j2\pi/N} \quad \text{称为Fourier矩阵}$$

Fourier矩阵

$$\mathbf{F}^H \mathbf{F} = \mathbf{F} \mathbf{F}^H = N \mathbf{I}$$

$$\mathbf{F}^{-1} = \frac{1}{N} \mathbf{F}^H = \frac{1}{N} \mathbf{F}^*$$

$$\mathbf{x} = \mathbf{F}^{-1} \hat{\mathbf{x}} = \frac{1}{N} \mathbf{F}^* \hat{\mathbf{x}}$$

$$\begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_{N-1} \end{bmatrix} = \frac{1}{N} \begin{bmatrix} 1 & 1 & \dots & 1 \\ 1 & w^* & \dots & (w^{N-1})^* \\ \vdots & \vdots & \ddots & \vdots \\ 1 & (w^{N-1})^* & \dots & (w^{(N-1)(N-1)})^* \end{bmatrix} \begin{bmatrix} X_0 \\ X_1 \\ \vdots \\ X_{N-1} \end{bmatrix}$$

DFT 反变换

$$x_n = \frac{1}{N} \sum_{k=0}^{N-1} X_k e^{j2\pi nk/N}, \quad n = 0, 1, \dots, N-1$$

Hadamard矩阵

定义 2.9.1 $H_n \in \mathbb{R}^{n \times n}$ 称为 Hadamard 矩阵, 若它的所有元素取 +1 或者 -1, 且

$$H_n H_n^T = H_n^T H_n = nI_n \quad (2.9.1)$$

第 1 列和第 1 行的所有元素为 +1 的 Hadamard 矩阵 称为规范化 Hadamard 矩阵。

只有当 $n = 2$ 或者 n 是 4 的整数倍时, Hadamard 矩阵才存在。

容易验证 $\frac{1}{\sqrt{n}}H_n$ 为标准正交矩阵。

$n \times n$ Hadamard 矩阵 H_n 的行列式 $\det(H_n) = n^{n/2}$ 。

定理 2.9.1 令 $n = 2^k, k = 1, 2, \dots$, 则规范化的标准正交 Hadamard 矩阵具有通用构造公式

$$\bar{H}_n = \frac{1}{\sqrt{2}} \begin{bmatrix} \bar{H}_{n/2} & \bar{H}_{n/2} \\ \bar{H}_{n/2} & -\bar{H}_{n/2} \end{bmatrix} \quad (2.9.2)$$

其中


$$\bar{H}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \quad (2.9.3)$$

Hadamard矩阵

例 2.9.1 当 $n = 2^3 = 8$ 时, Hadamard 矩阵

$$\begin{aligned} H_8 &= \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \otimes \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \otimes \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & -1 & 1 & -1 & 1 & -1 & 1 & -1 \\ 1 & 1 & -1 & -1 & 1 & 1 & -1 & -1 \\ 1 & -1 & -1 & 1 & 1 & -1 & -1 & 1 \\ 1 & 1 & 1 & 1 & -1 & -1 & -1 & -1 \\ 1 & -1 & 1 & -1 & -1 & 1 & -1 & 1 \\ 1 & 1 & -1 & -1 & -1 & -1 & 1 & 1 \\ 1 & -1 & -1 & 1 & -1 & 1 & 1 & -1 \end{bmatrix} \end{aligned}$$

Hadamard矩阵



$$\int_0^1 \phi_i(t) \phi_j(t) dt = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}$$

Toeplitz矩阵

任何一条对角线的元素取相同值

$$\mathbf{A} = \begin{bmatrix} a_0 & a_{-1} & a_{-2} & \cdots & a_{-n} \\ a_1 & a_0 & a_{-1} & \cdots & a_{-n+1} \\ a_2 & a_1 & a_0 & \ddots & \vdots \\ \vdots & \vdots & \ddots & \ddots & a_{-1} \\ a_n & a_{n-1} & \cdots & a_1 & a_0 \end{bmatrix} = [a_{i-j}]_{i,j=0}^n$$

对称 Toeplitz 矩阵 $\mathbf{A} = [a_{|i-j|}]_{i,j=0}^n$

若一个复 Toeplitz 矩阵的元素满足复共轭对称关系 $a_{-i} = a_i^*$

称为 Hermitian Toeplitz 矩阵

$$\mathbf{A} = \begin{bmatrix} a_0 & a_1^* & a_2^* & \cdots & a_n^* \\ a_1 & a_0 & a_1^* & \cdots & a_{n-1}^* \\ a_2 & a_1 & a_0 & \ddots & \vdots \\ \vdots & \vdots & \ddots & \ddots & a_1^* \\ a_n & a_{n-1} & \cdots & a_1 & a_0 \end{bmatrix}$$

Hankel矩阵

正方形矩阵 $A \in \mathbb{C}^{(n+1) \times (n+1)}$ 称为 Hankel 矩阵, 若

$$A = \begin{bmatrix} a_0 & a_1 & a_2 & \cdots & a_n \\ a_1 & a_2 & a_3 & \cdots & a_{n+1} \\ a_2 & a_3 & a_4 & \cdots & a_{n+2} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ a_n & a_{n+1} & a_{n+2} & \cdots & a_{2n} \end{bmatrix}$$

矩阵微分

矩阵微分是矩阵分析和多变量微积分中的一个重要工具，它在理论研究和实际应用中都有广泛的用途。通过矩阵微分，可以高效地处理和解决涉及多维数据的问题。

矩阵微分的主要用途：

1. 优化问题：在机器学习、统计学和工程优化等领域，经常需要最小化或最大化某个多变量函数（通常表达为矩阵形式）。矩阵微分提供了一种寻找这些函数最优点（极值点）的方法。例如，通过求解梯度等于零的点，可以找到函数的局部最小值或最大值。
2. 机器学习：在机器学习中，矩阵微分用于计算损失函数的梯度，这是许多优化算法（如梯度下降法）的核心步骤。此外，在神经网络的反向传播算法中，矩阵微分被用来高效地计算权重的更新。

函数对变量（元素、向量或者矩阵）的导数/微分

变元、函数和映射

$\mathbf{x} = [x_1, \dots, x_m]^T \in \mathbb{R}^m$ 为实向量变元

$\mathbf{X} = [\mathbf{x}_1, \dots, \mathbf{x}_n] \in \mathbb{R}^{m \times n}$ 为实矩阵变元

$f(\mathbf{x}) \in \mathbb{R}$ 为实值标量函数, 其变元为 $m \times 1$ 实值向量 \mathbf{x} , $f: \mathbb{R}^m \rightarrow \mathbb{R}$;

$f(\mathbf{X}) \in \mathbb{R}$ 为实值标量函数, 其变元为 $m \times n$ 实值矩阵 \mathbf{X} , $f: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$;

$f(\mathbf{x}) \in \mathbb{R}^p$ 为 p 维实列向量函数, 其变元为 $m \times 1$ 实值向量 \mathbf{x} , $f: \mathbb{R}^m \rightarrow \mathbb{R}^p$;

$f(\mathbf{X}) \in \mathbb{R}^p$ 为 p 维实列向量函数, 其变元为 $m \times n$ 实值矩阵 \mathbf{X} , $f: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}^p$;

$\mathbf{F}(\mathbf{x}) \in \mathbb{R}^{p \times q}$ 为 $p \times q$ 实矩阵函数, 其变元为 $m \times 1$ 实值向量 \mathbf{x} , $\mathbf{F}: \mathbb{R}^m \rightarrow \mathbb{R}^{p \times q}$;

$\mathbf{F}(\mathbf{X}) \in \mathbb{R}^{p \times q}$ 为 $p \times q$ 实矩阵函数, 其变元为 $m \times n$ 实值矩阵 \mathbf{X} , $\mathbf{F}: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}^{p \times q}$;

变元、函数和映射

表 3.1.1 实值函数的分类

函数类型	<u>向量变元</u> $\boldsymbol{x} \in \mathbb{R}^m$	<u>矩阵变元</u> $\boldsymbol{X} \in \mathbb{R}^{m \times n}$
<u>标量函数</u> $f \in \mathbb{R}$	$f(\boldsymbol{x})$ $f: \mathbb{R}^m \rightarrow \mathbb{R}$	$f(\boldsymbol{X})$ $f: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$
<u>向量函数</u> $\boldsymbol{f} \in \mathbb{R}^p$	$\boldsymbol{f}(\boldsymbol{x})$ $\boldsymbol{f}: \mathbb{R}^m \rightarrow \mathbb{R}^p$	$\boldsymbol{f}(\boldsymbol{X})$ $\boldsymbol{f}: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}^p$
<u>矩阵函数</u> $\boldsymbol{F} \in \mathbb{R}^{p \times q}$	$\boldsymbol{F}(\boldsymbol{x})$ $\boldsymbol{F}: \mathbb{R}^m \rightarrow \mathbb{R}^{p \times q}$	$\boldsymbol{F}(\boldsymbol{X})$ $\boldsymbol{F}: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}^{p \times q}$

Jacobian矩阵

行向量偏导算子 $D_x \stackrel{\text{def}}{=} \frac{\partial}{\partial \mathbf{x}^T} = \left[\frac{\partial}{\partial x_1}, \dots, \frac{\partial}{\partial x_m} \right]$

$$D_x f(\mathbf{x}) = \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}^T} = \left[\frac{\partial f(\mathbf{x})}{\partial x_1}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_m} \right]$$

当实值标量函数的变元为实值矩阵时，存在两种定义

1) $f(X)$ 关于矩阵变元 X 的Jacobian矩阵

$$X \in \mathbb{R}^{m \times n} \quad D_X f(X) = \frac{\partial f(X)}{\partial \mathbf{X}^T} = \begin{bmatrix} \frac{\partial f(X)}{\partial x_{11}} & \dots & \frac{\partial f(X)}{\partial x_{m1}} \\ \vdots & \ddots & \vdots \\ \frac{\partial f(X)}{\partial x_{1n}} & \dots & \frac{\partial f(X)}{\partial x_{mn}} \end{bmatrix} \in \mathbb{R}^{n \times m}$$

雅可比矩阵的每一行包含了
映射到函数中某个分量的导
数

2) 行偏导向量

$$D_{\text{vec}X} f(X) = \frac{\partial f(X)}{\partial \text{vec}^T(X)} = \left[\frac{\partial f(X)}{\partial x_{11}}, \dots, \frac{\partial f(X)}{\partial x_{m1}}, \dots, \frac{\partial f(X)}{\partial x_{1n}}, \dots, \frac{\partial f(X)}{\partial x_{mn}} \right]$$

$$D_{\text{vec}X} f(X) = \text{rvec}(D_X f(X)) = \left(\text{vec}(D_X^T f(X)) \right)^T$$

Jacobian矩阵

函数为矩阵，变元为矩阵

Jacobian 矩阵

$$D_{\mathbf{X}} \mathbf{F}(\mathbf{X}) \stackrel{\text{def}}{=} \frac{\partial \text{vec}(\mathbf{F}(\mathbf{X}))}{\partial (\text{vec} \mathbf{X})^T} \in \mathbb{R}^{pq \times mn}$$

其具体表达式为

$$D_{\mathbf{X}} \mathbf{F}(\mathbf{X}) = \begin{bmatrix} \frac{\partial f_{11}}{\partial (\text{vec} \mathbf{X})^T} \\ \vdots \\ \frac{\partial f_{p1}}{\partial (\text{vec} \mathbf{X})^T} \\ \vdots \\ \frac{\partial f_{1q}}{\partial (\text{vec} \mathbf{X})^T} \\ \vdots \\ \frac{\partial f_{pq}}{\partial (\text{vec} \mathbf{X})^T} \end{bmatrix} = \begin{bmatrix} \frac{\partial f_{11}}{\partial x_{11}} & \cdots & \frac{\partial f_{11}}{\partial x_{m1}} & \cdots & \frac{\partial f_{11}}{\partial x_{1n}} & \cdots & \frac{\partial f_{11}}{\partial x_{mn}} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \frac{\partial f_{p1}}{\partial x_{11}} & \cdots & \frac{\partial f_{p1}}{\partial x_{m1}} & \cdots & \frac{\partial f_{p1}}{\partial x_{1n}} & \cdots & \frac{\partial f_{p1}}{\partial x_{mn}} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \frac{\partial f_{1q}}{\partial x_{11}} & \cdots & \frac{\partial f_{1q}}{\partial x_{m1}} & \cdots & \frac{\partial f_{1q}}{\partial x_{1n}} & \cdots & \frac{\partial f_{1q}}{\partial x_{mn}} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \frac{\partial f_{pq}}{\partial x_{11}} & \cdots & \frac{\partial f_{pq}}{\partial x_{m1}} & \cdots & \frac{\partial f_{pq}}{\partial x_{1n}} & \cdots & \frac{\partial f_{pq}}{\partial x_{mn}} \end{bmatrix}$$