

# 矩阵论

---

2024年秋季学期

第六讲

2024年9月25日

## 第3章 矩阵微分

# 矩阵微分

矩阵微分是矩阵分析和多变量微积分中的一个重要工具，它在理论研究和实际应用中都有广泛的用途。通过矩阵微分，可以高效地处理和解决涉及多维数据的问题。

矩阵微分的主要用途：

1. 优化问题：在机器学习、统计学和工程优化等领域，经常需要最小化或最大化某个多变量函数（通常表达为矩阵形式）。矩阵微分提供了一种寻找这些函数最优点（极值点）的方法。例如，通过求解梯度等于零的点，可以找到函数的局部最小值或最大值。
2. 机器学习：在机器学习中，矩阵微分用于计算损失函数的梯度，这是许多优化算法（如梯度下降法）的核心步骤。此外，在神经网络的反向传播算法中，矩阵微分被用来高效地计算权重的更新。

**函数对变量（元素、向量或者矩阵）的导数/微分**

# 变元、函数和映射

$\mathbf{x} = [x_1, \dots, x_m]^T \in \mathbb{R}^m$  为实向量变元

$\mathbf{X} = [\mathbf{x}_1, \dots, \mathbf{x}_n] \in \mathbb{R}^{m \times n}$  为实矩阵变元

$f(\mathbf{x}) \in \mathbb{R}$  为实值标量函数, 其变元为  $m \times 1$  实值向量  $\mathbf{x}$ ,  $f: \mathbb{R}^m \rightarrow \mathbb{R}$  ;

$f(\mathbf{X}) \in \mathbb{R}$  为实值标量函数, 其变元为  $m \times n$  实值矩阵  $\mathbf{X}$ ,  $f: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$  ;

$\mathbf{f}(\mathbf{x}) \in \mathbb{R}^p$  为  $p$  维实列向量函数, 其变元为  $m \times 1$  实值向量  $\mathbf{x}$ ,  $\mathbf{f}: \mathbb{R}^m \rightarrow \mathbb{R}^p$  ;

$\mathbf{f}(\mathbf{X}) \in \mathbb{R}^p$  为  $p$  维实列向量函数, 其变元为  $m \times n$  实值矩阵  $\mathbf{X}$ ,  $\mathbf{f}: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}^p$  ;

$\mathbf{F}(\mathbf{x}) \in \mathbb{R}^{p \times q}$  为  $p \times q$  实矩阵函数, 其变元为  $m \times 1$  实值向量  $\mathbf{x}$ ,  $\mathbf{F}: \mathbb{R}^m \rightarrow \mathbb{R}^{p \times q}$  ;

$\mathbf{F}(\mathbf{X}) \in \mathbb{R}^{p \times q}$  为  $p \times q$  实矩阵函数, 其变元为  $m \times n$  实值向量  $\mathbf{X}$ ,  $\mathbf{F}: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}^{p \times q}$  ;

# 变元、函数和映射

表 3.1.1 实值函数的分类

函数类型	<u>向量变元</u> $\boldsymbol{x} \in \mathbb{R}^m$	<u>矩阵变元</u> $\boldsymbol{X} \in \mathbb{R}^{m \times n}$
<u>标量函数</u> $f \in \mathbb{R}$	$f(\boldsymbol{x})$ $f: \mathbb{R}^m \rightarrow \mathbb{R}$	$f(\boldsymbol{X})$ $f: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$
<u>向量函数</u> $\boldsymbol{f} \in \mathbb{R}^p$	$\boldsymbol{f}(\boldsymbol{x})$ $\boldsymbol{f}: \mathbb{R}^m \rightarrow \mathbb{R}^p$	$\boldsymbol{f}(\boldsymbol{X})$ $\boldsymbol{f}: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}^p$
<u>矩阵函数</u> $\boldsymbol{F} \in \mathbb{R}^{p \times q}$	$\boldsymbol{F}(\boldsymbol{x})$ $\boldsymbol{F}: \mathbb{R}^m \rightarrow \mathbb{R}^{p \times q}$	$\boldsymbol{F}(\boldsymbol{X})$ $\boldsymbol{F}: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}^{p \times q}$

# Jacobian矩阵

行向量偏导算子

$$\mathbf{D}_x \stackrel{\text{def}}{=} \frac{\partial}{\partial \mathbf{x}^T} = \left[ \frac{\partial}{\partial x_1}, \dots, \frac{\partial}{\partial x_m} \right]$$
$$\mathbf{D}_x f(\mathbf{x}) = \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}^T} = \left[ \frac{\partial f(\mathbf{x})}{\partial x_1}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_m} \right]$$

当实值标量函数的变元为实值矩阵时，存在两种定义

1)  $f(X)$  关于矩阵变元  $X$  的Jacobian矩阵

$$X \in \mathbb{R}^{m \times n} \quad \mathbf{D}_X f(X) = \frac{\partial f(X)}{\partial X^T} = \begin{bmatrix} \frac{\partial f(X)}{\partial x_{11}} & \dots & \frac{\partial f(X)}{\partial x_{m1}} \\ \vdots & \ddots & \vdots \\ \frac{\partial f(X)}{\partial x_{1n}} & \dots & \frac{\partial f(X)}{\partial x_{mn}} \end{bmatrix} \in \mathbb{R}^{n \times m}$$

# Jacobian矩阵

## 2) 行偏导向量

$$D_{\text{vec}X} f(X) = \frac{\partial f(X)}{\partial \text{vec}^T(X)} = \left[ \frac{\partial f(X)}{\partial x_{11}}, \dots, \frac{\partial f(X)}{\partial x_{m1}}, \dots, \frac{\partial f(X)}{\partial x_{1n}}, \dots, \frac{\partial f(X)}{\partial x_{mn}} \right]$$

$$D_{\text{vec}X} f(X) = \text{rvec}(D_X f(X)) = \left( \text{vec}(D_X^T f(X)) \right)^T$$

# Jacobian矩阵与梯度矩阵

## 函数为矩阵，变元为矩阵

Jacobian 矩阵

$$D_{\mathbf{X}} \mathbf{F}(\mathbf{X}) \stackrel{\text{def}}{=} \frac{\partial \text{vec}(\mathbf{F}(\mathbf{X}))}{\partial (\text{vec} \mathbf{X})^T} \in \mathbb{R}^{pq \times mn}$$

其具体表达式为

$$D_{\mathbf{X}} \mathbf{F}(\mathbf{X}) = \begin{bmatrix} \frac{\partial f_{11}}{\partial (\text{vec} \mathbf{X})^T} \\ \vdots \\ \frac{\partial f_{p1}}{\partial (\text{vec} \mathbf{X})^T} \\ \vdots \\ \frac{\partial f_{1q}}{\partial (\text{vec} \mathbf{X})^T} \\ \vdots \\ \frac{\partial f_{pq}}{\partial (\text{vec} \mathbf{X})^T} \end{bmatrix} = \begin{bmatrix} \frac{\partial f_{11}}{\partial x_{11}} & \cdots & \frac{\partial f_{11}}{\partial x_{m1}} & \cdots & \frac{\partial f_{11}}{\partial x_{1n}} & \cdots & \frac{\partial f_{11}}{\partial x_{mn}} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \frac{\partial f_{p1}}{\partial x_{11}} & \cdots & \frac{\partial f_{p1}}{\partial x_{m1}} & \cdots & \frac{\partial f_{p1}}{\partial x_{1n}} & \cdots & \frac{\partial f_{p1}}{\partial x_{mn}} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \frac{\partial f_{1q}}{\partial x_{11}} & \cdots & \frac{\partial f_{1q}}{\partial x_{m1}} & \cdots & \frac{\partial f_{1q}}{\partial x_{1n}} & \cdots & \frac{\partial f_{1q}}{\partial x_{mn}} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \frac{\partial f_{pq}}{\partial x_{11}} & \cdots & \frac{\partial f_{pq}}{\partial x_{m1}} & \cdots & \frac{\partial f_{pq}}{\partial x_{1n}} & \cdots & \frac{\partial f_{pq}}{\partial x_{mn}} \end{bmatrix}$$

# 梯度矩阵

$m \times 1$  列向量偏导算子即梯度算子记作  $\nabla_x$  , 定义为

$$\nabla_x \stackrel{\text{def}}{=} \frac{\partial}{\partial \mathbf{x}} = \left[ \frac{\partial}{\partial x_1}, \dots, \frac{\partial}{\partial x_m} \right]^T$$

$$\nabla_x f(\mathbf{x}) \stackrel{\text{def}}{=} \left[ \frac{\partial f(\mathbf{x})}{\partial x_1}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_m} \right]^T = \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}}$$

矩阵变元  $X$  的梯度算子为

$$\nabla_{\text{vec} X} = \frac{\partial}{\partial \text{vec} X} = \left[ \frac{\partial}{\partial x_{11}}, \dots, \frac{\partial}{\partial x_{m1}}, \dots, \frac{\partial}{\partial x_{1n}}, \dots, \frac{\partial}{\partial x_{mn}} \right]^T$$

矩阵变元  $X$  的梯度向量为

$$\nabla_{\text{vec} X} f(X) = \frac{\partial f(X)}{\partial \text{vec} X} = \left[ \frac{\partial f(X)}{\partial x_{11}}, \dots, \frac{\partial f(X)}{\partial x_{m1}}, \dots, \frac{\partial f(X)}{\partial x_{1n}}, \dots, \frac{\partial f(X)}{\partial x_{mn}} \right]^T$$



# 梯度矩阵

也可以直接定义梯度矩阵

$$\nabla_X f(X) = \begin{bmatrix} \frac{\partial f(X)}{\partial x_{11}} & \dots & \frac{\partial f(X)}{\partial x_{1n}} \\ \vdots & \ddots & \vdots \\ \frac{\partial f(X)}{\partial x_{m1}} & \dots & \frac{\partial f(X)}{\partial x_{mn}} \end{bmatrix} = \frac{\partial f(X)}{\partial X}$$

对于实值矩阵函数  $F(X) \in \mathbb{R}^{p \times q}$  (其中矩阵变元  $X \in \mathbb{R}^{m \times n}$ ) ,  
梯度矩阵定义为

$$\nabla_X F(X) = \frac{\partial \text{vec}^T F(X)}{\partial \text{vec} X} = \left( \frac{\partial \text{vec} F(X)}{\partial \text{vec}^T X} \right)^T$$

$$\nabla_X F(X) = (D_X F(X))^T$$

矩阵函数的梯度矩阵是其Jacobian矩阵的转置。

# 梯度矩阵

(1) 若  $f(X) = c$  为常数, 其中,  $X$  为  $m \times n$  矩阵, 则梯度  $\frac{\partial c}{\partial X} = \mathbf{0}_{m \times n}$

(2) 线性法则 若  $f(X)$  和  $g(X)$  分别是矩阵  $X$  的实值函数,  $c_1$  和  $c_2$  为实常数, 则

$$\frac{\partial [c_1 f(X) + c_2 g(X)]}{\partial X} = c_1 \frac{\partial f(X)}{\partial X} + c_2 \frac{\partial g(X)}{\partial X}$$

(3) 乘积法则 若  $f(X)$ 、 $g(X)$  和  $h(X)$  都是矩阵  $X$  的实值函数, 则

$$\frac{\partial [f(X)g(X)]}{\partial X} = g(X) \frac{\partial f(X)}{\partial X} + f(X) \frac{\partial g(X)}{\partial X}$$

$$\frac{\partial [f(X)g(X)h(X)]}{\partial X} = g(X)h(X) \frac{\partial f(X)}{\partial X} + f(X)h(X) \frac{\partial g(X)}{\partial X} + f(X)g(X) \frac{\partial h(X)}{\partial X}$$

# 梯度矩阵

**(4) 商法则** 若  $g(\mathbf{X}) \neq 0$ , 则

$$\frac{\partial[f(\mathbf{X})/g(\mathbf{X})]}{\partial\mathbf{X}} = \frac{1}{g^2(\mathbf{X})} \left[ g(\mathbf{X}) \frac{\partial f(\mathbf{X})}{\partial\mathbf{X}} - f(\mathbf{X}) \frac{\partial g(\mathbf{X})}{\partial\mathbf{X}} \right]$$

**(5) 链式法则**  $\frac{\partial g(f(\mathbf{X}))}{\partial\mathbf{X}} = \frac{dg(y)}{dy} \frac{\partial f(\mathbf{X})}{\partial\mathbf{X}}$

# 独立性与基本假设

矩阵求导的独立性主要体现在对矩阵元素的处理上。在对矩阵函数进行求导时，通常假设矩阵中的每个元素都是相互独立的。这种假设简化了求导过程，因为它允许单独对每个元素进行求导，而不用担心其他元素的影响。这一点在计算梯度或雅可比矩阵时尤为重要。

假设实值函数的向量变元  $x = [x_i]_{i=1}^m \in \mathbb{R}^m$  或者矩阵变元  $[x_{ij}]_{i=1,j=1}^{m,n} \in \mathbb{R}^{m \times n}$

本身无任何特殊结构，即向量或矩阵变元的元素之间是各自独立的。

上述独立性基本假设可以用数学公式表示成

$$\frac{\partial x_i}{\partial x_j} = \delta_{ij} = \begin{cases} 1, & i = j \\ 0, & \text{其他} \end{cases}$$

以及

$$\frac{\partial x_{kl}}{\partial x_{ij}} = \delta_{ki} \delta_{lj} = \begin{cases} 1, & k = i \text{ 且 } l = j \\ 0, & \text{其他} \end{cases}$$

# 独立性与基本假设

**示例** 求实值函数  $f(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x}$  的 Jacobian 矩阵。

**由于**  $\mathbf{x}^T \mathbf{A} \mathbf{x} = \sum_{k=1}^n \sum_{l=1}^n a_{kl} x_k x_l,$

故利用独立性基本假设可求出偏导向量  $\frac{\partial \mathbf{x}^T \mathbf{A} \mathbf{x}}{\partial \mathbf{x}^T}$  的第  $i$  个分量为

$$\left[ \frac{\partial \mathbf{x}^T \mathbf{A} \mathbf{x}}{\partial \mathbf{x}^T} \right]_i = \frac{\partial}{\partial x_i} \sum_{k=1}^n \sum_{l=1}^n a_{kl} x_k x_l = \sum_{k=1}^n x_k a_{ki} + \sum_{l=1}^n x_l a_{il}$$

**示例** 令  $F(\mathbf{X}) = \mathbf{X} \in \mathbb{R}^{m \times n}$ , 则直接计算偏导得

$$\frac{\partial f_{kl}}{\partial x_{ij}} = \frac{\partial x_{kl}}{\partial x_{ij}} = \delta_{ij} \delta_{ki}$$

于是得 Jacobian 矩阵

$$\mathbf{D}_X \mathbf{X} = \mathbf{I}_n \otimes \mathbf{I}_m = \mathbf{I}_{mn} \in \mathbb{R}^{mn \times mn} \quad \longleftarrow \quad \mathbf{D}_X F(\mathbf{X}) \stackrel{\text{def}}{=} \frac{\partial \text{vec}(F(\mathbf{X}))}{\partial (\text{vec } \mathbf{X})^T}$$

# 一阶实矩阵微分：Jacobian矩阵辨识

矩阵微分用符号  $d\mathbf{X}$  表示

标量函数  $\text{tr}(\mathbf{U})$  的微分

$$d[\text{tr}(\mathbf{U})] = d\left(\sum_{i=1}^n u_{ii}\right) = \sum_{i=1}^n du_{ii} = \text{tr}(d\mathbf{U})$$

矩阵的迹的微分等于矩阵微分的迹

矩阵乘积  $\mathbf{UV}$  的微分矩阵

$$d(\mathbf{UV}) = (d\mathbf{U})\mathbf{V} + \mathbf{U}(d\mathbf{V})$$

# 一阶实矩阵微分：Jacobian矩阵辨识

标量函数  $f(\mathbf{x})$ , 变元向量  $\mathbf{x} = [x_1, x_2, \dots, x_m]^T \in R^m$

微分法则的向量形式

$$df(\mathbf{x}) = \frac{\partial f(\mathbf{x})}{\partial x_1} dx_1 + \frac{\partial f(\mathbf{x})}{\partial x_2} dx_2 + \dots + \frac{\partial f(\mathbf{x})}{\partial x_m} dx_m$$

$$= \left[ \frac{\partial f(\mathbf{x})}{\partial x_1}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_m} \right] \begin{bmatrix} dx_1 \\ \vdots \\ dx_m \end{bmatrix}$$

标量函数对向量的导数

$$= \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}^T} d\mathbf{x} = \text{tr}(\mathbf{A} d\mathbf{x})$$

标量函数  $f(\mathbf{X})$ , 变元矩阵  $\mathbf{X} \in R^{m \times n}$

$$df(\mathbf{X}) = \text{tr}(\mathbf{A} d\mathbf{X})$$

**A: Jacobian矩阵**

# 一阶实矩阵微分：Jacobian矩阵辨识

## 标量函数的Jacobian矩阵辨识

$$df(\mathbf{x}) = \text{tr}(\mathbf{A}d\mathbf{x}) \quad \longleftrightarrow \quad D_{\mathbf{x}}f(\mathbf{x}) = \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}^T} = \mathbf{A}$$

$$df(\mathbf{X}) = \text{tr}(\mathbf{A}d\mathbf{X}) \quad \longleftrightarrow \quad D_{\mathbf{X}}f(\mathbf{X}) = \frac{\partial f(\mathbf{X})}{\partial \mathbf{X}^T} = \mathbf{A}$$

$$D_{\mathbf{X}}f(\mathbf{X}) = \frac{\partial f(\mathbf{X})}{\partial \mathbf{X}^T} = \mathbf{A} \quad \longleftrightarrow \quad \nabla_{\mathbf{X}}f(\mathbf{X}) = \mathbf{A}^T$$

习题1：利用矩阵微分证明二次型函数 $f(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x}$  变元向量  $\mathbf{x}$  的梯度向量

$$\nabla_{\mathbf{x}}(\mathbf{x}^T \mathbf{A} \mathbf{x}) = (\mathbf{A}^T + \mathbf{A}) \mathbf{x}$$

习题2：利用Jacobian矩阵辨识，求包含逆矩阵的迹函数  $\text{tr}(\mathbf{A} \mathbf{X}^{-1})$  的梯度矩阵



# 一阶实矩阵微分：Jacobian矩阵辨识

**示例** 已知  $\frac{\partial f}{\partial Y}$  和  $Y = AXB$ , 求  $\frac{\partial f}{\partial X}$ ?

**解**  $df = \text{tr} \left[ \left( \frac{\partial f}{\partial Y} \right)^T dY \right] = \text{tr} \left[ \left( \frac{\partial f}{\partial Y} \right)^T A dX B \right] = \text{tr} \left[ B \left( \frac{\partial f}{\partial Y} \right)^T A dX \right]$

$= \text{tr} \left[ \left( A^T \frac{\partial f}{\partial Y} B^T \right)^T dX \right],$


迹的性质：交换顺序

得  $\frac{\partial f}{\partial X} = A^T \frac{\partial f}{\partial Y} B^T。$

# 一阶实矩阵微分：Jacobian矩阵辨识

**示例** 已知  $f = \mathbf{a}^T \mathbf{X} \mathbf{b}$ , 求  $\frac{\partial f}{\partial \mathbf{X}}$ ?

**解**  $df = d\mathbf{a}^T \mathbf{X} \mathbf{b} + \mathbf{a}^T d\mathbf{X} \mathbf{b} + \mathbf{a}^T \mathbf{X} d\mathbf{b} = \text{tr}[\mathbf{a}^T d\mathbf{X} \mathbf{b}]$


$$0 = \text{tr}[\mathbf{b} \mathbf{a}^T d\mathbf{X}] = \text{tr}[(\mathbf{a} \mathbf{b}^T)^T d\mathbf{X}]$$

得  $\frac{\partial f}{\partial \mathbf{X}} = \mathbf{a} \mathbf{b}^T$ 。

**笔记** 上述两个例子反复应用了  $\text{tr}(\mathbf{A}\mathbf{B}) = \text{tr}(\mathbf{B}\mathbf{A})$   
( $\mathbf{A}\mathbf{B}$  和  $\mathbf{B}\mathbf{A}$  特征值相同)。

# 一阶实矩阵微分：Jacobian矩阵辨识

**示例** 已知  $f = \text{tr}[X^T S X]$  , 求  $\frac{\partial f}{\partial X}$ ?

**解**  $df = \text{tr}[d(X^T) S X] + \text{tr}[X^T S dX] = \text{tr}[(dX)^T S X] + \text{tr}[X^T S dX]$   
 $= \text{tr}[(S X)^T dX] + \text{tr}[X^T S dX] = \text{tr}[2(S X)^T dX]$ , 得  $\frac{\partial f}{\partial X} = 2S X$ 。

**示例** 已知  $f = \|Ax - b\|_2^2$  (实数域) , 求  $\frac{\partial f}{\partial X}$ ?

**解**  $df = d[(Ax - b)^T (Ax - b)] = d(Ax)^T (Ax - b) + (Ax - b)^T A dx$   
 $= (Ax - b)^T A dx + (Ax - b)^T A dx = \text{tr} [2(A^T Ax - A^T b)^T dX]$  ,  
得  $\frac{\partial f}{\partial X} = 2A^T Ax - 2A^T b$ 。

# Hessian矩阵

**定义** 假设有一实值函数  $f(x_1, \dots, x_n)$ ，如果  $f$  的所有二阶偏导数都存在并在定义域内连续，那么函数  $f$  的**海森矩阵** (Hessian matrix) 为

$$H[f(\mathbf{x})] = \frac{\partial^2 f(\mathbf{x})}{\partial \mathbf{x} \partial \mathbf{x}^T} = \frac{\partial}{\partial \mathbf{x}} \left[ \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}^T} \right] \in \mathbb{R}^{m \times m}$$

显然海森矩阵是一个对称矩阵

$$H[f(\mathbf{x})] = \nabla_x^2 f(\mathbf{x}) = \nabla_x (D_x f(\mathbf{x})) \quad [Hf(\mathbf{x})]_{i,j} = \left[ \frac{\partial^2 f(\mathbf{x})}{\partial \mathbf{x} \partial \mathbf{x}^T} \right]_{i,j} = \frac{\partial}{\partial x_i} \left[ \frac{\partial f(\mathbf{x})}{\partial x_j} \right]$$

$$H[f(\mathbf{x})] = \frac{\partial^2 f(\mathbf{x})}{\partial \mathbf{x} \partial \mathbf{x}^T} = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1 \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_m} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_m \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_m \partial x_m} \end{bmatrix} \in \mathbb{R}^{m \times m}$$

**示例**  $f = x^2 - y^2$ ,  $H_f = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix}$ 。

# 第三章习题

---

见学在浙大  
作业版块  
Homework2

10.13 交