



《矩阵论》习题解答

民间版

作者：杨志豪、徐若彭、张卓雨

组织：浙江大学信息与电子工程学院

时间：November, 2023

版本：1.0



浙江大学信息与电子工程学院

“考前勤奋，考后乐观。”

目录

第 1 次 作业	1
第 2 次 作业	8
第 3 次 作业	13
第 4 次 作业	16
第 5 次 作业	22

第一次 作业

1.8 利用初等行变换求解线性方程组

$$2x_1 - 4x_2 + 3x_3 - 4x_4 - 11x_5 = 28$$

$$-x_1 + 2x_2 - x_3 + 2x_4 + 5x_5 = -13$$

$$-3x_3 + 2x_4 + 5x_5 = -10$$

$$3x_1 - 5x_2 + 10x_3 - 7x_4 + 12x_5 = 31$$

解 根据原方程得增广矩阵

$$\begin{bmatrix} 2 & -4 & 3 & -4 & -11 & 28 \\ -1 & 2 & -1 & 2 & 5 & -13 \\ 0 & 0 & -3 & 2 & 5 & -10 \\ 3 & -5 & 10 & -7 & 12 & 31 \end{bmatrix}$$

利用初等行变换进行化简

(a) $r_1 + 2r_2 \rightarrow r_1, r_4 + 3r_2 \rightarrow r_4$

$$\begin{bmatrix} 0 & 0 & 1 & 0 & -1 & 2 \\ -1 & 2 & -1 & 2 & 5 & -13 \\ 0 & 0 & -3 & 2 & 5 & -10 \\ 0 & 1 & 7 & -1 & 27 & -8 \end{bmatrix}$$

(b) $r_2 - 2r_4 \rightarrow r_2$

$$\begin{bmatrix} 0 & 0 & 1 & 0 & -1 & 2 \\ -1 & 0 & -15 & 4 & -49 & 3 \\ 0 & 0 & -3 & 2 & 5 & -10 \\ 0 & 1 & 7 & -1 & 27 & -8 \end{bmatrix}$$

(c) $r_2 + 15r_1 \rightarrow r_2, r_3 + 3r_1 \rightarrow r_3, r_4 - 7r_1 \rightarrow r_4$

$$\begin{bmatrix} 0 & 0 & 1 & 0 & -1 & 2 \\ -1 & 0 & 0 & 4 & -64 & 33 \\ 0 & 0 & 0 & 2 & 2 & -4 \\ 0 & 1 & 0 & -1 & 34 & -22 \end{bmatrix}$$

(d) $\frac{1}{2} \times r_3 \rightarrow r_3$

$$\begin{bmatrix} 0 & 0 & 1 & 0 & -1 & 2 \\ -1 & 0 & 0 & 4 & -64 & 33 \\ 0 & 0 & 0 & 1 & 1 & -2 \\ 0 & 1 & 0 & -1 & 34 & -22 \end{bmatrix}$$

(e) $-r_2 \rightarrow r_2, r_2 + 4r_3 \rightarrow r_2, r_4 + r_3 \rightarrow r_4$

$$\begin{bmatrix} 0 & 0 & 1 & 0 & -1 & 2 \\ 1 & 0 & 0 & 0 & 68 & -41 \\ 0 & 0 & 0 & 1 & 1 & -2 \\ 0 & 1 & 0 & 0 & 35 & -24 \end{bmatrix}$$

(f) $r_1 \leftrightarrow r_2, r_2 \leftrightarrow r_4, r_3 \leftrightarrow r_4$

$$\begin{bmatrix} 1 & 0 & 0 & 0 & 68 & -41 \\ 0 & 1 & 0 & 0 & 35 & -24 \\ 0 & 0 & 1 & 0 & -1 & 2 \\ 0 & 0 & 0 & 1 & 1 & -2 \end{bmatrix}$$

方程组有特解 $[27, 11, 1, -1, -1]^T$ ，对应齐次方程组通解为 $[68, 35, -1, 1, -1]^T$ 。方程组的解为

$$\mathbf{x} = k \begin{bmatrix} 68 \\ 35 \\ -1 \\ 1 \\ -1 \end{bmatrix} + \begin{bmatrix} 27 \\ 11 \\ 1 \\ -1 \\ -1 \end{bmatrix}, \quad \forall k \in \mathbb{R}$$

1.12 证明自协方差矩阵和互协方差的下列性质：

(1) $\text{Var}(\mathbf{Ax} + \mathbf{b}) = \mathbf{A}\text{Var}(\mathbf{x})\mathbf{A}^H$ ，其中 \mathbf{A} 和 \mathbf{b} 分别为常数矩阵和常数向量。

(2) $\text{Cov}(\mathbf{x}, \mathbf{y}) = [\text{Cov}(\mathbf{y}, \mathbf{x})]^H$ 。

(3) $\text{Cov}(\mathbf{Ax}, \mathbf{By}) = \mathbf{A}\text{Cov}(\mathbf{x}, \mathbf{y})\mathbf{B}^H$ 。

证明

(1)

$$\begin{aligned} \mathbf{E}(\mathbf{Ax} + \mathbf{b}) &= \mathbf{A}\mathbf{E}(\mathbf{x}) + \mathbf{b} \triangleq \boldsymbol{\mu}_x \\ \text{Var}(\mathbf{Ax} + \mathbf{b}) &= \mathbf{E}\left\{[\mathbf{Ax} + \mathbf{b} - \boldsymbol{\mu}_x][\mathbf{Ax} + \mathbf{b} - \boldsymbol{\mu}_x]^H\right\} \\ &= \mathbf{E}\left\{[\mathbf{A}[\mathbf{x} - \mathbf{E}(\mathbf{x})]][\mathbf{A}[\mathbf{x} - \mathbf{E}(\mathbf{x})]]^H\right\} \\ &= \mathbf{A}\mathbf{E}\left\{[\mathbf{x} - \mathbf{E}(\mathbf{x})][\mathbf{x} - \mathbf{E}(\mathbf{x})]^H\right\}\mathbf{A}^H \\ &= \mathbf{A}\text{Var}(\mathbf{x})\mathbf{A}^H \end{aligned}$$

(2)

$$\begin{aligned} \text{Cov}(\mathbf{x}, \mathbf{y}) &= \mathbf{E}\left\{[\mathbf{x} - \mathbf{E}(\mathbf{x})][\mathbf{y} - \mathbf{E}(\mathbf{y})]^H\right\} \\ &= \left\{\mathbf{E}\left\{[\mathbf{x} - \mathbf{E}(\mathbf{x})][\mathbf{y} - \mathbf{E}(\mathbf{y})]^H\right\}^H\right\}^H \\ &= \left\{\mathbf{E}\left\{[\mathbf{y} - \mathbf{E}(\mathbf{y})][\mathbf{x} - \mathbf{E}(\mathbf{x})]^H\right\}\right\}^H \\ &= [\text{Cov}(\mathbf{y}, \mathbf{x})]^H \end{aligned}$$

(3)

$$\begin{aligned} \text{Cov}(\mathbf{Ax}, \mathbf{By}) &= \mathbf{E}\left\{[\mathbf{Ax} - \mathbf{E}(\mathbf{Ax})][\mathbf{By} - \mathbf{E}(\mathbf{By})]^H\right\} \\ &= \mathbf{E}\left\{[\mathbf{A}[\mathbf{x} - \mathbf{E}(\mathbf{x})]][\mathbf{B}[\mathbf{y} - \mathbf{E}(\mathbf{y})]]^H\mathbf{B}^H\right\} \\ &= \mathbf{A}\mathbf{E}\left\{[\mathbf{x} - \mathbf{E}(\mathbf{x})][\mathbf{y} - \mathbf{E}(\mathbf{y})]^H\right\}\mathbf{B}^H \\ &= \mathbf{A}\text{Cov}(\mathbf{x}, \mathbf{y})\mathbf{B}^H \end{aligned}$$

1.17 矩阵的秩在工程控制系统的设计中起着重要的作用。一个离散时间的控制系统的状态空间模型包括了差分方程

$$\mathbf{x}_{k+1} = \mathbf{Ax}_k + \mathbf{Bu}_k, \quad k = 0, 1, \dots$$

式中, $A \in \mathbb{R}^{n \times n}$, $B \in \mathbb{R}^{n \times m}$, 并且 $x_k \in \mathbb{R}^n$ 为描述系统 k 时刻状态的变量, 简称状态向量; 而 u_k 为系统在 k 时刻的输入或控制向量。矩阵对 (A, B) 称为可控的, 若

$$\text{rank}([B, AB, A^2B, \dots, A^{n-1}B]) = n$$

若 (A, B) 是可控的, 则最多用 n 步即可将系统控制到任意一个指定的状态 x , 试确定以下矩阵对是否可控:

$$(1) \quad A = \begin{bmatrix} 0.9 & 1 & 0 \\ 0 & -0.9 & 0 \\ 0 & 0 & 0.5 \end{bmatrix}, \quad B = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}$$

$$(2) \quad A = \begin{bmatrix} 0.8 & -0.3 & 0 \\ 0.2 & 0.5 & 1 \\ 0 & 0 & -0.5 \end{bmatrix}, \quad B = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}$$

解 矩阵为三阶矩阵, 所以 $n = 3$

(1)

$$[B, AB, A^2B] = \begin{bmatrix} 0 & 1 & 0 \\ 1 & -0.9 & 0.81 \\ 1 & 0.5 & 0.25 \end{bmatrix}$$

其秩为 3, 所以矩阵对 (A, B) 是可控的。

(2)

$$[B, AB, A^2B] = \begin{bmatrix} 1 & 0.5 & 0.19 \\ 1 & 0.7 & 0.45 \\ 0 & 0 & 0 \end{bmatrix}$$

其秩为 2, 所以矩阵对 (A, B) 是不可控的。

1.19 令正方矩阵 A 和 B 有同样的维数, 证明 $\text{tr}(AB) = \text{tr}(BA)$

证明 设矩阵维数为 n , 有

$$\begin{aligned} (AB)_{ii} &= \sum_{j=1}^n a_{ij} b_{ji} \\ \text{tr}(AB) &= \sum_{i=1}^n (AB)_{ii} = \sum_{i=1}^n \sum_{j=1}^n a_{ij} b_{ji} = \sum_{i=1}^n \sum_{j=1}^n b_{ij} a_{ji} \\ \text{tr}(AB) &= \text{tr}(BA) \end{aligned}$$

1.37 当 α 取何值时, 线性方程组

$$(\alpha + 3)x_1 + x_2 + 2x_3 = \alpha$$

$$3(\alpha + 1)x_1 + \alpha x_2 + (\alpha + 3)x_3 = 3$$

$$\alpha x_1 + (\alpha - 1)x_2 + x_3 = \alpha$$

有唯一解、无解和无穷多解。当方程组有无穷多解时, 求出它的通解。

解 增广矩阵

$$\begin{bmatrix} \alpha+3 & 1 & 2 & \alpha \\ 3(\alpha+1) & \alpha & \alpha+3 & 3 \\ \alpha & \alpha-1 & 1 & \alpha \end{bmatrix} \xrightarrow{\text{初等行变换}} \begin{bmatrix} 1 & \frac{2-\alpha}{3} & \frac{1}{3} & 0 \\ 0 & \alpha-(2-\alpha)(\alpha+1) & 2 & 3 \\ 0 & \alpha-1-\frac{\alpha(2-\alpha)}{3} & 1-\frac{\alpha}{3} & \alpha \end{bmatrix}$$

(1) 方程组有唯一解, 要求系数矩阵可逆, 行列式 $\neq 0$

$$[\alpha-(2-\alpha)(\alpha+1)](1-\frac{\alpha}{3})-2[\alpha-1-\frac{\alpha(2-\alpha)}{3}]=\frac{1}{3}(\alpha^2-\alpha^3)\neq 0$$

则 $\alpha \neq 0$ 且 $\alpha \neq 1$ 时, 方程组有唯一解。(2) 方程组无解, 要求系数矩阵不可逆, 行列式 $= 0$

$$[\alpha-(2-\alpha)(\alpha+1)](1-\frac{\alpha}{3})-2[\alpha-1-\frac{\alpha(2-\alpha)}{3}]=\frac{1}{3}(\alpha^2-\alpha^3)=0$$

要求方程为非一致性方程, 系数矩阵后两行比例与向量 $\begin{bmatrix} 0 & 3 & \alpha \end{bmatrix}^T$ 后两个元素所成比例不同, 则 $\alpha = 0$ (3) 方程组有无穷多解, 要求系数矩阵不可逆, 行列式 $= 0$

$$[\alpha-(2-\alpha)(\alpha+1)](1-\frac{\alpha}{3})-2[\alpha-1-\frac{\alpha(2-\alpha)}{3}]=\frac{1}{3}(\alpha^2-\alpha^3)=0$$

且方程为一致性方程, 则 $\alpha = 1$ 。此时方程的通解为 $x_2 = 2x_3 - 3, x_1 = 1 - x_3$ 。

1.42 已知向量组

$$\mathbf{a}_1 = \begin{bmatrix} a \\ 2 \\ 10 \end{bmatrix}, \quad \mathbf{a}_2 = \begin{bmatrix} -2 \\ 1 \\ 5 \end{bmatrix}, \quad \mathbf{a}_3 = \begin{bmatrix} -1 \\ 1 \\ 4 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ b \\ c \end{bmatrix}$$

试分别求出满足以下条件的 a, b, c 值:

- (1) \mathbf{b} 可由 $\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3$ 线性表示, 且唯一。
- (2) \mathbf{b} 不能由 $\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3$ 线性表示。
- (3) \mathbf{b} 可由 $\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3$ 线性表示, 但表示不唯一。并求出一般表达式。

解 令 $\mathbf{A} = [\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3]$ (1) 该问题等价于求 a, b, c 为何值时, $\mathbf{Ax} = \mathbf{b}$ 有唯一解

$$\text{增广矩阵: } \begin{bmatrix} a & -2 & -1 & 1 \\ 2 & 1 & 1 & b \\ 10 & 5 & 4 & c \end{bmatrix} \xrightarrow{\text{初等行变换}} \begin{bmatrix} a & -2 & -1 & 1 \\ 2+a & -1 & 0 & b+1 \\ 4+a & 0 & 0 & c-3b+1 \end{bmatrix}$$

 $\mathbf{Ax} = \mathbf{b}$ 有唯一解, 系数矩阵 \mathbf{A} 与增广矩阵秩相同, 且等于未知数个数。则 $a \neq -4$ 时, 方程组有唯一解

$$\mathbf{x} = \left[\frac{c-3b+1}{4+a}, \frac{2c+ac-10b-4ab-2}{4+a}, \frac{-ac+5ab-4c+20b}{4+a} \right]^T$$

(2) 当 $a = -4$, 且 $c \neq 3b - 1$ 时, 方程组无解

(3) 当 $a = -4$, 且 $c = 3b - 1$ 时, 方程组无穷多解, 设 x_1 为自由量, 有

$$x_1 = x_1$$

$$x_2 = -2x_1 - (b + 1)$$

$$x_3 = 2b + 1$$

基础解系 $\xi = [1, -2, 0]^T$, 特解 $\xi_0 = [0, -b - 1, 2b + 1]^T$, 方程组有无穷多解 $x = k\xi + \xi_0, \forall k \in \mathbb{R}$

1.73 已知 $AB = BA = O$ (零矩阵) 和 $\text{rank}(A^2) = \text{rank}(A)$, 证明

(1) $\text{rank}(A + B) = \text{rank}(A) + \text{rank}(B)$ 。

(2) $\text{rank}(A^k + B^k) = \text{rank}(A^k) + \text{rank}(B^k)$, 其中 k 是某个整数。

证明

(1) 首先对矩阵 A 进行 Jordan 标准型分解

$$A = S \begin{bmatrix} J_{n_1}(\lambda_1) & & 0 \\ & J_{n_2}(\lambda_2) & \\ & & \ddots \\ 0 & & & J_{n_k}(\lambda_k) \end{bmatrix} S^{-1} = S \Sigma S^{-1}$$

其中 S 为可逆矩阵

$$J_{n_k}(\lambda_k) = \begin{bmatrix} \lambda_k & 1 & & 0 \\ & \lambda_k & 1 & \\ & & \ddots & \ddots \\ 0 & & & \ddots & 1 \\ & & & & \lambda_k \end{bmatrix}$$

据此可以得到

$$A^2 = S \begin{bmatrix} J_{n_1}^2(\lambda_1) & & 0 \\ & J_{n_2}^2(\lambda_2) & \\ & & \ddots \\ 0 & & & J_{n_k}^2(\lambda_k) \end{bmatrix} S^{-1} = S \Sigma^2 S^{-1}$$

从上面可以看出, 经过 Jordan 标准型分解以后, A 和 A^2 的秩实际上由 Σ 和 Σ^2 决定。因为已知 $\text{rank}(A^2) = \text{rank}(A)$, 所以可以断定: 矩阵 A 中一定不存在下面形式的 Jordan 块

$$J = \begin{bmatrix} 0 & 1 & & 0 \\ & 0 & 1 & \\ & & \ddots & \ddots \\ 0 & & & \ddots & 1 \\ & & & & 0 \end{bmatrix}$$

否则, Σ^2 的秩将小于 Σ 的秩, A^2 的秩将小于 A 的秩。也就是说, 矩阵 A 的 0 特征值对应的 Jordan 块一定是一阶的。

若定义 $C = S^{-1}BS$, 则易知

$$AB = O \Leftrightarrow S\Sigma C = O \Leftrightarrow \Sigma C = O$$

若将 C 按行分块, 则与 Σ 的各个 Jordan 块的维数相对应, 即

$$C = \begin{bmatrix} C_1 & C_2 & \cdots & C_{n_k} \end{bmatrix}^T$$

由 $\Sigma C = O$ 可知, C 矩阵与 Σ 非零 Jordan 块对应的行一定为零。

同理, 由于 $BA = O$, 则 C 矩阵与 Σ 非零 Jordan 块对应的列也一定为零。有

$$\text{rank}(\Sigma + C) = \text{rank}(\Sigma) + \text{rank}(C)$$

矩阵左乘 S 右乘 S^{-1} 不影响矩阵的秩, 有

$$\text{rank}(A + B) = \text{rank}(\Sigma + C) = \text{rank}(\Sigma) + \text{rank}(C) = \text{rank}(A) + \text{rank}(B)$$

(2) 因为已知 $\text{rank}(A^2) = \text{rank}(A)$, 所以有

$$\text{rank}(A^{2k}) = \text{rank}(A^k)$$

因为 $AB = BA = O$, 所以

$$A^k B^k = B^k A^k = O$$

由 (1) 结论可得, $\text{rank}(A^k + B^k) = \text{rank}(A^k) + \text{rank}(B^k)$

1.81 证明逆矩阵的以下性质:

(1) 逆矩阵的行列式等于原矩阵行列式的倒数, 即 $|A^{-1}| = \frac{1}{|A|}$

(2) 逆矩阵是非奇异的。

(3) $(A^{-1})^{-1} = A$ 。

(4) 复共轭转置矩阵的逆矩阵 $(A^H)^{-1} = (A^{-1})^H = A^{-H}$ 。

(5) 若 $A^H = A$, 则 $(A^{-1})^H = A^{-1}$ 。

(6) $(A^*)^{-1} = (A^{-1})^*$ 。

证明

(1)

$$AA^{-1} = I, \quad |A||A^{-1}| = 1$$

$$|A^{-1}| = \frac{1}{|A|}$$

(2)

$$\because |A||A^{-1}| = 1, \quad \therefore |A^{-1}| \neq 0$$

即逆矩阵非奇异

(3)

$$(A^{-1})^{-1}A^{-1} = (AA^{-1})^{-1} = I$$

$$A^{-1}(A^{-1})^{-1} = (A^{-1}A)^{-1} = I$$

$$\therefore (A^{-1})^{-1} = A$$

(4)

$$(A^H)^{-1}A^H = I, \quad AA^{-1} = I$$

$$(AA^{-1})^H = (A^{-1})^HA^H = I^H = I$$

$$\text{同理 } A^H(A^{-1})^H = I$$

$$\therefore (A^H)^{-1} = (A^{-1})^H = A^{-H}$$

(5)

由 (4) 可知 $(A^{-1})^H = (A^H)^{-1}$

$$\therefore A^H = A$$

$$\therefore (A^{-1})^H = (A^H)^{-1} = A^{-1}$$

(6)

$$|A|A^{-1} = A^*, \quad A^{-1} = \frac{A^*}{|A|}$$

$$(A^{-1})^* = \left(\frac{A^*}{|A|}\right)^* = \frac{(A^*)^*}{|A|^{n-1}} = \frac{A}{|A|}$$

$$(A^*)^{-1} = \frac{A}{|A|}$$

$$\therefore (A^*)^{-1} = (A^{-1})^*$$

1.103 设 A 是 Hermitian 矩阵, 并且 M 是 A 的 Moore-Penrose 逆矩阵. 证明: 矩阵 M^2 是 A^2 的 Moore-Penrose 逆矩阵

解 由 Moore-Penrose 逆矩阵定义已知

$$AMA = A, MAM = M, (AM)^H = AM, (MA)^H = MA$$

(1)

$$\begin{aligned} A^2 M^2 A^2 &= AAMMAA = A(AM)^H(MA)^H A = AM^H A^H A^H M^H A \\ &= AM^H A^H A^H M^H A = AM^H AAM^H A \\ &= (AM^H A)^2 = [(AMA)^H]^2 = (A^H)^2 \\ &= A^2 \end{aligned}$$

(2)

$$\begin{aligned} M^2 A^2 M^2 &= MMAAMM = M(MA)^H AMM = MA^H M^H AMM \\ &= MA^H M^H A^H MM = MA^H MM = MAMM \\ &= M^2 \end{aligned}$$

(3)

$$\begin{aligned} (M^2 A^2)^H &= A^H A^H M^H M^H = A^H (MA)^H M^H = A^H MAM^H \\ &= AMAM^H = AM^H = (MA)^H = MA \\ M^2 A^2 &= MMAA = M(MA)^H A = MA^H M^H A = MA^H M^H A^H \\ &= M(AMA)^H = MA^H = MA \\ M^2 A^2 &= (M^2 A^2)^H \end{aligned}$$

(4)

$$\begin{aligned} (A^2 M^2)^H &= M^H M^H A^H A^H = M^H (AM)^H A^H \\ &= M^H AMA = M^H A = (AM)^H = AM \\ A^2 M^2 &= AAMM = A(AM)^H M = AM^H A^H M \\ &= (AMA)^H M = AM \\ (A^2 M^2)^H &= A^2 M^2 \end{aligned}$$

第二次 作业

课外习题：设 \mathbf{X} 为 $n \times n$ 维矩阵变量，分别求 $\text{tr}(\mathbf{X})$ 和 $\det(\mathbf{X})$ 的梯度矩阵解

(1).1

$$\text{dtr}(\mathbf{X}) = \text{tr}(\text{d}\mathbf{X})$$

$$\text{D}_{\mathbf{X}} \text{tr}(\mathbf{X}) = \mathbf{I}_n$$

$$\nabla_{\mathbf{X}} \text{tr}(\mathbf{X}) = \mathbf{I}_n^T = \mathbf{I}_n$$

(1).2

$$\begin{aligned} \nabla_{\mathbf{X}} \text{tr}(\mathbf{X}) &= \nabla_{\mathbf{X}} \left(\sum_{i=1}^n x_{ii} \right) = \begin{bmatrix} \frac{\partial \sum_{i=1}^n x_{ii}}{\partial x_{11}} & \frac{\partial \sum_{i=1}^n x_{ii}}{\partial x_{12}} & \cdots & \frac{\partial \sum_{i=1}^n x_{ii}}{\partial x_{1n}} \\ \frac{\partial \sum_{i=1}^n x_{ii}}{\partial x_{21}} & \frac{\partial \sum_{i=1}^n x_{ii}}{\partial x_{22}} & \cdots & \frac{\partial \sum_{i=1}^n x_{ii}}{\partial x_{2n}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial \sum_{i=1}^n x_{ii}}{\partial x_{n1}} & \frac{\partial \sum_{i=1}^n x_{ii}}{\partial x_{n2}} & \cdots & \frac{\partial \sum_{i=1}^n x_{ii}}{\partial x_{nn}} \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix}_{n \times n} \\ &= \mathbf{I}_n \end{aligned}$$

(2).1 若 \mathbf{X} 可逆

$$\text{d}|\mathbf{X}| = |\mathbf{X}| \text{tr}(\mathbf{X}^{-1} \text{d}\mathbf{X})$$

$$\text{D}_{\mathbf{X}} |\mathbf{X}| = |\mathbf{X}| \mathbf{X}^{-1}$$

$$\nabla_{\mathbf{X}} |\mathbf{X}| = |\mathbf{X}| \mathbf{X}^{-T}$$

(2).2 若 \mathbf{X} 可逆

由 Laplace 定理得矩阵 \mathbf{X} 的行列式可通过如下方式计算：

$$\det(\mathbf{X}) = \sum_{i=1}^n (-1)^{i+j} x_{ij} M_{ij}$$

其中 M_{ij} 是 \mathbf{X} 在 (i, j) 处的余子式。因此有

$$\begin{aligned} \nabla_{\mathbf{X}} \det(\mathbf{X}) &= \nabla_{\mathbf{X}} \left[\sum_{i=1}^n (-1)^{i+j} x_{ij} M_{ij} \right] \\ &= \begin{bmatrix} \frac{\partial \sum_{i=1}^n (-1)^{i+j} x_{ij} M_{ij}}{\partial x_{11}} & \frac{\partial \sum_{i=1}^n (-1)^{i+j} x_{ij} M_{ij}}{\partial x_{12}} & \cdots & \frac{\partial \sum_{i=1}^n (-1)^{i+j} x_{ij} M_{ij}}{\partial x_{1n}} \\ \frac{\partial \sum_{i=1}^n (-1)^{i+j} x_{ij} M_{ij}}{\partial x_{21}} & \frac{\partial \sum_{i=1}^n (-1)^{i+j} x_{ij} M_{ij}}{\partial x_{22}} & \cdots & \frac{\partial \sum_{i=1}^n (-1)^{i+j} x_{ij} M_{ij}}{\partial x_{2n}} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial \sum_{i=1}^n (-1)^{i+j} x_{ij} M_{ij}}{\partial x_{n1}} & \frac{\partial \sum_{i=1}^n (-1)^{i+j} x_{ij} M_{ij}}{\partial x_{n2}} & \cdots & \frac{\partial \sum_{i=1}^n (-1)^{i+j} x_{ij} M_{ij}}{\partial x_{nn}} \end{bmatrix} \\ &= [(-1)^{i+j} M_{ij}]_{n \times n} = (\mathbf{X}_{ij})_{n \times n} \\ &= (\mathbf{X}^*)^T = \det(\mathbf{X}) (\mathbf{X}^{-1})^T \end{aligned}$$

其中 \mathbf{X}^* 为 \mathbf{X} 的伴随矩阵。

若 \mathbf{X} 不可逆, $\nabla_{\mathbf{X}}|\mathbf{X}| = \mathbf{O}$

3.2 证明: 若 $\phi(\mathbf{x}) = (\mathbf{f}(\mathbf{x}))^T \mathbf{A} \mathbf{g}(\mathbf{x})$, 则

$$\mathbf{D}_{\mathbf{x}}\phi(\mathbf{x}) = (\mathbf{g}(\mathbf{x}))^T \mathbf{A}^T \mathbf{D}_{\mathbf{x}}\mathbf{f}(\mathbf{x}) + (\mathbf{f}(\mathbf{x}))^T \mathbf{A} \mathbf{D}_{\mathbf{x}}\mathbf{g}(\mathbf{x})$$

证明

1.

$$\begin{aligned} d\phi(\mathbf{x}) &= d(\mathbf{f}(\mathbf{x})^T \mathbf{A} \mathbf{g}(\mathbf{x})) \\ &= d(\mathbf{f}(\mathbf{x})^T) \mathbf{A} \mathbf{g}(\mathbf{x}) + \mathbf{f}(\mathbf{x})^T \mathbf{A} d\mathbf{g}(\mathbf{x}) \\ &= d\mathbf{x}^T \frac{\partial \mathbf{f}(\mathbf{x})}{\partial \mathbf{x}} \mathbf{A} \mathbf{g}(\mathbf{x}) + \mathbf{f}(\mathbf{x})^T \mathbf{A} \frac{\partial \mathbf{g}(\mathbf{x})}{\partial \mathbf{x}^T} d\mathbf{x} \\ &= \text{tr}(d\mathbf{x}^T \frac{\partial \mathbf{f}(\mathbf{x})}{\partial \mathbf{x}} \mathbf{A} \mathbf{g}(\mathbf{x}) + \mathbf{f}(\mathbf{x})^T \mathbf{A} \frac{\partial \mathbf{g}(\mathbf{x})}{\partial \mathbf{x}^T} d\mathbf{x}) \\ &= \text{tr}(\mathbf{g}(\mathbf{x})^T \mathbf{A}^T \frac{\partial \mathbf{f}(\mathbf{x})}{\partial \mathbf{x}^T} d\mathbf{x} + \mathbf{f}(\mathbf{x})^T \mathbf{A} \frac{\partial \mathbf{g}(\mathbf{x})}{\partial \mathbf{x}^T} d\mathbf{x}) \\ &= \text{tr}([\mathbf{g}(\mathbf{x})^T \mathbf{A}^T \mathbf{D}_{\mathbf{x}}\mathbf{f}(\mathbf{x}) + \mathbf{f}(\mathbf{x})^T \mathbf{A} \mathbf{D}_{\mathbf{x}}\mathbf{g}(\mathbf{x})] d\mathbf{x}) \\ \mathbf{D}_{\mathbf{x}}\phi(\mathbf{x}) &= (\mathbf{g}(\mathbf{x}))^T \mathbf{A}^T \mathbf{D}_{\mathbf{x}}\mathbf{f}(\mathbf{x}) + (\mathbf{f}(\mathbf{x}))^T \mathbf{A} \mathbf{D}_{\mathbf{x}}\mathbf{g}(\mathbf{x}) \end{aligned}$$

2.

记

$$\begin{aligned} \mathbf{f}(\mathbf{x}) &= [f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_m(\mathbf{x})]^T \\ \mathbf{g}(\mathbf{x}) &= [g_1(\mathbf{x}), g_2(\mathbf{x}), \dots, g_n(\mathbf{x})]^T \\ \mathbf{A} = (a_{ij})_{m \times n} &= \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} \end{aligned}$$

则可以将 $\phi(\mathbf{x})$ 写成标量的形式:

$$\phi(\mathbf{x}) = (\mathbf{f}(\mathbf{x}))^T \mathbf{A} \mathbf{g}(\mathbf{x}) = \sum_{i=1}^m \sum_{j=1}^n f_i(\mathbf{x}) a_{ij} g_j(\mathbf{x})$$

因此有

$$\begin{aligned} \mathbf{D}_{\mathbf{x}}\phi(\mathbf{x}) &= \mathbf{D}_{\mathbf{x}} \sum_{i=1}^m \sum_{j=1}^n f_i(\mathbf{x}) a_{ij} g_j(\mathbf{x}) \\ &= \sum_{i=1}^m \sum_{j=1}^n \mathbf{D}_{\mathbf{x}} f_i(\mathbf{x}) a_{ij} g_j(\mathbf{x}) \\ &= \sum_{i=1}^m \sum_{j=1}^n a_{ij} [(\mathbf{D}_{\mathbf{x}} f_i(\mathbf{x})) g_j(\mathbf{x}) + f_i(\mathbf{x}) (\mathbf{D}_{\mathbf{x}} g_j(\mathbf{x}))] \\ &= \sum_{i=1}^m \mathbf{D}_{\mathbf{x}} f_i(\mathbf{x}) \sum_{j=1}^n a_{ij} g_j(\mathbf{x}) + \sum_{i=1}^m f_i(\mathbf{x}) \sum_{j=1}^n a_{ij} \mathbf{D}_{\mathbf{x}} g_j(\mathbf{x}) \\ &= (\mathbf{g}(\mathbf{x}))^T \mathbf{A}^T \mathbf{D}_{\mathbf{x}}\mathbf{f}(\mathbf{x}) + (\mathbf{f}(\mathbf{x}))^T \mathbf{A} \mathbf{D}_{\mathbf{x}}\mathbf{g}(\mathbf{x}) \end{aligned}$$

3.7 证明

$$d[\operatorname{tr}(\mathbf{X}^T \mathbf{X})] = 2\operatorname{tr}(\mathbf{X}^T d\mathbf{X})$$

证明

$$\begin{aligned} d[\operatorname{tr}(\mathbf{X}^T \mathbf{X})] &= \operatorname{tr}[d(\mathbf{X}^T \mathbf{X})] \\ &= \operatorname{tr}[d(\mathbf{X}^T) \mathbf{X} + \mathbf{X}^T d\mathbf{X}] \\ &= \operatorname{tr}[d(\mathbf{X}^T) \mathbf{X}] + \operatorname{tr}(\mathbf{X}^T d\mathbf{X}) \\ &= \operatorname{tr}(\mathbf{X}^T d\mathbf{X}) + \operatorname{tr}(\mathbf{X}^T d\mathbf{X}) \\ &= 2\operatorname{tr}(\mathbf{X}^T d\mathbf{X}) \end{aligned}$$

3.11 求实标量函数 $f(\mathbf{x}) = \mathbf{a}^T \mathbf{x}$ 和 $f(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x}$ 的 Hessian 矩阵。

解

(1)

$$\mathbf{H}[f(\mathbf{x})] = \frac{\partial}{\partial \mathbf{x}^T} \left(\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} \right) = \frac{\partial \mathbf{a}}{\partial \mathbf{x}^T} = \mathbf{O}$$

(2)

$$\mathbf{H}[f(\mathbf{x})] = \frac{\partial}{\partial \mathbf{x}^T} \left(\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} \right) = \frac{\partial}{\partial \mathbf{x}^T} (\mathbf{A} \mathbf{x} + \mathbf{A}^T \mathbf{x}) = \mathbf{A}^T + \mathbf{A}$$

3.14 求矩阵函数 $\mathbf{A} \mathbf{X} \mathbf{B}$ 和 $\mathbf{A} \mathbf{X}^{-1} \mathbf{B}$ 的 Jacobian 矩阵。

解

(1)

$$d(\mathbf{A} \mathbf{X} \mathbf{B}) = \mathbf{A} d(\mathbf{X}) \mathbf{B}$$

已知

$$d\mathbf{F}(\mathbf{X}) = \mathbf{A} (d\mathbf{X}) \mathbf{B} \Leftrightarrow d(\operatorname{vec} \mathbf{F}(\mathbf{X})) = (\mathbf{B}^T \otimes \mathbf{A}) d(\operatorname{vec} \mathbf{X})$$

则

$$\mathbf{D}(\mathbf{A} \mathbf{X} \mathbf{B}) = \mathbf{B}^T \otimes \mathbf{A}$$

(2)

$$d(\mathbf{A} \mathbf{X}^{-1} \mathbf{B}) = \mathbf{A} d(\mathbf{X}^{-1}) \mathbf{B} = -\mathbf{A} \mathbf{X}^{-1} d(\mathbf{X}) \mathbf{X}^{-1} \mathbf{B}$$

已知

$$d\mathbf{F}(\mathbf{X}) = \mathbf{A} (d\mathbf{X}) \mathbf{B} \Leftrightarrow d(\operatorname{vec} \mathbf{F}(\mathbf{X})) = (\mathbf{B}^T \otimes \mathbf{A}) d(\operatorname{vec} \mathbf{X})$$

则

$$\mathbf{D}(\mathbf{A} \mathbf{X}^{-1} \mathbf{B}) = -(\mathbf{X}^{-1} \mathbf{B})^T \otimes \mathbf{A} \mathbf{X}^{-1}$$

3.23 求下列实值函数的 Hessian 矩阵：

(1) $(\mathbf{A} \mathbf{x} + \mathbf{b})^T (\mathbf{D} \mathbf{x} + \mathbf{e})$ 。

(2) $(\mathbf{A} \mathbf{x} + \mathbf{b})^T \mathbf{C} (\mathbf{D} \mathbf{x} + \mathbf{e})$ 。

(3) $(Ax + b)^T C (Ax + b)$ 。

解

1.

(1) 设 $f(x) = (Ax + b)^T (Dx + e)$

$$f(x) = x^T A^T Dx + b^T Dx + x^T A^T e + b^T e$$

$$\frac{\partial f(x)}{\partial x^T} = x^T (D^T A + A^T D) + b^T D + e^T A$$

$$H[f(x)] = \frac{\partial^2 f(x)}{\partial x \partial x^T} = A^T D + D^T A$$

(2) 设 $f(x) = (Ax + b)^T C (Dx + e)$

$$f(x) = x^T A^T C Dx + b^T C Dx + x^T A^T C e + b^T C e$$

$$\frac{\partial f(x)}{\partial x^T} = x^T (D^T C^T A + A^T C D) + b^T C D + e^T C^T A$$

$$H[f(x)] = \frac{\partial^2 f(x)}{\partial x \partial x^T} = A^T C D + D^T C^T A$$

(3) 设 $f(x) = (Ax + b)^T C (Ax + b)$

由 (2) 可得

$$H[f(x)] = A^T (C + C^T) A$$

2.

(1) 先求一阶微分:

$$\begin{aligned} d(Ax + b)^T (Dx + e) &= (Ax + b)^T d(Dx + e) + d(Ax + b)^T (Dx + e) \\ &= (x^T A^T + b^T) D dx + (dx^T) A^T (Dx + e) \\ &= x^T A^T D dx + b^T D dx + (dx^T) A^T Dx + (dx^T) A^T e \end{aligned}$$

再求二阶微分:

$$d^2(Ax + b)^T (Dx + e) = d(x^T A^T D dx) + d[(dx^T) A^T Dx] = 2(dx^T) A^T D dx$$

因此其 Hessian 矩阵为:

$$H[(Ax + b)^T (Dx + e)] = A^T D + (A^T D)^T = A^T D + D^T A$$

(2) 先求一阶微分:

$$\begin{aligned} d(Ax + b)^T C (Dx + e) &= (Ax + b)^T C d(Dx + e) + d(Ax + b)^T C (Dx + e) \\ &= (x^T A^T + b^T) C D dx + (dx^T) A^T C (Dx + e) \\ &= x^T A^T C D dx + b^T C D dx + (dx^T) A^T C Dx + (dx^T) A^T C e \end{aligned}$$

再求二阶微分:

$$d^2(Ax + b)^T C (Dx + e) = d(x^T A^T C D dx) + d[(dx^T) A^T C Dx] = 2(dx^T) A^T C D dx$$

因此其 Hessian 矩阵为:

$$H[(Ax + b)^T C (Dx + e)] = A^T C D + (A^T C D)^T = A^T C D + D^T C^T A$$

(3) 令 (2) 中的 $D = A, e = b$, 便有

$$H[(Ax + b)^T C (Ax + b)] = A^T C A + (A^T C A)^T = A^T C A + A^T C^T A = A^T (C^T + C) A$$

3.28 令 \mathbf{x} 为复向量, 求下列实值函数的复 Hessian 矩阵:

- (1) $(\mathbf{Ax} + \mathbf{b})^H(\mathbf{Dx} + \mathbf{e})$ 。
 (2) $(\mathbf{Ax} + \mathbf{b})^H\mathbf{C}(\mathbf{Dx} + \mathbf{e})$ 。
 (3) $(\mathbf{Ax} + \mathbf{b})^H\mathbf{C}(\mathbf{Ax} + \mathbf{b})$ 。

解 注: \mathbf{C} 应当为 Hermitian 矩阵

- (1) 设 $f(\mathbf{x}) = (\mathbf{Ax} + \mathbf{b})^H(\mathbf{Dx} + \mathbf{e})$

$$f(\mathbf{x}) = \mathbf{x}^H \mathbf{A}^H \mathbf{D} \mathbf{x} + \mathbf{b}^H \mathbf{D} \mathbf{x} + \mathbf{x}^H \mathbf{A}^H \mathbf{e} + \mathbf{b}^H \mathbf{e}$$

$$\mathbf{H}_{\mathbf{x}^*, \mathbf{x}} = \frac{\partial^2 f(\mathbf{x}, \mathbf{x}^*)}{\partial \mathbf{x}^* \partial \mathbf{x}^T} = \frac{\partial \mathbf{x}^H \mathbf{A}^H \mathbf{D} + \mathbf{b}^H \mathbf{D}}{\partial \mathbf{x}^*} = \mathbf{A}^H \mathbf{D}$$

$$\mathbf{H}_{\mathbf{x}^*, \mathbf{x}^*} = \frac{\partial^2 f(\mathbf{x}, \mathbf{x}^*)}{\partial \mathbf{x}^* \mathbf{x}^H} = \frac{\partial \mathbf{x}^T \mathbf{D}^T \mathbf{A}^* + \mathbf{e}^T \mathbf{A}^*}{\partial \mathbf{x}^*} = \mathbf{O}$$

$$\mathbf{H}_{\mathbf{x}, \mathbf{x}} = \mathbf{H}_{\mathbf{x}^*, \mathbf{x}^*}^* = \mathbf{O} \quad \mathbf{H}_{\mathbf{x}, \mathbf{x}^*} = \mathbf{H}_{\mathbf{x}^*, \mathbf{x}}^* = \mathbf{A}^T \mathbf{D}^*$$

$$\text{取 } \mathbf{H}_{\mathbf{x}^*, \mathbf{x}} = \frac{1}{2}(\mathbf{A}^H \mathbf{D} + \mathbf{D}^H \mathbf{A}), \quad \mathbf{H}_{\mathbf{x}, \mathbf{x}^*} = \frac{1}{2}(\mathbf{A}^T \mathbf{D}^* + \mathbf{D}^T \mathbf{A}^*)$$

$$\mathbf{H}[f(\mathbf{x})] = \begin{bmatrix} \frac{1}{2}(\mathbf{A}^H \mathbf{D} + \mathbf{D}^H \mathbf{A}) & \mathbf{O} \\ \mathbf{O} & \frac{1}{2}(\mathbf{A}^T \mathbf{D}^* + \mathbf{D}^T \mathbf{A}^*) \end{bmatrix}$$

- (2) 设 $f(\mathbf{x}) = (\mathbf{Ax} + \mathbf{b})^H \mathbf{C}(\mathbf{Dx} + \mathbf{e})$

$$f(\mathbf{x}) = \mathbf{x}^H \mathbf{A}^H \mathbf{C} \mathbf{D} \mathbf{x} + \mathbf{b}^H \mathbf{C} \mathbf{D} \mathbf{x} + \mathbf{x}^H \mathbf{A}^H \mathbf{C} \mathbf{e} + \mathbf{b}^H \mathbf{C} \mathbf{e}$$

$$\mathbf{H}_{\mathbf{x}^*, \mathbf{x}} = \frac{\partial^2 f(\mathbf{x}, \mathbf{x}^*)}{\partial \mathbf{x}^* \partial \mathbf{x}^T} = \frac{\partial \mathbf{x}^H \mathbf{A}^H \mathbf{C} \mathbf{D} + \mathbf{b}^H \mathbf{C} \mathbf{D}}{\partial \mathbf{x}^*} = \mathbf{A}^H \mathbf{C} \mathbf{D}$$

$$\mathbf{H}_{\mathbf{x}^*, \mathbf{x}^*} = \frac{\partial^2 f(\mathbf{x}, \mathbf{x}^*)}{\partial \mathbf{x}^* \mathbf{x}^H} = \frac{\partial \mathbf{x}^T \mathbf{D}^T \mathbf{C}^T \mathbf{A}^* + \mathbf{e}^T \mathbf{C}^T \mathbf{A}^*}{\partial \mathbf{x}^*} = \mathbf{O}$$

$$\mathbf{H}_{\mathbf{x}, \mathbf{x}} = \mathbf{H}_{\mathbf{x}^*, \mathbf{x}^*}^* = \mathbf{O} \quad \mathbf{H}_{\mathbf{x}, \mathbf{x}^*} = \mathbf{H}_{\mathbf{x}^*, \mathbf{x}}^* = \mathbf{A}^T \mathbf{C}^* \mathbf{D}^*$$

$$\text{取 } \mathbf{H}_{\mathbf{x}^*, \mathbf{x}} = \frac{1}{2}(\mathbf{A}^H \mathbf{C} \mathbf{D} + \mathbf{D}^H \mathbf{C} \mathbf{A}), \quad \mathbf{H}_{\mathbf{x}, \mathbf{x}^*} = \frac{1}{2}(\mathbf{A}^T \mathbf{C}^* \mathbf{D}^* + \mathbf{D}^T \mathbf{C}^T \mathbf{A}^*)$$

$$\mathbf{H}[f(\mathbf{x})] = \begin{bmatrix} \frac{1}{2}(\mathbf{A}^H \mathbf{C} \mathbf{D} + \mathbf{D}^H \mathbf{C} \mathbf{A}) & \mathbf{O} \\ \mathbf{O} & \frac{1}{2}(\mathbf{A}^T \mathbf{C}^* \mathbf{D}^* + \mathbf{D}^T \mathbf{C}^T \mathbf{A}^*) \end{bmatrix}$$

- (3) 设 $f(\mathbf{x}) = (\mathbf{Ax} + \mathbf{b})^H \mathbf{C}(\mathbf{Ax} + \mathbf{b})$

由 (2) 可得

$$\mathbf{H}[f(\mathbf{x})] = \begin{bmatrix} \frac{1}{2}(\mathbf{A}^H \mathbf{C} \mathbf{A} + \mathbf{A}^H \mathbf{C} \mathbf{A}) & \mathbf{O} \\ \mathbf{O} & \frac{1}{2}(\mathbf{A}^T \mathbf{C}^* \mathbf{A}^* + \mathbf{A}^T \mathbf{C}^T \mathbf{A}^*) \end{bmatrix}$$

第三次 作业

4.3(1)

解

$$E_w = \mathbf{e}^H \mathbf{W} \mathbf{e} = (\mathbf{y} - \mathbf{A} \boldsymbol{\theta})^H \mathbf{W} (\mathbf{y} - \mathbf{A} \boldsymbol{\theta})$$

因此可以求其关于 $\boldsymbol{\theta}$ 的共轭梯度：

$$\nabla_{\boldsymbol{\theta}^*} = \mathbf{A}^H \mathbf{W} \mathbf{A} \boldsymbol{\theta} - \mathbf{A}^H \mathbf{W} \mathbf{y}$$

令共轭梯度为 0 求得 $\boldsymbol{\theta}$ 的加权最小二乘估计为：

$$\hat{\boldsymbol{\theta}}_{\text{LS}} = (\mathbf{A}^H \mathbf{W} \mathbf{A})^{-1} \mathbf{A}^H \mathbf{W} \mathbf{y}$$

4.4

解 将约束条件 $\text{Re}(\mathbf{w}^H \mathbf{x}) = b$ 转化为

$$\mathbf{w}^H \mathbf{x} + \mathbf{x}^H \mathbf{w} = 2b$$

则可以构造如下的 Lagrange 函数：

$$J(\mathbf{w}, \lambda) = \mathbf{w}^H \mathbf{R}_e \mathbf{w} + \lambda(2b - \mathbf{w}^H \mathbf{x} - \mathbf{x}^H \mathbf{w})$$

注意到代价函数 $f(\mathbf{w}) = \mathbf{E}(\mathbf{w}^H \mathbf{e} \mathbf{e}^H \mathbf{w})$ 是一个实标量函数，其约束条件也为实方程，因此构造的 Lagrange 函数应为实标量函数，即 $\lambda \in \mathbb{R}$ 。

将该函数分别关于 \mathbf{w} 和 λ 求导并令其为零有：

$$\frac{\partial J(\mathbf{w}, \lambda)}{\partial \mathbf{w}} = \mathbf{R}_e^T \mathbf{w}^* - \lambda \mathbf{x}^* = 0$$

$$\frac{\partial J(\mathbf{w}, \lambda)}{\partial \lambda} = 2b - \mathbf{w}^H \mathbf{x} - \mathbf{x}^H \mathbf{w} = 0$$

由于协方差矩阵 \mathbf{R}_e 为 Hermitian 矩阵，且 $\lambda \in \mathbb{R}$ ，则上述两个条件可转化为：

$$\mathbf{R}_e \mathbf{w} = \lambda \mathbf{x}$$

$$\mathbf{w}^H \mathbf{x} + \mathbf{x}^H \mathbf{w} = 2b$$

(1) \mathbf{R}_e 为非奇异矩阵时：

可以得到 $\mathbf{w} = \lambda \mathbf{R}_e^{-1} \mathbf{x}$ ，代入约束条件并利用 \mathbf{R}_e 为 Hermitian 矩阵有：

$$\lambda \mathbf{x}^H \mathbf{R}_e^{-1} \mathbf{x} + \lambda \mathbf{x}^H \mathbf{R}_e^{-1} \mathbf{x} = 2b$$

因此可以解得

$$\lambda = \frac{b}{\mathbf{x}^H \mathbf{R}_e^{-1} \mathbf{x}}$$

进一步地可以得到最优滤波器 \mathbf{w} 为

$$\mathbf{w} = \frac{b \mathbf{R}_e^{-1} \mathbf{x}}{\mathbf{x}^H \mathbf{R}_e^{-1} \mathbf{x}}$$

(2) \mathbf{R}_e 为奇异矩阵时：

易知 \mathbf{R}_e 存在零特征值 λ_0 ，因此其对应的特征向量 \mathbf{v}_0 满足

$$\mathbf{v}_0 \in \ker \mathbf{R}_e$$

也即

$$\mathbf{R}_e \mathbf{v}_0 = 0$$

因此当 $\mathbf{w} = \mathbf{v}_0$ 时，有

$$f(\mathbf{w}) = f(\mathbf{v}_0) = \mathbf{v}_0^H \mathbf{R}_e \mathbf{v}_0 = 0$$

故最优滤波器 \mathbf{w} 为

$$\mathbf{w} = \mathbf{v}_0$$

4.12

证明 首先证明约束条件的等价性：

$$\begin{aligned} E\{\mathbf{e} - \boldsymbol{\varepsilon}\} &= E\{\mathbf{A}\mathbf{y} - \boldsymbol{\varepsilon}\} \\ &= E\{\mathbf{A}(\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}) - \boldsymbol{\varepsilon}\} \\ &= \mathbf{A}\mathbf{X}\boldsymbol{\beta} + E\{\mathbf{A}\boldsymbol{\varepsilon} - \boldsymbol{\varepsilon}\} \\ &= \mathbf{A}\mathbf{X}\boldsymbol{\beta} + \mathbf{0} \end{aligned}$$

因此 $E\{\mathbf{e} - \boldsymbol{\varepsilon}\} = \mathbf{0}$ 等价于

$$\mathbf{A}\mathbf{X} = \mathbf{O}$$

之后证明最优化问题的等价性：

$$\begin{aligned} E\{(\mathbf{e} - \boldsymbol{\varepsilon})^T(\mathbf{e} - \boldsymbol{\varepsilon})\} &= E\{(\mathbf{A}\mathbf{y} - \boldsymbol{\varepsilon})^T(\mathbf{A}\mathbf{y} - \boldsymbol{\varepsilon})\} \\ &= E\{(\mathbf{A}\mathbf{X}\boldsymbol{\beta} + \mathbf{A}\boldsymbol{\varepsilon} - \boldsymbol{\varepsilon})^T(\mathbf{A}\mathbf{X}\boldsymbol{\beta} + \mathbf{A}\boldsymbol{\varepsilon} - \boldsymbol{\varepsilon})\} \\ &= E\{(\mathbf{A}\boldsymbol{\varepsilon} - \boldsymbol{\varepsilon})^T(\mathbf{A}\boldsymbol{\varepsilon} - \boldsymbol{\varepsilon})\} \\ &= E\{\boldsymbol{\varepsilon}^T(\mathbf{A} - \mathbf{I})^T(\mathbf{A} - \mathbf{I})\boldsymbol{\varepsilon}\} \\ &= E\{\text{tr}[(\mathbf{A} - \mathbf{I})^T(\mathbf{A} - \mathbf{I})\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}^T]\} \\ &= \text{tr}\{(\mathbf{A} - \mathbf{I})^T(\mathbf{A} - \mathbf{I})E(\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}^T)\} \\ &= \text{tr}\{(\mathbf{A} - \mathbf{I})^T(\mathbf{A} - \mathbf{I})\sigma^2\mathbf{I}\} \\ &= \sigma^2[\text{tr}(\mathbf{A}^T\mathbf{A}) - 2\text{tr}(\mathbf{A}) + \text{tr}(\mathbf{I})] \end{aligned}$$

因此最优化问题 $\min E\{(\mathbf{e} - \boldsymbol{\varepsilon})^T(\mathbf{e} - \boldsymbol{\varepsilon})\}$ 等价于

$$\min [\text{tr}(\mathbf{A}^T\mathbf{A}) - 2\text{tr}(\mathbf{A})]$$

课外习题 1

解 构造如下的 Lagrange 函数：

$$J(\mathbf{x}, \boldsymbol{\lambda}) = \|\mathbf{x}\|_2^2 + \boldsymbol{\lambda}^T(\mathbf{b} - \mathbf{A}\mathbf{x})$$

将该函数分别对 \mathbf{x} 和 $\boldsymbol{\lambda}$ 求导并令其为零有：

$$\begin{aligned} \frac{\partial J(\mathbf{x}, \boldsymbol{\lambda})}{\partial \mathbf{x}} &= 2\mathbf{x} - \mathbf{A}^T\boldsymbol{\lambda} = \mathbf{0} \\ \frac{\partial J(\mathbf{x}, \boldsymbol{\lambda})}{\partial \boldsymbol{\lambda}} &= \mathbf{b} - \mathbf{A}\mathbf{x} = \mathbf{0} \end{aligned}$$

因此可以得到关于 $\boldsymbol{\lambda}$ 和 \mathbf{x} 的方程组：

$$\mathbf{A}^T\boldsymbol{\lambda} = 2\mathbf{x} \quad (1)$$

$$\mathbf{A}\mathbf{x} = \mathbf{b} \quad (2)$$

首先消去 \mathbf{x} ，对 (1) 式两边同时左乘 \mathbf{A} 有

$$\mathbf{A}\mathbf{A}^T\boldsymbol{\lambda} = 2\mathbf{A}\mathbf{x} = 2\mathbf{b}$$

则 $\boldsymbol{\lambda}$ 可以表示成如下的形式：

$$\boldsymbol{\lambda} = 2(\mathbf{A}\mathbf{A}^T)^\dagger \mathbf{b} + [\mathbf{I} - (\mathbf{A}\mathbf{A}^T)^\dagger \mathbf{A}\mathbf{A}^T]\mathbf{y}$$

将上式代入 (1) 式中有

$$\begin{aligned}\mathbf{x}^* &= \frac{1}{2}\mathbf{A}^T\lambda = \mathbf{A}^T(\mathbf{A}\mathbf{A}^T)^\dagger\mathbf{b} + \frac{1}{2}\mathbf{A}^T[\mathbf{I} - (\mathbf{A}\mathbf{A}^T)^\dagger\mathbf{A}\mathbf{A}^T]\mathbf{y} \\ &= \mathbf{A}^T(\mathbf{A}\mathbf{A}^T)^\dagger\mathbf{b} + \frac{1}{2}[\mathbf{A}^T - \mathbf{A}^T(\mathbf{A}\mathbf{A}^T)^\dagger\mathbf{A}\mathbf{A}^T]\mathbf{y}\end{aligned}$$

由 Moore-Penrose 逆矩阵的定义和性质可知:

$$\mathbf{A}^\dagger = \mathbf{A}^T(\mathbf{A}\mathbf{A}^T)^\dagger \quad (\mathbf{A}^T)^\dagger = (\mathbf{A}\mathbf{A}^T)^\dagger\mathbf{A}$$

进一步化简可得:

$$\begin{aligned}\mathbf{x}^* &= \mathbf{A}^\dagger\mathbf{b} + \frac{1}{2}[\mathbf{A}^T - \mathbf{A}^T(\mathbf{A}^T)^\dagger\mathbf{A}^T]\mathbf{y} \\ &= \mathbf{A}^\dagger\mathbf{b}\end{aligned}$$

课外习题 2

解 首先求出 $f(\mathbf{x})$ 的梯度:

$$\nabla_{\mathbf{x}}f(\mathbf{x}) = \begin{bmatrix} 4x_1^3 + 6x_1^2 + 4x_1 - 2x_2 \\ -2x_1 + 2x_2 \end{bmatrix}$$

令梯度为 0 可得到如下方程组:

$$\begin{cases} 4x_1^3 + 6x_1^2 + 4x_1 - 2x_2 = 0 \\ -2x_1 + 2x_2 = 0 \end{cases}$$

解得

$$\begin{cases} x_1 = 0 \\ x_2 = 0 \end{cases} \quad \text{或} \quad \begin{cases} x_1 = -\frac{1}{2} \\ x_2 = -\frac{1}{2} \end{cases} \quad \text{或} \quad \begin{cases} x_1 = -1 \\ x_2 = -1 \end{cases}$$

即有三个一阶稳定点

$$\mathbf{x}^{(1)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \mathbf{x}^{(2)} = \begin{bmatrix} -\frac{1}{2} \\ -\frac{1}{2} \end{bmatrix}, \mathbf{x}^{(3)} = \begin{bmatrix} -1 \\ -1 \end{bmatrix}$$

再求 $f(\mathbf{x})$ 的 Hessian 矩阵:

$$\mathbf{H}[f(\mathbf{x})] = \begin{bmatrix} 12x_1^2 + 12x_1 + 4 & -2 \\ -2 & 2 \end{bmatrix}$$

分别代入 $\mathbf{x}^{(1)}$ 、 $\mathbf{x}^{(2)}$ 、 $\mathbf{x}^{(3)}$ 可得:

$$\mathbf{H}[f(\mathbf{x}^{(1)})] = \begin{bmatrix} 4 & -2 \\ -2 & 2 \end{bmatrix}, \mathbf{H}[f(\mathbf{x}^{(2)})] = \begin{bmatrix} 1 & -2 \\ -2 & 2 \end{bmatrix}, \mathbf{H}[f(\mathbf{x}^{(3)})] = \begin{bmatrix} 4 & -2 \\ -2 & 2 \end{bmatrix}$$

由

$$\text{tr}\{\mathbf{H}[f(\mathbf{x})]\} = \lambda_1 + \lambda_2, |\mathbf{H}[f(\mathbf{x})]| = \lambda_1\lambda_2$$

可以通过求 Hessian 矩阵的迹和行列式判断其特征值符号, 进而判断其正定性。易知 $\mathbf{H}[f(\mathbf{x}^{(1)})]$ 和 $\mathbf{H}[f(\mathbf{x}^{(3)})]$ 正定, $\mathbf{H}[f(\mathbf{x}^{(2)})]$ 不定, 因此 $\mathbf{x}^{(2)}$ 为鞍点, $\mathbf{x}^{(1)}$ 和 $\mathbf{x}^{(3)}$ 都是局部最优点 (极小值点), 代入数据可得


$$f(\mathbf{x}^{(1)}) = f(\mathbf{x}^{(3)}) = 0$$

另外容易看出

$$f(\mathbf{x}) = x_1^2(x_1 + 1)^2 + (x_1 - x_2)^2 \geq 0$$

因此 $\mathbf{x}^{(1)}$ 和 $\mathbf{x}^{(3)}$ 都是全局最小值点。

第四次 作业

 **6.1** 考虑线性方程 $A\theta + \varepsilon = x$ ，其中， ε 为加性有色噪声向量，满足条件 $\mathbb{E}\{\varepsilon\} = \mathbf{0}$ 和 $\mathbb{E}\{\varepsilon\varepsilon^T\} = R$ 。令 R 已知，并使用加权误差函数 $Q(\theta) = \varepsilon^T W \varepsilon$ 作为求参数向量 θ 最优估计 $\hat{\theta}_{\text{WLS}}$ 的代价函数。这种方法称为加权最小二乘方法。证明

$$\hat{\theta}_{\text{WLS}} = (A^T W A)^{-1} A^T W x$$

其中，加权矩阵 W 的最优选择为 $W_{\text{opt}} = R^{-1}$ 。

证明 首先，将 $\varepsilon = x - A\theta$ 代入到 $Q(\theta)$ 中得到

$$\begin{aligned} Q(\theta) &= \varepsilon^T W \varepsilon \\ &= (x - A\theta)^T W (x - A\theta) \\ &= x^T W x - x^T W A \theta - \theta^T A^T W x + \theta^T A^T W A \theta \end{aligned}$$

考虑到加权矩阵 W 为对称矩阵，因此求 $Q(\theta)$ 的梯度并令其为零有

$$\frac{\partial Q(\theta)}{\partial \theta} = 2A^T W A \theta - 2A^T W x = \mathbf{0}$$

因此得到最优的参数估计

$$\hat{\theta}_{\text{WLS}} = (A^T W A)^{-1} A^T W x$$

因此估计误差的协方差矩阵可表示为

$$\begin{aligned} K &= \mathbb{E}\{(\theta - \hat{\theta}_{\text{WLS}})(\theta - \hat{\theta}_{\text{WLS}})^T\} \\ &= (A^T W A)^{-1} A^T W R W A (A^T W A)^{-1} \end{aligned}$$

为了求得最优的加权矩阵，需要使估计误差的均方误差最小，也即最小化 K 的迹，即令

$$\frac{\partial \text{tr}(K)}{\partial W} = \mathbf{0}$$

求 $\text{tr}(K)$ 的微分，有

$$\begin{aligned} d\text{tr}(K) &= \text{tr}(dK) \\ &= \text{tr}[d(A^T W A)^{-1} \cdot A^T W R W A (A^T W A)^{-1} + (A^T W A)^{-1} A^T dW \cdot R W A (A^T W A)^{-1} \\ &\quad + (A^T W A)^{-1} A^T W R dW \cdot A (A^T W A)^{-1} + (A^T W A)^{-1} A^T W R W A d(A^T W A)^{-1}] \end{aligned}$$

由 PI63 表 3.2.4 可知

$$d(A^T W A)^{-1} = -(A^T W A)^{-1} A^T dW \cdot A (A^T W A)^{-1}$$

并由矩阵迹的性质 $\text{tr}(AB) = \text{tr}(BA)$ 可知

$$\begin{aligned} d\text{tr}(K) &= \text{tr}[-A(A^T W A)^{-1} A^T W R W A (A^T W A)^{-2} A^T dW + R W A (A^T W A)^{-2} A^T dW \\ &\quad + A(A^T W A)^{-2} A^T W R dW - A(A^T W A)^{-2} A^T W R W A (A^T W A)^{-1} A^T dW] \end{aligned}$$

为了使过程更加直观，我们记 $B = A(A^T W A)^{-1} A^T W R W A (A^T W A)^{-2} A^T$, $C = R W A (A^T W A)^{-2} A^T$ ，则可化为

$$d\text{tr}(K) = \text{tr}[-(B + B^T)dW] + \text{tr}[(C + C^T)dW]$$

因此可以得到其梯度为

$$\frac{\partial \text{tr}(K)}{\partial W} = (C + C^T) - (B + B^T) = \mathbf{0}$$

即 $C = B$ 或 $C = B^T$ ，展开得

$$\begin{aligned} A(A^T W A)^{-1} A^T W R W A (A^T W A)^{-2} A^T &= R W A (A^T W A)^{-2} A^T \quad \text{或} \\ A(A^T W A)^{-2} A^T W R W A (A^T W A)^{-1} A^T &= R W A (A^T W A)^{-2} A^T \end{aligned}$$

可以看出上述两式均在 $\mathbf{W} = \mathbf{R}^{-1}$ 时成立, 因此加权矩阵 \mathbf{W} 的最优选择为 $\mathbf{W}_{\text{opt}} = \mathbf{R}^{-1}$ 。

6.4 令 $\lambda > 0$, 并且 $\mathbf{Ax} = \mathbf{b}$ 为超定方程。证明: 反 Tikhonov 正则化优化问题

$$\min \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 - \frac{1}{2} \lambda \|\mathbf{x}\|_2^2$$

的最优解为

$$\mathbf{x} = (\mathbf{A}^H \mathbf{A} - \lambda \mathbf{I})^{-1} \mathbf{A}^H \mathbf{b}$$

证明 令代价函数

$$\begin{aligned} f(\mathbf{x}) &= \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 - \frac{1}{2} \lambda \|\mathbf{x}\|_2^2 \\ &= \frac{1}{2} (\mathbf{Ax} - \mathbf{b})^H (\mathbf{Ax} - \mathbf{b}) - \frac{1}{2} \lambda \mathbf{x}^H \mathbf{x} \\ &= \frac{1}{2} (\mathbf{x}^H \mathbf{A}^H - \mathbf{b}^H) (\mathbf{Ax} - \mathbf{b}) - \frac{1}{2} \lambda \mathbf{x}^H \mathbf{x} \\ &= \frac{1}{2} \mathbf{x}^H \mathbf{A}^H \mathbf{Ax} - \frac{1}{2} \mathbf{x}^H \mathbf{A}^H \mathbf{b} - \frac{1}{2} \mathbf{b}^H \mathbf{Ax} + \frac{1}{2} \mathbf{b}^H \mathbf{b} - \frac{1}{2} \lambda \mathbf{x}^H \mathbf{x} \end{aligned}$$

令其梯度为零有

$$\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} = \mathbf{A}^H \mathbf{Ax} - \mathbf{A}^H \mathbf{b} - \lambda \mathbf{x} = \mathbf{0}$$

因此最优解为

$$\mathbf{x} = (\mathbf{A}^H \mathbf{A} - \lambda \mathbf{I})^{-1} \mathbf{A}^H \mathbf{b}$$

6.7 已知数据点 (1, 3), (3, 1), (5, 7), (4, 6), (7, 4), 分别求总体最小二乘和一般最小二乘的拟合直线, 并分析它们的距离平方和。

解 (1) 总体最小二乘:

i) 计算均值向量

$$\bar{\mathbf{x}} = \frac{1}{5} \sum_{i=1}^5 \mathbf{x}_i = \frac{1}{5} \left\{ \begin{bmatrix} 1 \\ 3 \end{bmatrix} + \begin{bmatrix} 3 \\ 1 \end{bmatrix} + \begin{bmatrix} 5 \\ 7 \end{bmatrix} + \begin{bmatrix} 4 \\ 6 \end{bmatrix} + \begin{bmatrix} 7 \\ 4 \end{bmatrix} \right\} = \begin{bmatrix} 4 \\ 4.2 \end{bmatrix}$$

ii) 构造 5×2 矩阵 \mathbf{M}

$$\mathbf{M} = \begin{bmatrix} (\mathbf{x}_1 - \bar{\mathbf{x}})^T \\ \vdots \\ (\mathbf{x}_5 - \bar{\mathbf{x}})^T \end{bmatrix} = \begin{bmatrix} -3 & -1.2 \\ -1 & -3.2 \\ 1 & 2.8 \\ 0 & 1.8 \\ 3 & -0.2 \end{bmatrix}$$

iii) 对 $\mathbf{M}^T \mathbf{M}$ 进行 EVD

$$\mathbf{M}^T \mathbf{M} = \begin{bmatrix} 20 & 9 \\ 9 & 20.8 \end{bmatrix} = \begin{bmatrix} 0.6505 & -0.7595 \\ 0.7595 & 0.6505 \end{bmatrix} \begin{bmatrix} 30.5082 & 0 \\ 0 & 12.2918 \end{bmatrix} \begin{bmatrix} 0.6505 & -0.7595 \\ 0.7595 & 0.6505 \end{bmatrix}^T$$

iv) 确定直线方程: $-0.7595(x - 4) + 0.6505(y - 4.2) = 0$

v) 计算距离平方和

$$D_{\text{TLS}} = \left\| \begin{bmatrix} -3 & -1.2 \\ -1 & -3.2 \\ 1 & 2.8 \\ 0 & 1.8 \\ 3 & -0.2 \end{bmatrix} \begin{bmatrix} -0.7595 \\ 0.6505 \end{bmatrix} \right\|_2^2 = 12.2918$$

(2) 一般最小二乘:

i) 代价函数表示为

$$D_{LS}^{(1)} = \sum_{i=1}^5 [m(x_i - \bar{x})^2 + (y_i - \bar{y})^2] = (-3m - 1.2)^2 + (-m - 3.2)^2 + (m + 2.8)^2 + 1.8^2 + (3m - 0.2)^2$$

$$\frac{\partial D_{LS}^{(1)}}{\partial m} = 40m + 18 = 0 \Rightarrow m = -0.45$$

则直线方程为

$$-0.45(x - 4) + (y - 4.2) = 0$$

距离平方和为

$$d_{LS}^{(1)} = \frac{D_{LS}^{(1)}}{1 + m^2} = 15.5925$$

ii) 代价函数表示为

$$D_{LS}^{(2)} = \sum_{i=1}^5 [(x_i - \bar{x})^2 + m(y_i - \bar{y})^2] = (-3 - 1.2m)^2 + (-1 - 3.2m)^2 + (1 + 2.8m)^2 + (1.8m)^2 + (3 - 0.2m)^2$$


$$\frac{\partial D_{LS}^{(2)}}{\partial m} = 45.6m + 18 = 0 \Rightarrow m = -0.3947$$

则直线方程为

$$(x - 4) - 0.3947(y - 4.2) = 0$$

距离平方和为

$$d_{LS}^{(2)} = \frac{D_{LS}^{(2)}}{1 + m^2} = 14.2305$$

 7.7 证明以下各题:

(1) 若 $\mathbf{A} = \mathbf{A}^2 = \mathbf{A}^H \in \mathbb{C}^{n \times n}$, 并且 $\text{rank}(\mathbf{A}) = r < n$, 则存在 $n \times n$ 酉矩阵 \mathbf{V} , 使得

$$\mathbf{V}^H \mathbf{A} \mathbf{V} = \text{diag}(\mathbf{I}_r, \mathbf{0})$$

(2) 若 $\mathbf{A} = \mathbf{A}^H \in \mathbb{C}^{n \times n}$, 并且 $\mathbf{A}^2 = \mathbf{I}_n$, 则存在酉矩阵 \mathbf{V} , 使得

$$\mathbf{V}^H \mathbf{A} \mathbf{V} = \text{diag}(\mathbf{I}_r, -\mathbf{I}_{n-r})$$

证明 (1) 由于 $\mathbf{A} = \mathbf{A}^H$, 则 \mathbf{A} 酉相似于对角阵, 即存在 $n \times n$ 酉矩阵 \mathbf{V} 和 $n \times n$ 对角矩阵 $\mathbf{\Sigma}$, 使得

$$\mathbf{A} = \mathbf{V} \mathbf{\Sigma} \mathbf{V}^H$$

由于 $\mathbf{A} = \mathbf{A}^2$, 因此有 $\mathbf{\Sigma} = \mathbf{\Sigma}^2$, 即对于对角矩阵 $\mathbf{\Sigma}$ 上的任意一个对角元素 σ_i , 有 $\sigma_i = \sigma_i^2$, 即 σ_i 总为 0 或 1。那么总可以交换 \mathbf{V} 中列向量的顺序, 使得所有的 $\sigma_i = 1$ 集中在一起, 所有的 $\sigma_i = 0$ 集中在一起, 由于 $\text{rank}(\mathbf{A}) = r$, 因此总可以得到

$$\mathbf{\Sigma} = \text{diag}(\mathbf{I}_r, \mathbf{0})$$

由 \mathbf{V} 是酉矩阵的性质, 得到

$$\mathbf{V}^H \mathbf{A} \mathbf{V} = \text{diag}(\mathbf{I}_r, \mathbf{0})$$

(2) 与 (1) 同理可以得到


$$\mathbf{\Sigma}^2 = \mathbf{I}_n$$

因此对于对角矩阵 $\mathbf{\Sigma}$ 上的任意一个对角元素 σ_i , 有 $\sigma_i^2 = 1$, 即 $\sigma_i = \pm 1$ 。那么总可以交换 \mathbf{V} 中列向量的顺序, 使得所有的 $\sigma_i = 1$ 集中在一起, 所有的 $\sigma_i = -1$ 集中在一起, 因此总可以得到

$$\mathbf{\Sigma} = \text{diag}(\mathbf{I}_r, -\mathbf{I}_{n-r})$$

由 \mathbf{V} 是酉矩阵的性质, 得到

$$\mathbf{V}^H \mathbf{A} \mathbf{V} = \text{diag}(\mathbf{I}_r, -\mathbf{I}_{n-r})$$

 **7.17** 已知 $\mathbf{u} = [1, 1, -1]^T$ 是矩阵 $\mathbf{A} = \begin{bmatrix} 2 & -1 & 2 \\ 5 & a & 3 \\ -1 & b & -2 \end{bmatrix}$ 的一个特征向量。

(1) 求 a, b 和特征向量 \mathbf{u} 对应的特征值。

(2) 矩阵 \mathbf{A} 能否相似于对角矩阵? 试说明理由。

解 (1) 令 $\mathbf{A}\mathbf{u} = \lambda\mathbf{u}$, 有

$$\begin{bmatrix} 2 & -1 & 2 \\ 5 & a & 3 \\ -1 & b & -2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix} = \begin{bmatrix} -1 \\ 2+a \\ 1+b \end{bmatrix} = \lambda \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix}$$

解得 $\lambda = -1, a = -3, b = 0$.

(2) 由 (1) 可知矩阵 \mathbf{A} 为

$$\mathbf{A} = \begin{bmatrix} 2 & -1 & 2 \\ 5 & -3 & 3 \\ -1 & 0 & -2 \end{bmatrix}$$

令 $\det(\lambda\mathbf{I} - \mathbf{A}) = 0$, 有

$$(\lambda + 1)^3 = 0$$

即特征值 $\lambda = -1$ 的代数多重度为 3。


考虑如下关于 \mathbf{u} 的方程

$$(\mathbf{A} - \lambda\mathbf{I})\mathbf{u} \Big|_{\lambda=-1} = \begin{bmatrix} 3 & -1 & 2 \\ 5 & -2 & 3 \\ -1 & 0 & -1 \end{bmatrix} \mathbf{u} = \mathbf{0}$$

其系数矩阵满足

$$\text{rank}(\mathbf{A} + \mathbf{I}) = \text{rank} \begin{bmatrix} 3 & -1 & 2 \\ 5 & -2 & 3 \\ -1 & 0 & -1 \end{bmatrix} = 2$$

因此其基础解系为 $n - \text{rank}(\mathbf{A} + \mathbf{I}) = 1$ 个, 从而特征值 $\lambda = -1$ 的几何多重度为 1, 因此代数多重度大于几何多重度, 矩阵 \mathbf{A} 不能相似于对角矩阵。

 **7.34** 令 \mathbf{A} 为实斜对称矩阵, 即其元素 $a_{ij} = -a_{ji}$ 。证明:

(1) \mathbf{A} 的特征值是纯虚数或零。

(2) 若 $\mathbf{u} + j\mathbf{v}$ 是与特征值 $j\mu$ (其中 μ 是非零的实数) 对应的特征向量, 并且 \mathbf{u} 和 \mathbf{v} 为实向量, 则 \mathbf{u} 与 \mathbf{v} 正交。

证明 (1) 由 \mathbf{A} 为实斜对称矩阵可知

$$\mathbf{A} + \mathbf{A}^T = \mathbf{O}$$

设 \mathbf{A} 的特征值 λ 及其对应的特征向量 \mathbf{x} , 则有

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x}$$

取共轭转置, 有

$$\mathbf{x}^H \mathbf{A}^H = \lambda^* \mathbf{x}^H$$

由 \mathbf{A} 为实斜对称矩阵有

$$\mathbf{x}^H \mathbf{A}^T = -\mathbf{x}^H \mathbf{A} = \lambda^* \mathbf{x}^H$$

对上式的等式两侧同时右乘向量 \mathbf{x} 有

$$-\mathbf{x}^H \mathbf{A}\mathbf{x} = -\lambda \mathbf{x}^H \mathbf{x} = \lambda^* \mathbf{x}^H \mathbf{x}$$

因此

$$(\lambda + \lambda^*)\mathbf{x}^H\mathbf{x} = 0$$

由于 $\mathbf{x}^H\mathbf{x} = \|\mathbf{x}\|_2^2 > 0$, 因此

$$\lambda + \lambda^* = 0$$

即 \mathbf{A} 的特征值为纯虚数或零。

(2) 由已知得

$$\mathbf{A}(\mathbf{u} + \mathbf{j}\mathbf{v}) = \mathbf{j}\mu(\mathbf{u} + \mathbf{j}\mathbf{v}) = -\mu\mathbf{v} + \mathbf{j}\mu\mathbf{u}$$

因此

$$\mathbf{A}\mathbf{u} = -\mu\mathbf{v}, \mathbf{A}\mathbf{v} = \mu\mathbf{u}$$

左式左乘 \mathbf{u}^T , 右式取转置有

$$\mathbf{u}^T\mathbf{A}\mathbf{u} = -\mu\mathbf{u}^T\mathbf{v}$$

$$\mathbf{v}^T\mathbf{A}^T = -\mathbf{v}^T\mathbf{A} = \mu\mathbf{u}^T$$

将下式代入上式有

$$\mathbf{u}^T\mathbf{A}\mathbf{u} = \mathbf{v}^T\mathbf{A}\mathbf{v} = \mu\mathbf{v}^T\mathbf{u}$$

$$\mu\mathbf{v}^T\mathbf{u} = -\mu\mathbf{u}^T\mathbf{v}$$

因此有

$$\mu(\mathbf{u}^T\mathbf{v} + \mathbf{v}^T\mathbf{u}) = 2\mu(\mathbf{u}, \mathbf{v}) = 0$$

即 $(\mathbf{u}, \mathbf{v}) = 0$, \mathbf{u} 与 \mathbf{v} 正交。

7.36 一滤波器的抽头延迟线的输出为 $y(k) = \mathbf{a}^T\mathbf{x}(k)$, 其中 $\mathbf{a} = [a_0, a_1, \dots, a_n]^T$ 和 $\mathbf{x}(k) = [x(k), x(k-1), \dots, x(k-n)]^T$. 令 $\mathbf{R}_x \stackrel{\text{def}}{=} \mathbb{E}\{\mathbf{x}\mathbf{x}^T\} = \mathbf{Q}\mathbf{\Sigma}\mathbf{Q}^T$, 其中 $\mathbf{\Sigma} = \text{diag}(\lambda_0, \lambda_1, \dots, \lambda_n)$. 如果输出序列 $\{y(k)\}$ 的均方值为 $J_a = \frac{1}{2}\mathbb{E}\{y^2(k)\}$, 证明以下结果:

(1) 在条件 $\mathbf{a}^T\mathbf{a} = 1$ 的约束下, 使 J_a 最小化等于 $J_w = \frac{1}{2} \sum_{i=0}^n w_i^2 \lambda_i$ 的最小化, 其中 $\mathbf{w} = [w_0, w_1, \dots, w_n]^T$, $\sum_{i=0}^n w_i^2 = 1$, 且 $\mathbf{w} = \mathbf{Q}^T\mathbf{a}$.

(2) 若取 $\mathbf{w} = [\pm 1, 0, \dots, 0]^T$, 则使 J_a 最小化的最优向量 $\mathbf{a} = \pm \mathbf{a}_0$, 其中, \mathbf{a}_0 是矩阵 \mathbf{R}_x 相对于最小特征值 λ_0 的特征向量。

证明 (1) 首先证明优化问题的等价性:

$$\begin{aligned} J_a &= \frac{1}{2}\mathbb{E}\{y^2(k)\} = \frac{1}{2}\mathbb{E}\{\mathbf{a}^T\mathbf{x}(k)\mathbf{x}(k)^T\mathbf{a}\} \\ &= \frac{1}{2}\mathbf{a}^T\mathbb{E}\{\mathbf{x}(k)\mathbf{x}(k)^T\}\mathbf{a} \\ &= \frac{1}{2}\mathbf{a}^T\mathbf{Q}\mathbf{\Sigma}\mathbf{Q}^T\mathbf{a} \\ &= \frac{1}{2}(\mathbf{Q}^T\mathbf{a})^T\mathbf{\Sigma}\mathbf{Q}^T\mathbf{a} \\ &= \frac{1}{2}\mathbf{w}^T\mathbf{\Sigma}\mathbf{w} \\ &= \frac{1}{2}\sum_{i=0}^n w_i^2 \lambda_i \end{aligned}$$


再说明约束条件的等价性:

由于 \mathbf{Q} 为正交矩阵, 因此有

$$\mathbf{a}^T\mathbf{a} = (\mathbf{Q}\mathbf{w})^T\mathbf{Q}\mathbf{w} = \mathbf{w}^T\mathbf{Q}^T\mathbf{Q}\mathbf{w} = \mathbf{w}^T\mathbf{w} = \sum_{i=0}^n w_i^2 = 1$$

(2) 若使 $J_{\mathbf{a}}$ 取得最小值, 也即 $J_{\mathbf{w}}$ 取得最小值, 考虑到约束条件 $\sum_{i=0}^n w_i^2 = 1$ 时, $J_{\mathbf{w}}$ 的最小值在 $\mathbf{w} = [\pm 1, 0, \dots, 0]^T$ 时取到, 设 $\mathbf{Q} = [\mathbf{a}_0, \mathbf{a}_1, \dots, \mathbf{a}_n]^T$, 则有

$$\mathbf{a} = \mathbf{Q}\mathbf{w} = \begin{bmatrix} \mathbf{a}_0 & \mathbf{a}_1 & \cdots & \mathbf{a}_n \end{bmatrix} \begin{bmatrix} \pm 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix} = \pm \mathbf{a}_0$$

 **7.55** 假定 $n \times n$ 维 Hermitian 矩阵 \mathbf{A} 的特征值按照顺序 $\lambda_1(\mathbf{A}) \geq \lambda_2(\mathbf{A}) \geq \dots \geq \lambda_n(\mathbf{A})$ 排列。用 Rayleigh 商证明:

(1) $\lambda_1(\mathbf{A} + \mathbf{B}) \geq \lambda_1(\mathbf{A}) + \lambda_n(\mathbf{B})$ 。

(2) $\lambda_n(\mathbf{A} + \mathbf{B}) \geq \lambda_n(\mathbf{A}) + \lambda_n(\mathbf{B})$

证明 由 Rayleigh 商的性质可知, 矩阵的最大和最小特征值分别为其 Rayleigh 商的最大和最小值。

(1)

$$\begin{aligned} \lambda_1(\mathbf{A} + \mathbf{B}) &= \max \frac{\mathbf{x}^H(\mathbf{A} + \mathbf{B})\mathbf{x}}{\mathbf{x}^H\mathbf{x}} \\ &= \max \left(\frac{\mathbf{x}^H\mathbf{A}\mathbf{x}}{\mathbf{x}^H\mathbf{x}} + \frac{\mathbf{x}^H\mathbf{B}\mathbf{x}}{\mathbf{x}^H\mathbf{x}} \right) \\ &\geq \max \left(\frac{\mathbf{x}^H\mathbf{A}\mathbf{x}}{\mathbf{x}^H\mathbf{x}} + \lambda_n(\mathbf{B}) \right) \\ &= \max \frac{\mathbf{x}^H\mathbf{A}\mathbf{x}}{\mathbf{x}^H\mathbf{x}} + \lambda_n(\mathbf{B}) \\ &= \lambda_1(\mathbf{A}) + \lambda_n(\mathbf{B}) \end{aligned}$$

(2)

$$\begin{aligned} \lambda_n(\mathbf{A} + \mathbf{B}) &= \min \frac{\mathbf{x}^H(\mathbf{A} + \mathbf{B})\mathbf{x}}{\mathbf{x}^H\mathbf{x}} \\ &= \min \left(\frac{\mathbf{x}^H\mathbf{A}\mathbf{x}}{\mathbf{x}^H\mathbf{x}} + \frac{\mathbf{x}^H\mathbf{B}\mathbf{x}}{\mathbf{x}^H\mathbf{x}} \right) \\ &\geq \min \frac{\mathbf{x}^H\mathbf{A}\mathbf{x}}{\mathbf{x}^H\mathbf{x}} + \min \frac{\mathbf{x}^H\mathbf{B}\mathbf{x}}{\mathbf{x}^H\mathbf{x}} \\ &= \lambda_n(\mathbf{A}) + \lambda_n(\mathbf{B}) \end{aligned}$$

第五次 作业

5.1 已知矩阵

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \\ 0 & 0 \end{bmatrix}$$

通过计算 $\mathbf{A}\mathbf{A}^T$ 和 $\mathbf{A}^T\mathbf{A}$ 的特征值和特征向量, 求矩阵 \mathbf{A} 的奇异值分解。

解 矩阵 $\mathbf{A}\mathbf{A}^T$ 为

$$\mathbf{A}\mathbf{A}^T = \begin{bmatrix} 2 & 2 & 0 \\ 2 & 2 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

其特征值为 4,0,0, 对应的特征向量为

$$\begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \\ 0 \end{bmatrix}, \begin{bmatrix} -\frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

矩阵 $\mathbf{A}^T\mathbf{A}$ 为

$$\mathbf{A}^T\mathbf{A} = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}$$

其特征值为 4,0, 对应的特征向量为

$$\begin{bmatrix} \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{bmatrix}, \begin{bmatrix} -\frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} \end{bmatrix}$$

因此矩阵 \mathbf{A} 的奇异值分解为

$$\mathbf{A} = \begin{bmatrix} \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} & 0 \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{bmatrix}^T$$

5.9 令 \mathbf{A} 为 $m \times n$ 矩阵, 且 \mathbf{P} 为 $m \times m$ 正交矩阵。证明 \mathbf{PA} 与 \mathbf{A} 的奇异值相同。矩阵 \mathbf{PA} 与 \mathbf{A} 的左、右奇异向量有何关系?

证明 设 \mathbf{A} 的奇异值分解为

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$$

由于 \mathbf{P} 和 \mathbf{U} 都是正交矩阵, 则显然 \mathbf{PU} 也是正交矩阵, 因此 \mathbf{PA} 的奇异值分解为

$$\mathbf{PA} = \mathbf{PU}\mathbf{\Sigma}\mathbf{V}^T$$

因此 \mathbf{PA} 与 \mathbf{A} 的奇异值相同, 且 \mathbf{PA} 与 \mathbf{A} 的右奇异向量也相同, \mathbf{PA} 的左奇异向量为 \mathbf{PU} 的列向量, \mathbf{A} 的左奇异向量为 \mathbf{U} 的列向量。

5.10 令 \mathbf{A} 是一个 $m \times n$ 矩阵, 并且 $\lambda_1, \dots, \lambda_n$ 是矩阵 $\mathbf{A}^T\mathbf{A}$ 的特征值, 相对应的特征向量为 $\mathbf{u}_1, \dots, \mathbf{u}_n$ 。证明 \mathbf{A} 的奇异值 σ_i 等于范数 $\|\mathbf{A}\mathbf{u}_i\|$, 即 $\sigma_i = \|\mathbf{A}\mathbf{u}_i\|, i = 1, \dots, n$ 。

证明 由于 $\lambda_i = \sigma_i^2$, 有

$$\mathbf{A}^T\mathbf{A}\mathbf{u}_i = \sigma_i^2\mathbf{u}_i$$

两边同时左乘 \mathbf{u}_i^T 得

$$(\mathbf{A}\mathbf{u}_i)^T(\mathbf{A}\mathbf{u}_i) = \sigma_i^2\mathbf{u}_i^T\mathbf{u}_i$$

由于 \mathbf{u}_i 为单位向量，因此有

$$\sigma_i = \|\mathbf{A}\mathbf{u}_i\|$$

5.15 假定计算机仿真的观测数据为

$$x(n) = \sqrt{20} \sin(2\pi 0.2n) + \sqrt{2} \sin(2\pi 0.215n) + w(n)$$

产生，其中， $w(n)$ 是一高斯白噪声，其均值为 0，方差为 1，并取 $n = 1, 2, \dots, 128$ 。试针对 10 次独立的仿真实验数据，分别确定自相关矩阵

$$\mathbf{R} = \begin{bmatrix} r(0) & r(-1) & \cdots & r(2p) \\ r(1) & r(0) & \cdots & r(-2p+1) \\ \vdots & \vdots & \ddots & \vdots \\ r(M) & r(M-1) & \cdots & r(M-2p) \end{bmatrix}$$

的有效秩。式中， $r(k) = \frac{1}{128} \sum_{i=1}^{128-k} x(i)x(i+k)$ 表示观测信号的样本自相关函数（未知的观测数据皆令其等于 0），并取 $M = 50, p = 10$ 。

解 采用 P297 的归一化奇异值方法计算有效秩，即有效秩为

$$\hat{r} = \max_i \frac{\sigma_i}{\sigma_1} \geq \varepsilon$$

这里阈值 ε 分别取 3% 和 5%。给出 Python 代码如下：

```
import numpy as np
import matplotlib.pyplot as plt
import itertools
T = 128
M = 50
p = 10
n = range(1, T + 1)
e = [0.03, 0.05]
R = np.zeros((M+1, 2*p+1))
def signal_x(n: int) -> float:
    """
    Calculate the value of the signal at a given time point.
    Args:
    n: The time point at which to calculate the signal value.
    Returns:
    float: The value of the signal at the given time point.
    """
    if n in range(1, T + 1):
        return (
            np.sqrt(20) * np.sin(2 * np.pi * 0.2 * n)
            + np.sqrt(2) * np.sin(2 * np.pi * 0.215 * n)
            + np.random.randn()
        )
    else:
        return 0
def acf(x, k: int, T: int) -> float:
    """
    Calculate the autocorrelation function (ACF) at lag k for a given signal.
    Args:
```

```

x: The signal function.
k: The lag at which to calculate the ACF.
T: The total number of time points in the signal.
Returns:
float: The value of the ACF at the specified lag.
"""
    return sum(x(i) * x(i + k) for i in range(1, T - k + 1)) / T
for i, j in itertools.product(range(M+1), range(2*p+1)):
    R[i,j] = acf(signal_x, i-j, T)
u, s, v = np.linalg.svd(R)
s /= s[0]
for e_this in e:
    for rank in range(1, 2*p+2):
        if s[rank]/s[0] < e_this:
            break
        else:
            continue
    print(f'选择阈值为{e_this}时的有效秩为{rank}')
```

两个不同的阈值运行结果均显示有效秩为 4.

给出 Matlab 代码如下:

```

clear
clc
T = 128; M = 50; p = 10;
e = 0.05; n = 1: T;
x = sqrt(20) * sin(2 * pi * 0.2 * n)
    + sqrt(2) * sin(2 * pi * 0.215 * n)
    + randn(1, T);
r = xcorr(x) / T;
R = zeros(M + 1, 2 * p + 1);
for i = 0: M
    R (m + 1, :) = r(T + m :- 1: T + m - 2 * p);
end
sigma = svd(R);
for i = 1 : length(sigma)
    if sigma(i) / sigma(1) < e
        r = i - 1;
        break;
    end
end
end
```

两个不同的阈值运行结果均显示有效秩为 4.

